

Übung 07: Zusammenhänge

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

Henrik Hadorf

08.06.2026

Setup

Lade die für deine Analyse nötigen Pakete.

```
library(haven)
library(dplyr)
library(ggplot2)
library(labelled)
```

Aufgabe 1: Daten laden

Lies den ALLBUS-Datensatz von 2023 ein. Speichere den Datensatz in einem Objekt namens `allbus_c_2023_raw`.

```
allbus_c_2023_raw <- haven::read_dta(here::here("./data/ZA8831_v1-3-0.dta"))
```

Unter Sitzungen => Sitzung 08 findest du außerdem eine mit summarytools erstellte Übersicht über den Datensatz. Lade sie gern herunter und lege sie in deinen Datenordner. Du wirst im Laufe dieser und zukünftiger Übungen die Gelegenheit bekommen, selbst auszuwählen, welche Zusammenhänge dich interessieren. Um diese Auswahl zu treffen, kannst du dich auf diese Datensatzübersicht stützen.

Aufgabe 2: Variablen vorbereiten

Suche dir zwei (oder mehr) Variablen aus, deren Zusammenhang dich interessiert. Nimm dazu gern die Datensatzübersicht zur Hand (siehe oben). Welches Bauchgefühl oder welche Vermutung hast du bezüglich des Zusammenhangs?

Häufigkeit Internetnutzung privat (xr20) und Alter (age)

Je älter die Befragte, desto seltener nutzt sie das Internet.

Mit dem look for-Befehl aus dem labelled-Package kannst du anschließend nach diesen Variablen suchen. Beantworte dir für jede der Variablen folgende Fragen: Welche Werte kann sie annehmen? Und welche davon sind in Wahrheit “Missings”? Konvertiere diese Werte zu NA. Transformiere dabei die Variable zu einem Faktor, wenn sie kategorial ist, oder zu einer numerischen Variable, wenn sie metrisch bzw. intervallskaliert ist. Vergiss bei ersterer Option nicht, die leeren Faktorlevel zu entfernen (siehe Skript zu Sitzung 08).

```
allbus_c_2023_raw %>%  
  labelled::look_for("xr20")
```

```
pos variable label col_type missing  
16 xr20      HAEUFIGKEIT INTERNETNUTZUN~ dbl+lbl 0
```

```
values  
[-42] DATENFEHLER: MFN  
[-10] TNZ: FILTER  
[-9] KEINE ANGABE  
[-8] WEISS NICHT  
[1] MEHRMALS TÄGLICH  
[2] CA. 1X AM TAG  
[3] MEHRMALS PRO WOCHE  
[4] CA. 1X PRO WOCHE  
[5] SELTENER  
[6] NIE
```

```
summary(allbus_c_2023_raw$age) # look_for("age") funktioniert nicht
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-32.00	37.00	54.00	52.14	66.00	99.00

```
allbus_c_2023 <- allbus_c_2023_raw %>%
  dplyr::mutate(
    xr20_f = haven::as_factor(dplyr::case_when(
      xr20 < 0 ~ NA, .default = xr20)) %>%
    forcats::fct_drop(),
    age_d = dplyr::case_when(age < 0 ~ NA, .default = as.double(age)))
```

Welche Werte kann sie annehmen?

age = 18 bis 99

xr20 = [1] mehrmals täglich, [2] ca. 1mal am Tag, [3] mehrmals pro Woche, [4] ca. 1mal pro Woche, [5] seltener, [6] nie

Und welche davon sind in Wahrheit "Missings"?


age = -32

xr20 = -42, -10, -9, -8


Aufgabe 3: Zusammenhang erkunden

Überlege dir, wie du den Zusammenhang, der dich interessiert, am besten darstellen könntest. In einer Kreuztabelle? In einem (gestapelten) Balkendiagramm? In einer Korrelationsmatrix oder einem Korrelationskoeffizienten? Nutze alle Darstellungsmöglichkeiten, die sinnvoll sind und führe die entsprechenden Analysen durch. Interpretiere dein Output unten.

```
# Boxplots Altersverteilung für jede Nutzungsgruppe
allbus_c_2023 %>%
  dplyr::filter(!is.na(xr20_f), !is.na(age_d)) %>%
  ggplot2::ggplot(aes(x = xr20_f, y = age_d)) +
  ggplot2::geom_boxplot(fill = "steelblue") +
  ggplot2::stat_summary(fun = mean, geom = "point",
                        shape = 3, size = 2, color = "red") +
  ggplot2::labs(x = "Häufigkeit private Internetnutzung",
                y = "Alter (Jahre)") +
  ggplot2::theme_bw() +
  ggplot2::theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



```
# Histogramm
allbus_c_2023 %>%
  dplyr::filter(!is.na(xr20_f), !is.na(age_d)) %>%
  ggplot2::ggplot(aes(x = age_d)) +
  ggplot2::geom_histogram(binwidth = 5, fill = "steelblue", color = "black") +
  ggplot2::facet_wrap(~ xr20_f) +
  ggplot2::labs(x = "Alter (Jahre)", y = "Anzahl") +
  ggplot2::theme_bw()
```



Im Einklang mit meiner Hypothese zeigen die Boxplots, dass der Altersdurchschnitt (sowohl Median als auch arith. Mittel) über die 6 Kategorien hinweg ansteigt -> Je seltener das Internet privat genutzt wird, desto höher liegt das typische Alter der Befragten.

Auch das gruppierte Histogramm scheint die Hypothese zu stützen. Die Grafik zeigt, dass kaum jemand unter 50 das Internet seltener als einmal täglich nutzt. Zugleich wird deutlich, dass die große Mehrheit der Befragten das Internet zumindest gelegentlich nutzt und nur ein verschwindend geringer Teil es gar nicht verwendet.