

Übung 05: Häufigkeiten — Musterlösung

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

Musterlösung

26.05.2026

Setup

```
library(here)
library(skimr)
library(summarytools)
library(dplyr)
library(questionr)
```

Aufgabe 1: Daten laden und vorbereiten

Lade den Datensatz `btw_2025_strukturdaten.RData`. Filtere anschließend die Landeszeilen heraus, sodass nur echte Wahlkreise übrig bleiben. Speichere das Ergebnis als `wk_btw_2025_strukt`. Wie viele Wahlkreise hat der gefilterte Datensatz?

```
load(here::here("output/btw_2025_strukturdaten.RData"))

wk_btw_2025_strukt <- btw_2025_strukturdaten %>%
  dplyr::filter(wahlkreis_nr < 900)
```

299 Zeilen — eine pro Wahlkreis. Die Landeszeilen (`wahlkreis_nr >= 900`) wurden herausgefiltert.

Aufgabe 2: Variable kennenlernen

Schaue dir die Variable `bev_dichte_ew_km2` (Bevölkerungsdichte in Einwohner pro km²) an. Nutze `summarytools::descr()` oder `skimr::skim()` oder auch `dplyr::summarize()` für einen ersten Überblick.

```
summarytools::descr(wk_btw_2025_strukt$bev_dichte_ew_km2)
```

Descriptive Statistics

`wk_btw_2025_strukt$bev_dichte_ew_km2`

Label: Bevölkerungsdichte am 31.12.2023 (EW je km²)

N: 299

	bev_dichte_ew_km2
-----	-----
Mean	918.58
Std.Dev	1458.34
Min	37.10
Q1	144.60
Median	269.00
Q3	977.10
Max	12189.60
MAD	244.18
IQR	798.70
CV	1.59
Skewness	3.23
SE.Skewness	0.14
Kurtosis	14.85
N.Valid	299.00
N	299.00
Pct.Valid	100.00

a) Was fällt dir auf?

Die Variable ist stark rechtsschief: der Median liegt bei ca. 270 EW/km², der Mittelwert aber deutlich höher. Das deutet darauf hin, dass wenige sehr dicht besiedelte Großstadtwahlkreise den Mittelwert nach oben ziehen.

b) Wie groß ist die Spannweite? Berechne sie mit `dplyr::summarise()` und interpretiere sie im gegebenen Kontext.

```

wk_btw_2025_strukt %>%
  dplyr::summarise(
    min = min(bev_dichte_ew_km2),
    max = max(bev_dichte_ew_km2),
    spannweite = max(bev_dichte_ew_km2) - min(bev_dichte_ew_km2)
  )

```

```

      min      max spannweite
1 37.1 12189.6    12152.5

```

Das Minimum beträgt ca. 37 EW/km², das Maximum ca. 12200 EW/km² — eine Spannweite von über 5000. Das zeigt die extreme Bandbreite zwischen dünn besiedelten ländlichen Wahlkreisen und dicht besiedelten Großstadtwahlkreisen.

Aufgabe 3: Variable klassieren

Erstelle mit `dplyr::case_when()` eine neue Variable `bev_dichte_kat`, die die Bevölkerungsdichte in vier Kategorien einteilt: ländlich (unter 100 EW/km²), halbstädtisch (100–500), städtisch (500–1500), Großstadt (über 1500). Setze die Variable anschließend als **factor** mit sinnvoller Reihenfolge.

```

wk_btw_2025_strukt <- wk_btw_2025_strukt %>%
  dplyr::mutate(bev_dichte_kat = dplyr::case_when(
    bev_dichte_ew_km2 < 100 ~ "ländlich",
    bev_dichte_ew_km2 >= 100 & bev_dichte_ew_km2 < 500 ~ "halbstädtisch",
    bev_dichte_ew_km2 >= 500 & bev_dichte_ew_km2 < 1500 ~ "städtisch",
    bev_dichte_ew_km2 >= 1500 ~ "Großstadt"
  ),
  bev_dichte_kat = factor(bev_dichte_kat,
    levels = c("ländlich", "halbstädtisch", "städtisch", "Großstadt")))

```

Aufgabe 4: Häufigkeitstabelle

Erstelle eine Häufigkeitstabelle der neuen Variable `bev_dichte_kat` mit `dplyr::count()`. Ergänze relative Häufigkeiten (`pct`) und kumulierte relative Häufigkeiten (`cum_pct`), jeweils auf zwei Nachkommastellen gerundet. Alternativ kannst du auch `questionr::freq()` verwenden.

```

wk_btw_2025_strukt %>%
  dplyr::count(bev_dichte_kat) %>%
  dplyr::mutate(pct = round(n / sum(n) * 100, 2),
               cum_pct = cumsum(pct))

```

	bev_dichte_kat	n	pct	cum_pct
1	ländlich	29	9.70	9.70
2	halbstädtisch	161	53.85	63.55
3	städtisch	49	16.39	79.94
4	Großstadt	60	20.07	100.01

Welche Kategorie ist am häufigsten vertreten? Was sagt das über die Struktur der Bundestagswahlkreise aus?

Die meisten Wahlkreise sind halbstädtisch. Das spiegelt wider, dass Wahlkreise nach Bevölkerungszahl, nicht nach Fläche eingeteilt werden.

Aufgabe 5: Ost-West-Vergleich

Erstelle zunächst eine neue Variable `ost_west`, die die Wahlkreise den Kategorien “Ost”, “West” und “Berlin” zuordnet. Nutze dafür `dplyr::case_when()`.

Erstelle anschließend eine gruppierte Häufigkeitstabelle mit `group_by` und `count`, die zeigt, wie sich die Bevölkerungsdichtekategorien innerhalb von Ost, West und Berlin verteilen. Die relativen Häufigkeiten sollen sich innerhalb jeder Gruppe auf 100% summieren.

Hinweis: Ostdeutsche Bundesländer: Brandenburg, Mecklenburg-Vorpommern, Sachsen, Sachsen-Anhalt, Thüringen. Berlin wird separat ausgewiesen.

```

wk_btw_2025_strukt <- wk_btw_2025_strukt %>%
  dplyr::mutate(ost_west = dplyr::case_when(
    land %in% c("Brandenburg", "Mecklenburg-Vorpommern",
               "Sachsen", "Sachsen-Anhalt", "Thüringen") ~ "Ost",
    land == "Berlin" ~ "Berlin",
    .default = "West"
  ))

wk_btw_2025_strukt %>%
  dplyr::group_by(ost_west) %>%
  dplyr::count(bev_dichte_kat) %>%
  dplyr::mutate(pct = round(n / sum(n) * 100, 2)) %>%
  dplyr::ungroup()

```

```
# A tibble: 9 x 4
  ost_west bev_dichte_kat      n    pct
  <chr>    <fct>          <int> <dbl>
1 Berlin  Großstadt         12 100
2 Ost     ländlich          19 39.6
3 Ost     halbstädtisch     21 43.8
4 Ost     städtisch          5 10.4
5 Ost     Großstadt          3  6.25
6 West    ländlich          10  4.18
7 West    halbstädtisch     140 58.6
8 West    städtisch          44 18.4
9 West    Großstadt         45 18.8
```

Was fällt dir beim Vergleich zwischen Ost und West auf? Gibt es Unterschiede in der Siedlungsstruktur?

In Ostdeutschland gibt es anteilig deutlich mehr ländliche Wahlkreise als im Westen — das spiegelt die geringere Bevölkerungsdichte in den neuen Bundesländern wider. Auch im Westen dominiert die halbstädtische Kategorie. Berlin ist erwartungsgemäß ausschließlich in den städtischen Kategorien vertreten.