

Sitzung 05: Kennwerte und deren Visualisierung

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

15.05.2026

Inhalt

Setup	1
01 Kennwerte mit <code>skimr::skim()</code>	4
02 Kennwerte mit <code>dplyr::summarise()</code>	6
03 Gruppieren mit <code>dplyr::group_by()</code>	8
04 Visualisierung mit Base R	10

Nun, da wir gelernt haben wie wir Datensätze einlesen, säubern und zusammenführen, können wir bereits viele spannende deskriptive politikwissenschaftliche Fragen beantworten. Solche Fragen kreisen meistens entweder um die **Verteilung von Merkmalen** oder um den **Zusammenhang zwischen Merkmalen** (dazu mehr in Sitzung 08).

Zum Beispiel: Wie ungleich ist Arbeitslosigkeit über Wahlkreise verteilt? Oder: Wo war die Wahlbeteiligung bei der Bundestagswahl 2025 am höchsten und wo am niedrigsten?

Setup

```
library(dplyr)
library(skimr)
library(summarytools)
library(here)

load(here::here("output/btw_2025_ergebnisse.RData"))
load(here::here("output/btw_2025_strukturdaten.RData"))
```

Kurze Erinnerung: was war da nochmal drin?

```
btw_2025_ergebnisse %>%  
  dplyr::glimpse()
```

Rows: 15,617

Columns: 19

```
$ wahlart      <chr> "BT", "BT", "BT", "BT", "BT", "BT", "BT", "BT", "BT~  
$ wahltag      <chr> "23.02.2025", "23.02.2025", "23.02.2025", "23.02.20~  
$ gebietsart   <chr> "Bund", "Bund", "Bund", "Bund", "Bund", "Bund", "Bu~  
$ gebietsnummer <int> 99, 99, 99, 99, 99, 99, 99, 99, 99, 99, 99, 99, 99, ~  
$ gebietsname  <chr> "Bundesgebiet", "Bundesgebiet", "Bundesgebiet", "Bu~  
$ ueg_gebietsart <chr> "", "", "", "", "", "", "", "", "", "", "", "", "", ~  
$ ueg_gebietsnummer <int> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, ~  
$ gruppenart   <chr> "System-Gruppe", "System-Gruppe", "System-Gruppe", ~  
$ gruppenname  <chr> "Wahlberechtigte", "Wählende", "Ungültige", "Ungült~  
$ gruppenreihenfolge <int> -4, -3, -2, -2, -1, -1, 1, 1, 2, 2, 3, 3, 4, 4, 5, ~  
$ stimme       <int> NA, NA, 1, 2, 1, 2, 1, 2, 1, 2, 1, 2, 1, 2, 1~  
$ anzahl       <int> 60510631, 49928653, 423264, 279141, 49505389, 49649~  
$ prozent      <dbl> NA, 82.512200, 0.847738, 0.559080, 99.152262, 99.44~  
$ vorp_anzahl  <int> 61172771, 46707343, 488483, 408956, 46218860, 46298~  
$ vorp_prozent <dbl> NA, 76.353159, 1.045838, 0.875571, 98.954162, 99.12~  
$ diff_prozent <dbl> -1.082410, 6.896796, -13.351335, -31.743024, 7.1107~  
$ diff_prozent_pkt <dbl> NA, 6.159041, -0.198100, -0.316491, 0.198100, 0.316~  
$ bemerkung    <lgl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, ~  
$ gewählt     <chr> "", "", "", "", "", "", "", "", "", "", "", "", "", "", ~
```

```
btw_2025_strukturdaten %>%  
  dplyr::glimpse()
```

Rows: 316

Columns: 52

```
$ land      <chr> "Schleswig-Holstein", "Schleswig-  
Holste~  
$ wahlkreis_nr <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 901,~  
$ wahlkreis_name <chr> "Flensburg - Schleswig", "Nordfriesland~  
$ gemeinden  <int> 124, 197, 178, 163, 3, 92, 49, 95, 49, ~  
$ flache_km2 <dbl> 2128.1, 2777.9, 2000.0, 2165.4, 143.0, ~  
$ bev_insgesamt_1000 <dbl> 301.2, 239.1, 223.6, 255.9, 273.7, 223.~
```

\$ bev_deutsche_1000	<dbl> 271.7, 216.7, 205.6, 238.2, 238.9, 203.~
\$ bev_auslander_pct	<dbl> 9.8, 9.4, 8.0, 6.9, 12.7, 8.8, 13.0, 9.~
\$ bev_dichte_ew_km2	<dbl> 141.5, 86.1, 111.8, 118.2, 1913.8, 171.~
\$ geburtensaldo_je_1000_ew	<dbl> -6.1, -7.1, -6.4, -6.0, -3.1, -7.4, -
4.~	
\$ wanderungssaldo_je_1000_ew	<dbl> 18.0, 16.3, 17.7, 17.5, 9.8, 17.9, 16.3~
\$ alter_unter_18_pct	<dbl> 16.9, 15.7, 16.5, 17.0, 15.1, 16.3, 17.~
\$ alter_18_24_pct	<dbl> 7.7, 7.0, 6.6, 6.5, 10.1, 6.7, 6.7, 6.6~
\$ alter_25_34_pct	<dbl> 12.3, 11.5, 10.9, 10.3, 17.3, 10.8, 10.~
\$ alter_35_59_pct	<dbl> 32.1, 32.5, 33.7, 34.0, 31.4, 33.0, 35.~
\$ alter_60_74_pct	<dbl> 19.2, 20.9, 20.5, 20.3, 15.8, 20.0, 18.~
\$ alter_75plus_pct	<dbl> 11.7, 12.5, 11.9, 12.0, 10.3, 13.1, 11.~
\$ boden_siedlung_verkehr_pct	<dbl> 12.6, 11.2, 11.7, 11.6, 54.5, 12.5, 22.~
\$ boden_vegetation_gewaesser_pct	<dbl> 87.4, 88.8, 88.3, 88.4, 45.5, 87.5, 77.~
\$ wohnungen_fertig_je_1000_ew	<dbl> 5.2, 6.5, 3.4, 4.3, 2.6, 3.9, 4.8, 5.9,~
\$ wohnungen_bestand_je_1000_ew	<dbl> 527.7, 604.9, 512.8, 508.8, 545.5, 519.~
\$ wohnflache_je_wohnung	<dbl> 94.4, 94.6, 97.8, 99.1, 72.0, 91.1, 91.~
\$ wohnflache_je_ew	<dbl> 49.8, 57.2, 50.1, 50.4, 39.3, 47.3, 45.~
\$ pkw_je_1000ew	<dbl> 597.8, 632.9, 631.5, 648.0, 460.9, 602.~
\$ pkw_elektro_hybrid_pct	<dbl> 5.7, 5.9, 5.2, 6.2, 6.3, 6.0, 6.7, 6.8,~
\$ unternehmen_je_1000ew	<dbl> 40.0, 56.4, 39.4, 38.3, 35.0, 37.7, 41.~
\$ handwerk_je_1000ew	<dbl> 6.8, 9.1, 6.8, 6.5, 4.4, 6.5, 7.2, 7.2,~
\$ schulabg_beruflich_2022	<dbl> 3.5, 3.1, 2.4, 2.0, 5.3, 4.1, 2.2, 2.3,~
\$ schulabg_allg_je_1000ew	<dbl> 9.9, 9.0, 8.3, 8.1, 8.4, 9.0, 9.2, 8.4,~
\$ schulabg_ohne_abschluss_pct	<dbl> 9.5, 10.0, 9.3, 10.5, 9.4, 8.9, 7.6, 7.~
\$ schulabg_hauptschule_pct	<dbl> 23.2, 20.6, 21.9, 18.9, 17.8, 19.9, 18.~
\$ schulabg_mittlere_reife_pct	<dbl> 34.0, 42.6, 38.0, 34.3, 29.4, 32.8, 34.~
\$ schulabg_abitur_pct	<dbl> 33.2, 26.8, 30.8, 36.3, 43.4, 38.4, 39.~
\$ kita_unter_3_quote	<dbl> 41.9, 36.0, 34.0, 42.8, 41.0, 37.8, 36.~
\$ kita_3_bis_6_quote	<dbl> 92.1, 91.0, 89.4, 92.7, 95.3, 87.9, 83.~
\$ einkommen_je_ew_2021	<int> 23052, 26700, 24456, 25749, 21680, 2381~
\$ bip_je_ew_2021	<int> 34278, 38762, 36003, 32892, 49099, 3255~
\$ svb_insgesamt_je_1000ew	<dbl> 357.9, 366.6, 324.1, 305.3, 504.6, 343.~
\$ svb_landwirtschaft_pct	<dbl> 1.7, 2.8, 3.0, 2.6, 0.2, 1.5, 2.2, 1.0,~
\$ svb_prod_gewerbe_pct	<dbl> 19.6, 19.9, 27.1, 23.8, 15.9, 21.2, 27.~
\$ svb_handel_gast_verkehr_pct	<dbl> 26.6, 32.6, 23.0, 22.9, 19.3, 28.3, 28.~
\$ svb_oeffentl_dienstl_pct	<dbl> 15.3, 12.5, 15.2, 17.3, 25.2, 18.6, 14.~
\$ svb_uebrige_dienstl_pct	<dbl> 36.8, 32.1, 31.9, 33.5, 39.5, 30.3, 27.~
\$ sgb_2_insgesamt_je_1000ew	<dbl> 71.1, 58.6, 67.5, 52.4, 110.6, 74.3, 70~
\$ sgb_2_nicht_erwerbsfaehig_pct	<dbl> 25.9, 26.2, 24.8, 27.4, 25.5, 27.5, 28.~
\$ sgb_2_auslander_pct	<dbl> 37.9, 37.3, 41.7, 44.3, 41.7, 39.4, 53.~
\$ alo_quote_insgesamt	<dbl> 6.3, 5.3, 5.7, 4.6, 7.6, 5.8, 5.4, 4.9,~
\$ alo_quote_maenner	<dbl> 6.9, 5.7, 6.0, 4.9, 8.2, 6.1, 5.6, 5.0,~

```
$ alo_quote_frauen      <dbl> 5.7, 4.9, 5.3, 4.1, 7.0, 5.5, 5.2, 4.7, ~
$ alo_quote_15_24      <dbl> 6.0, 4.9, 5.7, 5.4, 5.6, 6.0, 5.6, 4.2, ~
$ alo_quote_55_64      <dbl> 6.1, 5.3, 5.3, 4.3, 8.0, 5.4, 5.1, 4.9, ~
$ fussnoten            <chr> "", "", "", "", "", "", "", "", "", "", ~
```

01 Kennwerte mit skimr::skim()

Frage: Wie ungleich ist Arbeitslosigkeit über Wahlkreise verteilt?

Dazu erstellen wir erst einen Subdatensatz nur mit den Wahlkreisen:

```
wk <- btw_2025_strukturdaten %>%
  dplyr::filter(wahlkreis_nr < 900)
```

Alle Kennwerte zur Arbeitslosenquote auf einmal ausgeben:

```
wk %>%
  dplyr::select(alo_quote_insgesamt) %>%
  summary()
```

```
alo_quote_insgesamt
Min.   : 2.50
1st Qu.: 4.30
Median : 5.60
Mean   : 5.96
3rd Qu.: 7.30
Max.   :14.80
```

```
wk %>%
  dplyr::select(alo_quote_insgesamt) %>%
  summarytools::descr()
```

Descriptive Statistics

wk\$alo_quote_insgesamt

Label: Arbeitslosenquote November 2024 - insgesamt

N: 299

```

              alo_quote_insgesamt
-----
              Mean              5.96
```

Std.Dev	2.18
Min	2.50
Q1	4.30
Median	5.60
Q3	7.30
Max	14.80
MAD	2.22
IQR	3.00
CV	0.37
Skewness	0.81
SE.Skewness	0.14
Kurtosis	0.57
N.Valid	299.00
N	299.00
Pct.Valid	100.00

```

wk %>%
  dplyr::select(alo_quote_insgesamt) %>%
  skimr::skim()

```

Table 1: Data summary

Name	Piped data
Number of rows	299
Number of columns	1
Column type frequency:	
numeric	1
Group variables	None

Variable type: numeric

skim_variable	n_miss- ing	com- plete_rate	mean	sd	p0	p25	p50	p75	p100	hist
alo_quote_insgesamt	0	1	5.96	2.18	2.5	4.3	5.6	7.3	14.8	

02 Kennwerte mit `dplyr::summarise()`

Gezielt einzelne Kennwerte zur Arbeitslosigkeit ausgeben:

```
wk %>%  
  dplyr::summarise(  
    n = dplyr::n(),  
    min = min(alo_quote_insgesamt, na.rm = TRUE),  
    max = max(alo_quote_insgesamt, na.rm = TRUE),  
    range = max(alo_quote_insgesamt, na.rm = TRUE) - min(alo_quote_insgesamt, na.rm = TRUE),  
    mittelwert = mean(alo_quote_insgesamt, na.rm = TRUE),  
    sd = sd(alo_quote_insgesamt, na.rm = TRUE),  
    median = median(alo_quote_insgesamt, na.rm = TRUE),  
    mad = mad(alo_quote_insgesamt, na.rm = TRUE),  
    q25 = quantile(alo_quote_insgesamt, probs = 0.25, na.rm = TRUE),  
    q75 = quantile(alo_quote_insgesamt, probs = 0.75, na.rm = TRUE),  
    iqr = IQR(alo_quote_insgesamt, na.rm = TRUE)  
  ) %>%  
  t()
```

	[,1]
n	299.000000
min	2.500000
max	14.800000
range	12.300000
mittelwert	5.960201
sd	2.175517
median	5.600000
mad	2.223900
q25	4.300000
q75	7.300000
iqr	3.000000

Was sagt uns das?

- Die durchschnittliche Arbeitslosigkeit liegt bei etwa 6% in deutschen Wahlkreisen
- Im Durchschnitt weicht ein Wahlkreis ca. 2 PP vom Mittelwert ab
- Median ist etwas kleiner als der Mittelwert — Ausreißer nach oben, aber keine zu starke Verzerrung
- Zwischen dem Wahlkreis mit der niedrigsten (2,5%) und höchsten (14,8%) Arbeitslosenquote liegen fast 12 Prozentpunkte — erhebliche Ungleichheit

- Die mittleren 50% der Wahlkreise liegen zwischen 4,3% und 7,3% (IQR: 3 PP) — Abweichungen sind Ausreißer, nicht die Regel

Extremfälle identifizieren:

```
wk %>%
  dplyr::select(wahlkreis_name, land, alo_quote_insgesamt) %>%
  dplyr::arrange(alo_quote_insgesamt) %>%
  head(10)
```

	wahlkreis_name	land	alo_quote_insgesamt
1	Erding - Ebersberg	Bayern	2.5
2	Bad Tölz-Wolfratshausen - Miesbach	Bayern	2.5
3	Memmingen - Unterallgäu	Bayern	2.5
4	Roth	Bayern	2.6
5	Donau-Ries	Bayern	2.6
6	Biberach	Baden-Württemberg	2.6
7	Neu-Ulm	Bayern	2.7
8	Freising	Bayern	2.8
9	Augsburg-Land	Bayern	2.8
10	Schwandorf	Bayern	3.0

```
wk %>%
  dplyr::select(wahlkreis_name, land, alo_quote_insgesamt) %>%
  dplyr::arrange(alo_quote_insgesamt) %>%
  tail(10)
```

	wahlkreis_name	land	alo_quote_insgesamt
290	Bremen I	Bremen	10.4
291	Herne - Bochum II	Nordrhein-Westfalen	10.7
292	Essen II	Nordrhein-Westfalen	10.8
293	Essen III	Nordrhein-Westfalen	10.8
294	Bremen II - Bremerhaven	Bremen	11.7
295	Dortmund I	Nordrhein-Westfalen	11.7
296	Dortmund II	Nordrhein-Westfalen	11.7
297	Duisburg I	Nordrhein-Westfalen	12.7
298	Duisburg II	Nordrhein-Westfalen	12.7
299	Gelsenkirchen	Nordrhein-Westfalen	14.8

03 Gruppieren mit `dplyr::group_by()`

Kennwerte zur Arbeitslosenquote pro Bundesland:

```

wk %>%
  dplyr::group_by(land) %>%
  skimr::skim(alo_quote_insgesamt) %>%
  dplyr::select(-n_missing, -complete_rate)

```

Table 3: Data summary

Name	Piped data
Number of rows	299
Number of columns	52
Column type frequency: numeric	1
Group variables	land

Variable type: numeric

skim_variable	land	mean	sd	p0	p25	p50	p75	p100	hist
alo_quote_insgesamt	Baden-Württemberg	4.21	0.85	2.6	3.90	4.00	4.57	7.6	
alo_quote_insgesamt	Bayern	3.65	0.96	2.5	3.15	3.40	3.90	6.7	
alo_quote_insgesamt	Berlin	9.70	0.00	9.7	9.70	9.70	9.70	9.7	
alo_quote_insgesamt	Brandenburg	6.23	1.15	4.2	5.50	6.40	6.85	8.3	
alo_quote_insgesamt	Bremen	11.05	0.92	10.4	10.73	11.05	11.37	11.7	
alo_quote_insgesamt	Hamburg	8.00	0.00	8.0	8.00	8.00	8.00	8.0	
alo_quote_insgesamt	Hessen	5.36	1.10	3.7	4.50	5.10	6.25	8.0	
alo_quote_insgesamt	Mecklenburg-Vorpommern	7.73	1.06	6.2	7.18	7.70	8.60	8.9	

skim_variable	land	mean	sd	p0	p25	p50	p75	p100	hist
alo_quote_ins- gesamt	Niedersachsen	5.83	1.33	3.3	5.00	5.90	6.70	7.9	
alo_quote_ins- gesamt	Nordrhein- Westfalen	7.57	2.28	4.1	5.80	7.20	8.83	14.8	
alo_quote_ins- gesamt	Rheinland-Pfalz	5.15	1.11	3.7	4.30	5.10	5.90	7.2	
alo_quote_ins- gesamt	Saarland	6.92	1.93	5.3	5.90	6.35	7.37	9.7	
alo_quote_ins- gesamt	Sachsen	6.39	1.27	5.1	5.47	5.95	6.85	9.0	
alo_quote_ins- gesamt	Sachsen-Anhalt	7.45	1.12	5.7	6.73	7.55	8.43	8.8	
alo_quote_ins- gesamt	Schleswig-Holstein	5.75	1.08	4.6	4.95	5.40	6.05	7.8	
alo_quote_ins- gesamt	Thüringen	6.00	0.94	5.0	5.30	6.00	6.10	8.0	

```

alo_bula <- wk %>%
  dplyr::group_by(land) %>%
  dplyr::summarise(
    n = dplyr::n(),
    mittelwert = mean(alo_quote_insgesamt, na.rm = TRUE),
    sd = sd(alo_quote_insgesamt, na.rm = TRUE)
  )

alo_bula

```

```

# A tibble: 16 x 4
  land                n mittelwert    sd
  <chr>              <int>      <dbl> <dbl>
1 Baden-Württemberg   38        4.21 0.853
2 Bayern              47        3.65 0.963
3 Berlin              12        9.7  0
4 Brandenburg         10        6.23 1.15
5 Bremen               2       11.0 0.919
6 Hamburg              6         8    0
7 Hessen              22        5.36 1.10
8 Mecklenburg-Vorpommern 6        7.73 1.06
9 Niedersachsen       30        5.83 1.33
10 Nordrhein-Westfalen 64        7.57 2.28

```


11 Rheinland-Pfalz	15	5.15	1.11
12 Saarland	4	6.92	1.93
13 Sachsen	16	6.39	1.27
14 Sachsen-Anhalt	8	7.45	1.12
15 Schleswig-Holstein	11	5.75	1.08
16 Thüringen	8	6	0.937

04 Visualisierung mit Base R

Wie kann ich Lage- und Streuungsmaße nun visuell darstellen?

Boxplot — Wie ist die Arbeitslosigkeit über alle Wahlkreise bundesweit verteilt?

```
boxplot(wk$alo_quote_insgesamt)
```



Boxplot — Wie ist sie innerhalb der Bundesländer verteilt?

```
boxplot(alo_quote_insgesamt ~ land, data = wk)
```

