

# Sitzung 05: Kennwerte und deren Visualisierung

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

23.06.2026

## Inhalt

|                                                  |    |
|--------------------------------------------------|----|
| Setup                                            | 1  |
| 01 Kennwerte mit <code>skimr::skim()</code>      | 4  |
| 02 Kennwerte mit <code>dplyr::summarise()</code> | 6  |
| 03 Gruppieren mit <code>dplyr::group_by()</code> | 8  |
| 04 Visualisierung mit Base R                     | 10 |

Nun, da wir gelernt haben wie wir Datensätze einlesen, säubern und zusammenführen, können wir bereits viele spannende deskriptive politikwissenschaftliche Fragen beantworten. Solche Fragen kreisen meistens entweder um die **Verteilung von Merkmalen** oder um den **Zusammenhang zwischen Merkmalen** (dazu mehr in Sitzung 08).

Zum Beispiel: Wie ungleich ist Arbeitslosigkeit über Wahlkreise verteilt? Oder: Wo war die Wahlbeteiligung bei der Bundestagswahl 2025 am höchsten und wo am niedrigsten?

## Setup

```
library(dplyr)
library(skimr)
library(summarytools)
library(here)

load(here::here("output/btw_2025_ergebnisse.RData"))
load(here::here("output/btw_2025_strukturdaten.RData"))
```

Kurze Erinnerung: was war da nochmal drin?

```
btw_2025_ergebnisse %>%  
  dplyr::glimpse()
```

Rows: 15,617

Columns: 19

```
$ wahlart          <chr> "BT", "BT", "BT", "BT", "BT", "BT", "BT", "BT", "BT~  
$ wahltag          <chr> "23.02.2025", "23.02.2025", "23.02.2025", "23.02.20~  
$ gebietsart       <chr> "Bund", "Bund", "Bund", "Bund", "Bund", "Bund", "Bu~  
$ gebietsnummer    <int> 99, 99, 99, 99, 99, 99, 99, 99, 99, 99, 99, 99, 99, ~  
$ gebietsname      <chr> "Bundesgebiet", "Bundesgebiet", "Bundesgebiet", "Bu~  
$ ueg_gebietsart    <chr> "", "", "", "", "", "", "", "", "", "", "", "", "", ~  
$ ueg_gebietsnummer <int> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, ~  
$ gruppenart       <chr> "System-Gruppe", "System-Gruppe", "System-Gruppe", ~  
$ gruppenname      <chr> "Wahlberechtigte", "Wählende", "Ungültige", "Ungült~  
$ gruppenreihenfolge <int> -4, -3, -2, -2, -1, -1, 1, 1, 2, 2, 3, 3, 4, 4, 5, ~  
$ stimme           <int> NA, NA, 1, 2, 1, 2, 1, 2, 1, 2, 1, 2, 1, 2, 1, ~  
$ anzahl           <int> 60510631, 49928653, 423264, 279141, 49505389, 49649~  
$ prozent           <dbl> NA, 82.512200, 0.847738, 0.559080, 99.152262, 99.44~  
$ vorp_anzahl       <int> 61172771, 46707343, 488483, 408956, 46218860, 46298~  
$ vorp_prozent      <dbl> NA, 76.353159, 1.045838, 0.875571, 98.954162, 99.12~  
$ diff_prozent      <dbl> -1.082410, 6.896796, -13.351335, -31.743024, 7.1107~  
$ diff_prozent_pkt  <dbl> NA, 6.159041, -0.198100, -0.316491, 0.198100, 0.316~  
$ bemerkung        <lgl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, ~  
$ gewahlt          <chr> "", "", "", "", "", "", "", "", "", "", "", "", "", "", ~
```

```
btw_2025_strukturdaten %>%  
  dplyr::glimpse()
```

Rows: 316

Columns: 52

```
$ land              <chr> "Schleswig-Holstein", "Schleswig-  
Holste~  
$ wahlkreis_nr      <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 901,~  
$ wahlkreis_name     <chr> "Flensburg - Schleswig", "Nordfriesland~  
$ gemeinden         <int> 124, 197, 178, 163, 3, 92, 49, 95, 49, ~  
$ flache_km2         <dbl> 2128.1, 2777.9, 2000.0, 2165.4, 143.0, ~  
$ bev_insgesamt_1000 <dbl> 301.2, 239.1, 223.6, 255.9, 273.7, 223.~
```

|                                   |                                                |
|-----------------------------------|------------------------------------------------|
| \$ bev_deutsche_1000              | <dbl> 271.7, 216.7, 205.6, 238.2, 238.9, 203.~ |
| \$ bev_auslander_pct              | <dbl> 9.8, 9.4, 8.0, 6.9, 12.7, 8.8, 13.0, 9.~ |
| \$ bev_dichte_ew_km2              | <dbl> 141.5, 86.1, 111.8, 118.2, 1913.8, 171.~ |
| \$ geburtensaldo_je_1000_ew       | <dbl> -6.1, -7.1, -6.4, -6.0, -3.1, -7.4, -    |
| 4.~                               |                                                |
| \$ wanderungssaldo_je_1000_ew     | <dbl> 18.0, 16.3, 17.7, 17.5, 9.8, 17.9, 16.3~ |
| \$ alter_unter_18_pct             | <dbl> 16.9, 15.7, 16.5, 17.0, 15.1, 16.3, 17.~ |
| \$ alter_18_24_pct                | <dbl> 7.7, 7.0, 6.6, 6.5, 10.1, 6.7, 6.7, 6.6~ |
| \$ alter_25_34_pct                | <dbl> 12.3, 11.5, 10.9, 10.3, 17.3, 10.8, 10.~ |
| \$ alter_35_59_pct                | <dbl> 32.1, 32.5, 33.7, 34.0, 31.4, 33.0, 35.~ |
| \$ alter_60_74_pct                | <dbl> 19.2, 20.9, 20.5, 20.3, 15.8, 20.0, 18.~ |
| \$ alter_75plus_pct               | <dbl> 11.7, 12.5, 11.9, 12.0, 10.3, 13.1, 11.~ |
| \$ boden_siedlung_verkehr_pct     | <dbl> 12.6, 11.2, 11.7, 11.6, 54.5, 12.5, 22.~ |
| \$ boden_vegetation_gewaesser_pct | <dbl> 87.4, 88.8, 88.3, 88.4, 45.5, 87.5, 77.~ |
| \$ wohnungen_fertig_je_1000_ew    | <dbl> 5.2, 6.5, 3.4, 4.3, 2.6, 3.9, 4.8, 5.9,~ |
| \$ wohnungen_bestand_je_1000_ew   | <dbl> 527.7, 604.9, 512.8, 508.8, 545.5, 519.~ |
| \$ wohnflache_je_wohnung          | <dbl> 94.4, 94.6, 97.8, 99.1, 72.0, 91.1, 91.~ |
| \$ wohnflache_je_ew               | <dbl> 49.8, 57.2, 50.1, 50.4, 39.3, 47.3, 45.~ |
| \$ pkw_je_1000ew                  | <dbl> 597.8, 632.9, 631.5, 648.0, 460.9, 602.~ |
| \$ pkw_elektro_hybrid_pct         | <dbl> 5.7, 5.9, 5.2, 6.2, 6.3, 6.0, 6.7, 6.8,~ |
| \$ unternehmen_je_1000ew          | <dbl> 40.0, 56.4, 39.4, 38.3, 35.0, 37.7, 41.~ |
| \$ handwerk_je_1000ew             | <dbl> 6.8, 9.1, 6.8, 6.5, 4.4, 6.5, 7.2, 7.2,~ |
| \$ schulabg_beruflich_2022        | <dbl> 3.5, 3.1, 2.4, 2.0, 5.3, 4.1, 2.2, 2.3,~ |
| \$ schulabg_allg_je_1000ew        | <dbl> 9.9, 9.0, 8.3, 8.1, 8.4, 9.0, 9.2, 8.4,~ |
| \$ schulabg_ohne_abschluss_pct    | <dbl> 9.5, 10.0, 9.3, 10.5, 9.4, 8.9, 7.6, 7.~ |
| \$ schulabg_hauptschule_pct       | <dbl> 23.2, 20.6, 21.9, 18.9, 17.8, 19.9, 18.~ |
| \$ schulabg_mittlere_reife_pct    | <dbl> 34.0, 42.6, 38.0, 34.3, 29.4, 32.8, 34.~ |
| \$ schulabg_abitur_pct            | <dbl> 33.2, 26.8, 30.8, 36.3, 43.4, 38.4, 39.~ |
| \$ kita_unter_3_quote             | <dbl> 41.9, 36.0, 34.0, 42.8, 41.0, 37.8, 36.~ |
| \$ kita_3_bis_6_quote             | <dbl> 92.1, 91.0, 89.4, 92.7, 95.3, 87.9, 83.~ |
| \$ einkommen_je_ew_2021           | <int> 23052, 26700, 24456, 25749, 21680, 2381~ |
| \$ bip_je_ew_2021                 | <int> 34278, 38762, 36003, 32892, 49099, 3255~ |
| \$ svb_insgesamt_je_1000ew        | <dbl> 357.9, 366.6, 324.1, 305.3, 504.6, 343.~ |
| \$ svb_landwirtschaft_pct         | <dbl> 1.7, 2.8, 3.0, 2.6, 0.2, 1.5, 2.2, 1.0,~ |
| \$ svb_prod_gewerbe_pct           | <dbl> 19.6, 19.9, 27.1, 23.8, 15.9, 21.2, 27.~ |
| \$ svb_handel_gast_verkehr_pct    | <dbl> 26.6, 32.6, 23.0, 22.9, 19.3, 28.3, 28.~ |
| \$ svb_oeffentl_dienstl_pct       | <dbl> 15.3, 12.5, 15.2, 17.3, 25.2, 18.6, 14.~ |
| \$ svb_uebrige_dienstl_pct        | <dbl> 36.8, 32.1, 31.9, 33.5, 39.5, 30.3, 27.~ |
| \$ sgb_2_insgesamt_je_1000ew      | <dbl> 71.1, 58.6, 67.5, 52.4, 110.6, 74.3, 70~ |
| \$ sgb_2_nicht_erwerbsfaehig_pct  | <dbl> 25.9, 26.2, 24.8, 27.4, 25.5, 27.5, 28.~ |
| \$ sgb_2_auslander_pct            | <dbl> 37.9, 37.3, 41.7, 44.3, 41.7, 39.4, 53.~ |
| \$ alo_quote_insgesamt            | <dbl> 6.3, 5.3, 5.7, 4.6, 7.6, 5.8, 5.4, 4.9,~ |
| \$ alo_quote_maenner              | <dbl> 6.9, 5.7, 6.0, 4.9, 8.2, 6.1, 5.6, 5.0,~ |

```
$ alo_quote_frauen      <dbl> 5.7, 4.9, 5.3, 4.1, 7.0, 5.5, 5.2, 4.7, ~
$ alo_quote_15_24      <dbl> 6.0, 4.9, 5.7, 5.4, 5.6, 6.0, 5.6, 4.2, ~
$ alo_quote_55_64      <dbl> 6.1, 5.3, 5.3, 4.3, 8.0, 5.4, 5.1, 4.9, ~
$ fussnoten            <chr> "", "", "", "", "", "", "", "", "", "", ~
```

## 01 Kennwerte mit skimr::skim()

**Frage: Wie ungleich ist Arbeitslosigkeit über Wahlkreise verteilt?**

Dazu erstellen wir erst einen Subdatensatz nur mit den Wahlkreisen:

```
wk <- btw_2025_strukturdaten %>%
  dplyr::filter(wahlkreis_nr < 900)
```

Alle Kennwerte zur Arbeitslosenquote auf einmal ausgeben:

```
wk %>%
  dplyr::select(alo_quote_insgesamt) %>%
  summary()
```

```
alo_quote_insgesamt
Min.      : 2.50
1st Qu.: 4.30
Median : 5.60
Mean     : 5.96
3rd Qu.: 7.30
Max.     :14.80
```

```
wk %>%
  dplyr::select(alo_quote_insgesamt) %>%
  summarytools::descr()
```

Descriptive Statistics

wk\$alo\_quote\_insgesamt

Label: Arbeitslosenquote November 2024 - insgesamt

N: 299

```

              alo_quote_insgesamt
-----
              Mean              5.96
```

|             |        |
|-------------|--------|
| Std.Dev     | 2.18   |
| Min         | 2.50   |
| Q1          | 4.30   |
| Median      | 5.60   |
| Q3          | 7.30   |
| Max         | 14.80  |
| MAD         | 2.22   |
| IQR         | 3.00   |
| CV          | 0.37   |
| Skewness    | 0.81   |
| SE.Skewness | 0.14   |
| Kurtosis    | 0.57   |
| N.Valid     | 299.00 |
| N           | 299.00 |
| Pct.Valid   | 100.00 |

```

wk %>%
  dplyr::select(alo_quote_insgesamt) %>%
  skimr::skim()

```

Table 1: Data summary

|                        |            |
|------------------------|------------|
| Name                   | Piped data |
| Number of rows         | 299        |
| Number of columns      | 1          |
| Column type frequency: |            |
| numeric                | 1          |
| Group variables        | None       |

#### Variable type: numeric

| skim_variable       | n_miss-<br>ing | com-<br>plete_rate | mean | sd   | p0  | p25 | p50 | p75 | p100 | hist |
|---------------------|----------------|--------------------|------|------|-----|-----|-----|-----|------|------|
| alo_quote_insgesamt | 0              | 1                  | 5.96 | 2.18 | 2.5 | 4.3 | 5.6 | 7.3 | 14.8 |      |

## 02 Kennwerte mit `dplyr::summarise()`

Gezielt einzelne Kennwerte zur Arbeitslosigkeit ausgeben:

```
wk %>%
  dplyr::summarise(
    n = dplyr::n(),
    min = min(alo_quote_insgesamt, na.rm = TRUE),
    max = max(alo_quote_insgesamt, na.rm = TRUE),
    range = max(alo_quote_insgesamt, na.rm = TRUE) - min(alo_quote_insgesamt, na.rm = TRUE),
    mittelwert = mean(alo_quote_insgesamt, na.rm = TRUE),
    sd = sd(alo_quote_insgesamt, na.rm = TRUE),
    median = median(alo_quote_insgesamt, na.rm = TRUE),
    mad = mad(alo_quote_insgesamt, na.rm = TRUE),
    q25 = quantile(alo_quote_insgesamt, probs = 0.25, na.rm = TRUE),
    q75 = quantile(alo_quote_insgesamt, probs = 0.75, na.rm = TRUE),
    iqr = IQR(alo_quote_insgesamt, na.rm = TRUE)
  ) %>%
  t()
```

|            | [,1]       |
|------------|------------|
| n          | 299.000000 |
| min        | 2.500000   |
| max        | 14.800000  |
| range      | 12.300000  |
| mittelwert | 5.960201   |
| sd         | 2.175517   |
| median     | 5.600000   |
| mad        | 2.223900   |
| q25        | 4.300000   |
| q75        | 7.300000   |
| iqr        | 3.000000   |

Was sagt uns das?

- Die durchschnittliche Arbeitslosigkeit liegt bei etwa 6% in deutschen Wahlkreisen
- Im Durchschnitt weicht ein Wahlkreis ca. 2 PP vom Mittelwert ab
- Median ist etwas kleiner als der Mittelwert — Ausreißer nach oben, aber keine zu starke Verzerrung
- Zwischen dem Wahlkreis mit der niedrigsten (2,5%) und höchsten (14,8%) Arbeitslosenquote liegen fast 12 Prozentpunkte — erhebliche Ungleichheit

- Die mittleren 50% der Wahlkreise liegen zwischen 4,3% und 7,3% (IQR: 3 PP) — Abweichungen sind Ausreißer, nicht die Regel

Extremfälle identifizieren:

```
wk %>%
  dplyr::select(wahlkreis_name, land, alo_quote_insgesamt) %>%
  dplyr::arrange(alo_quote_insgesamt) %>%
  head(10)
```

|    | wahlkreis_name                     | land              | alo_quote_insgesamt |
|----|------------------------------------|-------------------|---------------------|
| 1  | Erding - Ebersberg                 | Bayern            | 2.5                 |
| 2  | Bad Tölz-Wolfratshausen - Miesbach | Bayern            | 2.5                 |
| 3  | Memmingen - Unterallgäu            | Bayern            | 2.5                 |
| 4  | Roth                               | Bayern            | 2.6                 |
| 5  | Donau-Ries                         | Bayern            | 2.6                 |
| 6  | Biberach                           | Baden-Württemberg | 2.6                 |
| 7  | Neu-Ulm                            | Bayern            | 2.7                 |
| 8  | Freising                           | Bayern            | 2.8                 |
| 9  | Augsburg-Land                      | Bayern            | 2.8                 |
| 10 | Schwandorf                         | Bayern            | 3.0                 |

```
wk %>%
  dplyr::select(wahlkreis_name, land, alo_quote_insgesamt) %>%
  dplyr::arrange(alo_quote_insgesamt) %>%
  tail(10)
```

|     | wahlkreis_name          | land                | alo_quote_insgesamt |
|-----|-------------------------|---------------------|---------------------|
| 290 | Bremen I                | Bremen              | 10.4                |
| 291 | Herne - Bochum II       | Nordrhein-Westfalen | 10.7                |
| 292 | Essen II                | Nordrhein-Westfalen | 10.8                |
| 293 | Essen III               | Nordrhein-Westfalen | 10.8                |
| 294 | Bremen II - Bremerhaven | Bremen              | 11.7                |
| 295 | Dortmund I              | Nordrhein-Westfalen | 11.7                |
| 296 | Dortmund II             | Nordrhein-Westfalen | 11.7                |
| 297 | Duisburg I              | Nordrhein-Westfalen | 12.7                |
| 298 | Duisburg II             | Nordrhein-Westfalen | 12.7                |
| 299 | Gelsenkirchen           | Nordrhein-Westfalen | 14.8                |

### 03 Gruppieren mit `dplyr::group_by()`

Kennwerte zur Arbeitslosenquote pro Bundesland:

```

wk %>%
  dplyr::group_by(land) %>%
  skimr::skim(alo_quote_insgesamt) %>%
  dplyr::select(-n_missing, -complete_rate)

```

Table 3: Data summary

|                                   |            |
|-----------------------------------|------------|
| Name                              | Piped data |
| Number of rows                    | 299        |
| Number of columns                 | 52         |
| Column type frequency:<br>numeric | 1          |
| Group variables                   | land       |

#### Variable type: numeric

| skim_variable       | land                   | mean  | sd   | p0   | p25   | p50   | p75   | p100 | hist |
|---------------------|------------------------|-------|------|------|-------|-------|-------|------|------|
| alo_quote_insgesamt | Baden-Württemberg      | 4.21  | 0.85 | 2.6  | 3.90  | 4.00  | 4.57  | 7.6  |      |
| alo_quote_insgesamt | Bayern                 | 3.65  | 0.96 | 2.5  | 3.15  | 3.40  | 3.90  | 6.7  |      |
| alo_quote_insgesamt | Berlin                 | 9.70  | 0.00 | 9.7  | 9.70  | 9.70  | 9.70  | 9.7  |      |
| alo_quote_insgesamt | Brandenburg            | 6.23  | 1.15 | 4.2  | 5.50  | 6.40  | 6.85  | 8.3  |      |
| alo_quote_insgesamt | Bremen                 | 11.05 | 0.92 | 10.4 | 10.73 | 11.05 | 11.37 | 11.7 |      |
| alo_quote_insgesamt | Hamburg                | 8.00  | 0.00 | 8.0  | 8.00  | 8.00  | 8.00  | 8.0  |      |
| alo_quote_insgesamt | Hessen                 | 5.36  | 1.10 | 3.7  | 4.50  | 5.10  | 6.25  | 8.0  |      |
| alo_quote_insgesamt | Mecklenburg-Vorpommern | 7.73  | 1.06 | 6.2  | 7.18  | 7.70  | 8.60  | 8.9  |      |



| skim_variable        | land                | mean | sd   | p0  | p25  | p50  | p75  | p100 | hist |
|----------------------|---------------------|------|------|-----|------|------|------|------|------|
| alo_quote_ins-gesamt | Niedersachsen       | 5.83 | 1.33 | 3.3 | 5.00 | 5.90 | 6.70 | 7.9  |      |
| alo_quote_ins-gesamt | Nordrhein-Westfalen | 7.57 | 2.28 | 4.1 | 5.80 | 7.20 | 8.83 | 14.8 |      |
| alo_quote_ins-gesamt | Rheinland-Pfalz     | 5.15 | 1.11 | 3.7 | 4.30 | 5.10 | 5.90 | 7.2  |      |
| alo_quote_ins-gesamt | Saarland            | 6.92 | 1.93 | 5.3 | 5.90 | 6.35 | 7.37 | 9.7  |      |
| alo_quote_ins-gesamt | Sachsen             | 6.39 | 1.27 | 5.1 | 5.47 | 5.95 | 6.85 | 9.0  |      |
| alo_quote_ins-gesamt | Sachsen-Anhalt      | 7.45 | 1.12 | 5.7 | 6.73 | 7.55 | 8.43 | 8.8  |      |
| alo_quote_ins-gesamt | Schleswig-Holstein  | 5.75 | 1.08 | 4.6 | 4.95 | 5.40 | 6.05 | 7.8  |      |
| alo_quote_ins-gesamt | Thüringen           | 6.00 | 0.94 | 5.0 | 5.30 | 6.00 | 6.10 | 8.0  |      |

```

alo_bula <- wk %>%
  dplyr::group_by(land) %>%
  dplyr::summarise(
    n = dplyr::n(),
    mittelwert = mean(alo_quote_insgesamt, na.rm = TRUE),
    sd = sd(alo_quote_insgesamt, na.rm = TRUE)
  )

alo_bula

```

```

# A tibble: 16 x 4
  land                n mittelwert    sd
  <chr>              <int>      <dbl> <dbl>
1 Baden-Württemberg   38        4.21 0.853
2 Bayern              47        3.65 0.963
3 Berlin              12        9.7  0
4 Brandenburg         10        6.23 1.15
5 Bremen               2       11.0 0.919
6 Hamburg              6         8    0
7 Hessen              22        5.36 1.10
8 Mecklenburg-Vorpommern 6        7.73 1.06
9 Niedersachsen       30        5.83 1.33
10 Nordrhein-Westfalen 64        7.57 2.28

```


|                       |    |      |       |
|-----------------------|----|------|-------|
| 11 Rheinland-Pfalz    | 15 | 5.15 | 1.11  |
| 12 Saarland           | 4  | 6.92 | 1.93  |
| 13 Sachsen            | 16 | 6.39 | 1.27  |
| 14 Sachsen-Anhalt     | 8  | 7.45 | 1.12  |
| 15 Schleswig-Holstein | 11 | 5.75 | 1.08  |
| 16 Thüringen          | 8  | 6    | 0.937 |

## 04 Visualisierung mit Base R

Wie kann ich Lage- und Streuungsmaße nun visuell darstellen?

Boxplot — Wie ist die Arbeitslosigkeit über alle Wahlkreise bundesweit verteilt?

```
boxplot(wk$alo_quote_insgesamt)
```



Boxplot — Wie ist sie innerhalb der Bundesländer verteilt?

```
boxplot(alo_quote_insgesamt ~ land, data = wk)
```

