

Quantitative Methoden mit R & R-Studio

Sommersemester 2026 | Sitzung 5

Maura Kratz

Recap

1. Struktur von Datensätzen überblicken und auf deren Kompatibilität hinarbeiten ✓
2. Datensätze basierend auf einer gemeinsamen Schlüsselvariable zusammenführen mit `dplyr::left_join()` ✓

Was heute ansteht:

- Check-In
- Besprechung der Übung 3
- Kennwerte und Visualisierung
- kurze Intro in Quarto

Feedback zu Übung 3

- dar steht für daraus/darunter (also “Sonstige Parteien”, “daraus BSW”)
- `filter()` und `select()` tun sehr unterschiedliche Dinge
- `filter()`-Aufgabe kann unterschiedlich gelöst werden: `wahlkreis_nr > 900`
oder `wahlkreis_name == "Land Insgesamt" | wahlkreis_name == "Insgesamt"` oder
`dplyr::filter(wknr %in% c(901, 902, 903 ... ))`
- in `case_when()` wurde `TRUE ~` durch `.default =` ersetzt

Exkurs CSV-Dateien

- CSV steht für *Comma-Separated Values*, aber in der Praxis gibt es Varianten, die sich im verwendeten **Spalten- & Dezimaltrenner** unterscheiden:
 - Englisch Format: Spalten durch `,` getrennt, Dezimalzahlen mit `.` (z.B. `1.5`)
 - Deutsches Format: Spalten durch `;` getrennt, Dezimalzahlen mit `,` (z.B. `1,5`)
- Das Format hängt von den **Systemeinstellungen** ab, mit denen die Datei gespeichert wurde

```
rio::import("daten.csv", sep = ";", dec = ",") # Deutsches csv-Format
rio::import("data.csv", sep = ",", dec = ".") # Englisch csv-Format
# Englisch ist der Standard in R und muss nicht explizit eingestellt werden.
```

Exkurs Encoding

Das Encoding bestimmt wie Sonderzeichen gespeichert werden.

Encoding	Typisch für
UTF-8	Mac, moderne Tools
latin1	Älteres Windows/Excel

Wenn Umlaute als `Ã¼` erscheinen ist das Encoding falsch.

```
rio::import("datei.csv", sep = ";", dec = ",",  
            encoding = "latin1")
```



Tip

Im Zweifel Datei kurz in RStudio öffnen und nachschauen!

Willkommen zurück!

I) Vorbereitung	01: Einführung in R und R-Studio	02: Projekte und Datenimport	03: Daten aufbereiten	04: Daten zusammenführen
II) Deskriptiv	05: Kannwerte & deren Visualisierung	06: Häufigkeiten & deren Visualisierung	07: The Grammar of Graphics	08: Korrelation & deskriptive Regression
III) Inferenz	09: Einfache und multiple lineare Regression (OLS)	10: Regression Diagnostics	11: Logistische Regression (GLM)	12: Varianzanalysen (ANOVA)
13: Wahlthema (Faktoranalyse, Indexbildung, ...) / Research Notes				
14: Wahlthema (Faktoranalyse, Indexbildung, ...) / Research Notes				

miro

Spannende Fragen an Daten lassen sich meistens zwei Polen zuordnen:

1. Variation einer Variable
(Kennwerte, Sitzung 5 & Häufigkeiten, Sitzung 06)
2. Kovariation zweier Variablen
(Zusammenhänge, Sitzung 08)

Voraussetzungen und Vokabeln

- Qualitative & quantitative, diskrete & stetige, latente & manifeste, unabhängige & abhängige Variablen
- Variable, Ausprägung, Fall
- Skalierung (definiert mögl. Ausprägungen):
 - Nominalskala
 - Ordinalskala
 - Intervallskala
 - Verhältnisskala

Voraussetzungen und Vokabeln

- Lagemaße
 - Modus
 - Mittelwert (arithmetisches Mittel)
 - Median
- Streuungsmaße
 - Spannweite (range)
 - Quartile, Interquartilsabstand (IQR)
 - Varianz, bzw. Standardabweichung
 - Mittlere absolute Abweichung vom Median (Median Absolute Deviation, MAD)

Skalenniveaus

Skalenniveau	Mögliche Aussagen	Beispiel(e)	Zulässige Operationen
kategorial · Nominalskala	Gleichheit / Verschiedenheit	Diagnosen, Religion, Parteipräferenz	=, ≠
kategorial · Ordinalskala	... & Rangfolge	Schulabschlüsse, Zustimmungswerte (Likert- Skala)	=, ≠, <, >
metrisch · Intervallskala	... & Interpretierbare Abstände	Temperatur in °C, Kalenderjahre, IQ	=, ≠, <, >, +, -
metrisch · Verhältnisskala	... & Absoluter Nullpunkt & interpretierbare Verhältnisse	Einkommen in Euro, Körpergröße in cm, Alter in Jahren	=, ≠, <, >, +, -, ×, ÷



Tip

Je höher das Skalenniveau, desto mehr mathematische Operationen sind zulässig.

Skalenniveau

Skalenniveau	Lagemaße			Streuungsmaße		
	Modus	Median	Mittelwert	Spannweite	IQR	Varianz & SD
Nominal	<i>ja</i>	<i>nein</i>	<i>nein</i>	<i>nein</i>	<i>nein</i>	<i>nein</i>
Ordinal	<i>ja</i>	<i>ja</i>	<i>nein</i>	<i>ja</i>	<i>ja</i>	<i>nein</i>
Intervall	<i>ja</i>	<i>ja</i>	<i>ja</i>	<i>ja</i>	<i>ja</i>	<i>ja</i>
Verhältnis	<i>ja</i>	<i>ja</i>	<i>ja</i>	<i>ja</i>	<i>ja</i>	<i>ja</i>

Hands On - Daten aggregieren



Datentransformation mit *dplyr*

Befehl	Beschreibung	Bsp
<code>mutate()</code>	Neue Variablen hinzufügen	<pre>df %>% mutate(anteil = stimmen / sum(stimmen))</pre>
<code>summarise()</code>	Mehrere Werte zusammenfassen	<pre>df %>% summarise(mean(stimmen))</pre>
<code>count()</code>	Häufigkeiten zählen	<pre>df %>% count(partei)</pre>
<code>group_by()</code>	Operationen gruppenweise ausführen	<pre>df %>% group_by(partei) %>% summarise(mean(stimmen))</pre>

Datentransformation mit *dplyr*




Tip

`dplyr::count()` zählt wie viele Zeilen pro Gruppe vorhanden sind. `count(land)` ist eine Abkürzung für `group_by(land) %>% summarise(n = n())`. Gibt immer eine Spalte mit Häufigkeitszählungen namens `n` zurück.

`dplyr::n()` zählt die Anzahl Zeilen in der aktuellen Gruppe — aber nur innerhalb von `summarise()`, `mutate()` oder `filter()`. Kann nicht alleinstehend aufgerufen werden.

Minute Cards

Bitte füllt die Minute Cards für die heutige Sitzung aus. Das sollt enicht länger als 3 Minuten dauern. Vielen Dank für eure Mitarbeit!



Vielen Dank und bis kommenden Dienstag!



Sitzung 5 von 14



Übung 4 zu “Daten Aggregieren” bis spätestens
Sonntagabend!