

Quantitative Methoden mit R & R-Studio

Sommersemester 2026 | Sitzung 10

Maura Kratz


Willkommen zurück!

I) Vorbereitung	01: Einführung in R und R-Studio	02: Projekte und Datenimport	03: Daten aufbereiten	04: Daten zusammenführen
II) Deskriptiv	05: Kannwerte & deren Visualisierung	06: Häufigkeiten & deren Visualisierung	07: The Grammar of Graphics	08: Zusammenhänge (Kreuztabellen, Korrelationen ...)
III) Inferenz	09: Einfache und multiple lineare (OLS) Regression	10: Regression Diagnostics	11: Logistische Regression (GLM)	
12: Wahlthema (Faktoranalyse, Indexbildung, ...) / Research Notes				
13: Wahlthema (Faktoranalyse, Indexbildung, ...) / Research Notes				

miro


Recap: Einfache lineare Regressionen

- Eine (einfache) lineare Regression zu rechnen heißt eine Gerade durch Punkte zu ziehen!
- UV $\rightarrow$ AV
- Wenn x um eine Einheit steigt, ändert sich y um den Betrag b.




Recap: Multiple lineare Regressionen

Einfache lineare Regression



Multiple lineare Regression



Recap: Multiple lineare Regressionen

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots + b_kx_k$$

- Die b -Koeffizienten geben den **spezifischen / isolierten Einfluss** jedes Prädiktors an:
- Wenn x_k um eine Einheit steigt, ändert sich y um b_k , **wenn alle anderen Prädiktoren konstant bleiben** (*ceteris paribus*).

Multiple ≠ Multivariate Regression

Multiple = mehrere **unabhängige** Variablen

Multivariate = mehrere **abhängige** Variablen

Wichtigste Marker einer Regression

- Regressionskoeffizient b
- Modellgüte: Bestimmtheitsmaß R^2 = Anteil der aufgeklärten Varianz
- Signifikanz:
 - p-Wert: Wie wahrscheinlich ist es, einen solchen oder noch extremeren Koeffizienten zu beobachten, wenn H_0 (= kein Zusammenhang) stimmte?
 - Beispielschwellwerte: $p < 0.001$ = hochsignifikant ***, $p < 0.01$ = signifikant **, $p < 0.05$ = schwach signifikant *, $p > 0.05$ = nicht signifikant
 - KI: 95% KI enthält 0 $\Rightarrow$ nicht signifikant; 95% KI enthält keinen Wert über 0 $\Rightarrow$ signifikant
 - In 95 von 100 Stichproben würde das berechnete Konfidenzintervall den wahren Regressionskoeffizienten in der Grundgesamtheit enthalten.
 - Wenn man den Zorn der Statistiker*innen auf sich ziehen will: Der wahre Regressionskoeffizient liegt mit 95%iger Wahrscheinlichkeit im KI.

Voraussetzungen und deren Bedeutung

Überblick: Voraussetzungen der linearen Regression

Nr	Voraussetzung	Worauf bezogen?	Folgen bei Verletzung
1	Skalenniveau (metrische AV)	Daten / Messung	Modell ist inhaltlich nicht interpretierbar
2	Exogenität	Modellspezifikation	Koeffizienten verzerrt (z.B. Omitted Variable Bias)
3	Unabhängige Beobachtungen	Studiendesign	Scheinsignifikanz
4	Linearität	Funktionale Form	Koeffizienten falsch
5	Homoskedastizität	Residuen	Scheinsignifikanz
6	Keine Multikollinearität*	UVs untereinander	Koeffizienten instabil, große Standardfehler
7	Keine Ausreißer	Einzelne Fälle	Schätzung instabil
(8)	Normalverteilung der Residuen (optional)	Residuen	Nur bei kleinem n: Inferenz ungenau

* nur bei multiplen linearen Regressionen (mind. zwei UVs). Voraussetzungen 1–3 sind der Analyse *vorgelagert* (Daten & Design), 4–8 werden *am geschätzten Modell* geprüft.

1 Skalenniveau: Welches Modell für welche Skala?

Skalenniveau der AV	Beispiel	Modell
Metrisch	Lebenszufriedenheit (0–10), Einkommen	Lineare Regression (OLS) — diese Sitzung
Dichotom (binär)	Wahlbeteiligung (ja/nein)	Logistische Regression — Sitzung 11!
Nominal (mehr als 2 Kategorien)	Parteiwahl (CDU, SPD, Grüne, ...)	Multinomiale logistische Regression
Ordinal	Zustimmung (stimme gar nicht zu; egal; ...voll zu)	Ordinale logistische Regression
Zählvariable	Anzahl Demonstrationsteilnahmen	Poisson- / Negativ-Binomial-Regression

Merke: Das Skalenniveau der **AV** bestimmt das Modell. Die UVs dürfen jedes Skalenniveau haben (kategoriale UVs als Dummies). Quasi-metrische AVs (z.B. 5er-Skalen) werden in der Praxis oft mit OLS gerechnet — umstritten, aber verbreitet.

2 Exogenität

- Die UVs dürfen nicht mit dem Fehlerterm korrelieren → alles, was die AV beeinflusst und *nicht* im Modell steht, darf nicht systematisch mit den UVs zusammenhängen.
- Häufigste Verletzung: Omitted Variable Bias (OVB) → relevante Variable fehlt im Modell, die mit einer UV **und** der AV korreliert
 - Beispiel: Einkommen ~ Bildung
 - Fehlt: soziale Herkunft (beeinflusst Bildung *und* Einkommen)
 - Herkunftseffekt landet im Fehlerterm → korreliert mit Bildung
 - Bildungskoeffizient „schluckt“ den Herkunftseffekt → **verzerrt**
- Die Schätzung selbst wird falsch — nicht nur die Standardfehler!
- Kein statistischer Test möglich (ε ist unbeobachtbar)
- Theoriegeleitete Lösung: *Welche Variablen beeinflussen AV und UV gemeinsam?* → als Kontrollvariablen aufnehmen.
- Vollständige Lösung nur über Forschungsdesign (Experimente → fortgeschrittene Methoden)

3 Unabhängige Beobachtungen

- **Was heißt das?** Die Beobachtungen beeinflussen sich nicht gegenseitig
- Bsp. für Cluster: Regionen, Klassen, Länder, Haushalte, Personen über die Zeit (Paneldaten)
- **Warum problematisch?** Das Modell tut so, als hätte es unabhängige Datenpunkte → ist sich zu sicher → Standardfehler zu klein → Effekte erscheinen signifikant, obwohl sie es nicht sind (Scheinsignifikanz)
- Prüfung nicht statistisch, sondern über das **Studiendesign**
- Lösungen: Abhängigkeiten explizit modellieren statt sie zu ignorieren!

3 Unabhängige Beobachtungen

Abhängigkeitsstruktur	Beispiel	Lösung
Cluster (Fälle in Gruppen)	Schüler:innen in Klassen, Befragte in Ländern	Mehrebenenmodell oder cluster-robuste Standardfehler
Messwiederholung	Panelbefragung (z.B. SOEP)	Fixed-/Random-Effects-Panelmodelle
Zeitliche Abfolge	monatliche Umfragewerte einer Partei	Zeitreihenmodelle, autokorrelations-robuste Standardfehler
Räumliche Nähe	benachbarte Wahlkreise ähneln sich	räumliche Regressionsmodelle

Alle Verfahren → fortgeschrittene Methoden; hier nur als Ausblick. Im ALLBUS (Zufallsstichprobe einzelner Personen) ist die Annahme erfüllt.

4 Linearität


- **Was heißt das?** Der Zusammenhang zwischen UV und AV lässt sich durch eine Gerade beschreiben — der Effekt ist überall gleich stark
- Eine Gerade durch einen gekrümmten Zusammenhang beschreibt die Daten falsch — Koeffizient und Vorhersagen sind verzerrt
- Beispiel: Alter und Lebenszufriedenheit verlaufen oft U-förmig — eine Gerade würde fälschlich „kein Effekt“ zeigen
- **Lösung:** Polynomiale Regression (z.B. Alter^2) oder Spline-Modelle

5 Homoskedastizität

- **Was heißt das?** Die Residuen streuen über alle vorhergesagten Werte hinweg gleich stark — das Modell ist überall gleich (un)genau
- Bei ungleicher Streuung (Heteroskedastizität) sind die **Standardfehler falsch** → p-Werte und KIs nicht verlässlich
- Die Koeffizienten selbst bleiben unverzerrt — nur die Signifikanzaussagen leiden
- Lösung: Heteroskedastizitätsrobuste Standardfehler (z.B. HC3)

6 Keine Multikollinearität

- Multikollinearität liegt vor, wenn zwei (oder mehr) UVs so stark korrelieren, dass sie im Grunde dasselbe messen
- Bsp.: Bildungsjahre und höchster Abschluss
- **Warum problematisch?** Interpretation einzelner Koeffizienten wird unzuverlässig und Standardfehler sehr groß! (Vorhersagekraft des Modells bleibt ok.)



7 Keine Ausreißer

- **Was heißt das?** Kein einzelner Fall dominiert die Schätzung
- **Warum problematisch?** Bei OLS werden Residuen **quadriert** — extreme Fälle bekommen dadurch überproportionales Gewicht und können die Gerade regelrecht „zu sich ziehen“
- **Wichtig:** Ausreißer prüfen heißt nicht automatisch ausschließen! Erst klären: Datenfehler oder echter Extremfall?

8 Normalverteilte Residuen

- **Was heißt das?** Die Abweichungen vom Modell sind zufällig und symmetrisch — viele kleine, wenige große Fehler
- **Warum problematisch?** p-Werte und KIs basieren auf der t-Verteilung — diese Herleitung setzt normalverteilte Residuen voraus
- Bei großem n entschärft sich das Problem (zentraler Grenzwertsatz), daher in der Praxis meistens irrelevant!

Voraussetzungen prüfen

Prüfung d. Voraussetzungen

Voraussetzung	Prüfung
Skalenniveau (metrische AV)*	theoretisch: Codebuch, Theorie
Exogenität	theoretisch: relevante Kontrollvariablen im Modell?
Unabhängige Beobachtungen	theoretisch: Studiendesign
Linearer Zusammenhang	grafisch: Scatterplot + Loess; Residuen vs. Fitted statistisch: Rainbow-Test
Homoskedastizität der Residuen	grafisch: Residuen vs. Fitted-Plot statistisch: Breusch-Pagan-Test
Keine Multikollinearität**	statistisch: Variance Inflation Factor (VIF)
Keine Ausreißer	grafisch: Cook's Distance statistisch: Anteil > Schwellwert
Normalverteilte Residuen	grafisch: Histogramm, Q-Q-Plot statistisch: Shapiro-Wilk***

* Die UVen können metrisch oder kategorial sein; kategoriale mit mehr als zwei Ausprägungen werden als Dummies kodiert.

** nur bei multiplen linearen Regressionen

*** nur bis n = 5000; bei großem n grafische Prüfung bevorzugen


Remedies bei Verletzung

Was tun bei Verletzung der Annahmen?

Verletzung	Lösung
Skalenniveau (AV nicht metrisch)	Anderes Modell wählen, z.B. logistische Regression bei binärer AV (→ Sitzung 11!)
Exogenität verletzt	Relevante Kontrollvariablen aufnehmen; vollständig nur über Forschungsdesign lösbar (fortgeschritten)
Abhängige Beobachtungen	Cluster-robuste Standardfehler; Mehrebenen- oder Panelmodelle (FE/RE)
Kein linearer Zusammenhang	U-Form → UV quadrieren ($I(x^2)$) · Sättigung → UV logarithmieren ($\log(x)$) · exponentielles Wachstum → AV logarithmieren ($\log(y)$) · Schwellenwert → UV kategorisieren · komplexe Formen → Splines (fortgeschritten)
Heteroskedastizität	Heteroskedastizitätsrobuste Standardfehler (HC3)*
Multikollinearität	Eine der korrelierten UVen ausschließen oder zu Index zusammenfassen
Ausreißer	Fälle prüfen; Modell mit & ohne Ausreißer vergleichen; ggf. ausschließen; oder robuste Regression (fortgeschritten)
Nicht normalverteilte Residuen	Bei großem n unkritisch (zentraler Grenzwertsatz); bei kleinem n: Bootstrapping (fortgeschritten)


* Long JS & Ervin LH (2000). Using heteroscedasticity consistent standard errors in the linear regression model. *The American Statistician*, 54(3), 217–224. Zum Vertiefen: Kapitel 21 bis 24 in Wagemann, Goerres & Siewert (2020). *Handbuch Methoden der Politikwissenschaft*. Springer.

Verletzung d. Linearität



- Rot = lineares Modell
- Liegt die Punktwolke systematisch daneben → Annahme verletzt
- Vier typische Muster + Lösungen auf den nächsten Folien

Muster 1: U-Form




Beispiel: Lebenszufriedenheit ~
Alter (Tief in der Lebensmitte)

Lösung: quadratischen Term
ergänzen

Rot = lineares Modell verfehlt die
Kurve

Grün = Modell mit $I(x^2)$ fängt
sie ein


Muster 2: Sättigung



Beispiel: Lebenszufriedenheit ~
Einkommen (jeder zusätzliche
Euro bringt weniger)

Lösung: UV logarithmieren
Nur bei positiven Werten
möglich!


Muster 3: Exponentielles Wachstum



Beispiel: AV wächst prozentual statt absolut (z.B. Kampagnenbudgets)

Lösung: AV logarithmieren
Koeffizienten dann
näherungsweise als %-Änderung
interpretierbar

Muster 4: Schwellenwert / Knick



Beispiel: Effekt setzt erst ab bestimmtem Wert ein (z.B. Sperrklausel)



Lösung: UV kategorisieren (Dummy)

Linearität: typische Muster & Lösungen

Muster	Beispiel	Lösung
U-Form / umgekehrte U-Form	Lebenszufriedenheit ~ Alter	Quadratischer Term: $I(x^2)$
Sättigung	Lebenszufriedenheit ~ Einkommen	UV logarithmieren: $\log(x)$
Exponentielles Wachstum	AV wächst prozentual statt absolut	AV logarithmieren: $\log(y)$
Schwellenwert / Knick	Effekt erst ab bestimmtem Wert (z.B. Sperrklausel)	UV kategorisieren
Komplexe Wellenform	mehrfache Richtungswechsel	Splines (→ fortgeschrittene Methoden)

Faustregel: ein Bogen → quadratischer Term · einseitiges Abflachen → `log()` (nur bei positiven Werten) · mehr als zwei Richtungswechsel → Splines

Annahme d. Homoskedastizität



Robuste Standardfehler (HC3)

- Problem Heteroskedastizität: Die Streuung der Residuen ist nicht überall gleich → die normalen Standardfehler sind **zu klein oder zu groß**
- Die **Koeffizienten bleiben identisch** — nur SEs, t- und p-Werte ändern sich
- Lösung: Standardfehler werden so korrigiert, dass sie der tatsächlichen, ungleichen Streuung gerecht werden


```
```{r}
lmtest::coeftest(model_2, vcov = sandwich::vcovHC(model_2, type = "HC3"))
```
```

Hands On - Diagnostics



Minute Cards

Bitte füllt die Minute Cards für die heutige Sitzung aus. Das sollt enicht länger als 3 Minuten dauern. Vielen Dank für eure Mitarbeit!



Vielen Dank und bis kommenden Dienstag!



Sitzung 10 von 13



**Übung 10 zu Regressionsdiagnostik bis spätestens
Sonntagabend!**