

# Quantitative Methoden mit R & R-Studio

Sommersemester 2026 | Sitzung 10

Maura Kratz


# Willkommen zurück!

|                                                                   |                                                    |                                         |                                  |                                                      |
|-------------------------------------------------------------------|----------------------------------------------------|-----------------------------------------|----------------------------------|------------------------------------------------------|
| I) Vorbereitung                                                   | 01: Einführung in R und R-Studio                   | 02: Projekte und Datenimport            | 03: Daten aufbereiten            | 04: Daten zusammenführen                             |
| II) Deskriptiv                                                    | 05: Kannwerte & deren Visualisierung               | 06: Häufigkeiten & deren Visualisierung | 07: The Grammar of Graphics      | 08: Zusammenhänge (Kreuztabellen, Korrelationen ...) |
| III) Inferenz                                                     | 09: Einfache und multiple lineare (OLS) Regression | 10: Regression Diagnostics              | 11: Logistische Regression (GLM) |                                                      |
| 12: Wahlthema (Faktoranalyse, Indexbildung, ...) / Research Notes |                                                    |                                         |                                  |                                                      |
| 13: Wahlthema (Faktoranalyse, Indexbildung, ...) / Research Notes |                                                    |                                         |                                  |                                                      |

miro


# Recap: Einfache lineare Regressionen

- Eine (einfache) lineare Regression zu rechnen heißt eine Gerade durch Punkte zu ziehen!
- UV  $\rightarrow$  AV
- Wenn x um eine Einheit steigt, ändert sich y um den Betrag b.




# Recap: Multiple lineare Regressionen

Einfache lineare Regression



Multiple lineare Regression



# Recap: Multiple lineare Regressionen

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots + b_kx_k$$

- Die  $b$ -Koeffizienten geben den **spezifischen / isolierten Einfluss** jedes Prädiktors an:
- Wenn  $x_k$  um eine Einheit steigt, ändert sich  $y$  um  $b_k$ , **wenn alle anderen Prädiktoren konstant bleiben** (*ceteris paribus*).



## Multiple ≠ Multivariate Regression

Multiple = mehrere **unabhängige** Variablen

Multivariate = mehrere **abhängige** Variablen

# Wichtigste Marker einer Regression

- Regressionskoeffizient  $b$
- Modellgüte: Bestimmtheitsmaß  $R^2$  = Anteil der aufgeklärten Varianz
- Signifikanz:
  - p-Wert: Wie wahrscheinlich ist es, einen solchen oder noch extremeren Koeffizienten zu beobachten, wenn  $H_0$  (= kein Zusammenhang) stimmte?
  - Beispielschwellwerte:  $p < 0.001$  = hochsignifikant \*\*\*,  $p < 0.01$  = signifikant \*\*,  $p < 0.05$  = schwach signifikant \*,  $p > 0.05$  = nicht signifikant
  - KI: 95% KI enthält 0  $\Rightarrow$  nicht signifikant; 95% KI enthält keinen Wert über 0  $\Rightarrow$  signifikant
  - In 95 von 100 Stichproben würde das berechnete Konfidenzintervall den wahren Regressionskoeffizienten in der Grundgesamtheit enthalten.
  - Wenn man den Zorn der Statistiker\*innen auf sich ziehen will: Der wahre Regressionskoeffizient liegt mit 95%iger Wahrscheinlichkeit im KI.

# Voraussetzungen und deren Bedeutung

# Überblick: Voraussetzungen der linearen Regression

| Nr  | Voraussetzung                            | Worauf bezogen?     | Folgen bei Verletzung                               |
|-----|------------------------------------------|---------------------|-----------------------------------------------------|
| 1   | Skalenniveau (metrische AV)              | Daten / Messung     | Modell ist inhaltlich nicht interpretierbar         |
| 2   | Exogenität                               | Modellspezifikation | Koeffizienten verzerrt (z.B. Omitted Variable Bias) |
| 3   | Unabhängige Beobachtungen                | Studiendesign       | Scheinsignifikanz                                   |
| 4   | Linearität                               | Funktionale Form    | Koeffizienten falsch                                |
| 5   | Homoskedastizität                        | Residuen            | Scheinsignifikanz                                   |
| 6   | Keine Multikollinearität*                | UVs untereinander   | Koeffizienten instabil, große Standardfehler        |
| 7   | Keine Ausreißer                          | Einzelne Fälle      | Schätzung instabil                                  |
| (8) | Normalverteilung der Residuen (optional) | Residuen            | Nur bei kleinem n: Inferenz ungenau                 |

\* nur bei multiplen linearen Regressionen (mind. zwei UVs). Voraussetzungen 1–3 sind der Analyse *vorgelagert* (Daten & Design), 4–8 werden *am geschätzten Modell* geprüft.



# 1 Skalenniveau: Welches Modell für welche Skala?

| Skalenniveau der AV             | Beispiel                                           | Modell                                   |
|---------------------------------|----------------------------------------------------|------------------------------------------|
| Metrisch                        | Lebenszufriedenheit (0–10), Einkommen              | Lineare Regression (OLS) — diese Sitzung |
| Dichotom (binär)                | Wahlbeteiligung (ja/nein)                          | Logistische Regression — Sitzung 11!     |
| Nominal (mehr als 2 Kategorien) | Parteiwahl (CDU, SPD, Grüne, ...)                  | Multinomiale logistische Regression      |
| Ordinal                         | Zustimmung (stimme gar nicht zu; egal; ...voll zu) | Ordinale logistische Regression          |
| Zählvariable                    | Anzahl Demonstrationsteilnahmen                    | Poisson- / Negativ-Binomial-Regression   |

Merke: Das Skalenniveau der **AV** bestimmt das Modell. Die UVs dürfen jedes Skalenniveau haben (kategoriale UVs als Dummies). Quasi-metrische AVs (z.B. 5er-Skalen) werden in der Praxis oft mit OLS gerechnet — umstritten, aber verbreitet.

## 2 Exogenität

- Die UVs dürfen nicht mit dem Fehlerterm korrelieren → alles, was die AV beeinflusst und *nicht* im Modell steht, darf nicht systematisch mit den UVs zusammenhängen.
- Häufigste Verletzung: Omitted Variable Bias (OVB) → relevante Variable fehlt im Modell, die mit einer UV **und** der AV korreliert
  - Beispiel: Einkommen ~ Bildung
  - Fehlt: soziale Herkunft (beeinflusst Bildung *und* Einkommen)
  - Herkunftseffekt landet im Fehlerterm → korreliert mit Bildung
  - Bildungskoeffizient „schluckt“ den Herkunftseffekt → **verzerrt**
- Die Schätzung selbst wird falsch — nicht nur die Standardfehler!
- Kein statistischer Test möglich ( $\varepsilon$  ist unbeobachtbar)
- Theoriegeleitete Lösung: *Welche Variablen beeinflussen AV und UV gemeinsam?* → als Kontrollvariablen aufnehmen.
- Vollständige Lösung nur über Forschungsdesign (Experimente → fortgeschrittene Methoden)

# 3 Unabhängige Beobachtungen

- **Was heißt das?** Die Beobachtungen beeinflussen sich nicht gegenseitig
- Bsp. für Cluster: Regionen, Klassen, Länder, Haushalte, Personen über die Zeit (Paneldaten)
- **Warum problematisch?** Das Modell tut so, als hätte es unabhängige Datenpunkte → ist sich zu sicher → Standardfehler zu klein → Effekte erscheinen signifikant, obwohl sie es nicht sind (Scheinsignifikanz)
- Prüfung nicht statistisch, sondern über das **Studiendesign**
- Lösungen: Abhängigkeiten explizit modellieren statt sie zu ignorieren!

# 3 Unabhängige Beobachtungen

| Abhängigkeitsstruktur      | Beispiel                                      | Lösung                                                     |
|----------------------------|-----------------------------------------------|------------------------------------------------------------|
| Cluster (Fälle in Gruppen) | Schüler:innen in Klassen, Befragte in Ländern | Mehrebenenmodell oder cluster-robuste Standardfehler       |
| Messwiederholung           | Panelbefragung (z.B. SOEP)                    | Fixed-/Random-Effects-Panelmodelle                         |
| Zeitliche Abfolge          | monatliche Umfragewerte einer Partei          | Zeitreihenmodelle, autokorrelations-robuste Standardfehler |
| Räumliche Nähe             | benachbarte Wahlkreise ähneln sich            | räumliche Regressionsmodelle                               |

Alle Verfahren → fortgeschrittene Methoden; hier nur als Ausblick. Im ALLBUS (Zufallsstichprobe einzelner Personen) ist die Annahme erfüllt.

# 4 Linearität


- **Was heißt das?** Der Zusammenhang zwischen UV und AV lässt sich durch eine Gerade beschreiben — der Effekt ist überall gleich stark
- Eine Gerade durch einen gekrümmten Zusammenhang beschreibt die Daten falsch — Koeffizient und Vorhersagen sind verzerrt
- Beispiel: Alter und Lebenszufriedenheit verlaufen oft U-förmig — eine Gerade würde fälschlich „kein Effekt“ zeigen
- **Lösung:** Polynomiale Regression (z.B.  $\text{Alter}^2$ ) oder Spline-Modelle

# 5 Homoskedastizität

- **Was heißt das?** Die Residuen streuen über alle vorhergesagten Werte hinweg gleich stark — das Modell ist überall gleich (un)genau
- Bei ungleicher Streuung (Heteroskedastizität) sind die **Standardfehler falsch** → p-Werte und KIs nicht verlässlich
- Die Koeffizienten selbst bleiben unverzerrt — nur die Signifikanzaussagen leiden
- Lösung: Heteroskedastizitätsrobuste Standardfehler (z.B. HC3)

# 6 Keine Multikollinearität

- Multikollinearität liegt vor, wenn zwei (oder mehr) UVs so stark korrelieren, dass sie im Grunde dasselbe messen
- Bsp.: Bildungsjahre und höchster Abschluss
- **Warum problematisch?** Interpretation einzelner Koeffizienten wird unzuverlässig und Standardfehler sehr groß! (Vorhersagekraft des Modells bleibt ok.)



# 7 Keine Ausreißer

- Was heißt das? Kein einzelner Fall dominiert die Schätzung
- Warum problematisch? Bei OLS werden Residuen **quadriert** — extreme Fälle bekommen dadurch überproportionales Gewicht und können die Gerade regelrecht „zu sich ziehen“
- Wichtig: Ausreißer prüfen heißt nicht automatisch ausschließen! Erst klären: Datenfehler oder echter Extremfall?



# 8 Normalverteilte Residuen

- **Was heißt das?** Die Abweichungen vom Modell sind zufällig und symmetrisch — viele kleine, wenige große Fehler
- **Warum problematisch?** p-Werte und KIs basieren auf der t-Verteilung — diese Herleitung setzt normalverteilte Residuen voraus
- Bei großem  $n$  entschärft sich das Problem (zentraler Grenzwertsatz), daher in der Praxis meistens irrelevant!

# Voraussetzungen prüfen

# Prüfung d. Voraussetzungen

| Voraussetzung                  | Prüfung                                                                                       |
|--------------------------------|-----------------------------------------------------------------------------------------------|
| Skalenniveau (metrische AV)*   | <b>theoretisch:</b> Codebuch, Theorie                                                         |
| Exogenität                     | <b>theoretisch:</b> relevante Kontrollvariablen im Modell?                                    |
| Unabhängige Beobachtungen      | <b>theoretisch:</b> Studiendesign                                                             |
| Linearer Zusammenhang          | <b>grafisch:</b> Scatterplot + Loess; Residuen vs. Fitted<br><b>statistisch:</b> Rainbow-Test |
| Homoskedastizität der Residuen | <b>grafisch:</b> Residuen vs. Fitted-Plot<br><b>statistisch:</b> Breusch-Pagan-Test           |
| Keine Multikollinearität**     | <b>statistisch:</b> Variance Inflation Factor (VIF)                                           |
| Keine Ausreißer                | <b>grafisch:</b> Cook's Distance<br><b>statistisch:</b> Anteil > Schwellwert                  |
| Normalverteilte Residuen       | <b>grafisch:</b> Histogramm, Q-Q-Plot<br><b>statistisch:</b> Shapiro-Wilk***                  |

\* Die UVen können metrisch oder kategorial sein; kategoriale mit mehr als zwei Ausprägungen werden als Dummies kodiert.

\*\* nur bei multiplen linearen Regressionen

\*\*\* nur bis n = 5000; bei großem n grafische Prüfung bevorzugen


# Remedies bei Verletzung

# Was tun bei Verletzung der Annahmen?

| Verletzung                       | Lösung                                                                                                                                                                                                                          |
|----------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Skalenniveau (AV nicht metrisch) | Anderes Modell wählen, z.B. logistische Regression bei binärer AV (→ Sitzung 11!)                                                                                                                                               |
| Exogenität verletzt              | Relevante Kontrollvariablen aufnehmen; vollständig nur über Forschungsdesign lösbar (fortgeschritten)                                                                                                                           |
| Abhängige Beobachtungen          | Cluster-robuste Standardfehler; Mehrebenen- oder Panelmodelle (FE/RE)                                                                                                                                                           |
| Kein linearer Zusammenhang       | U-Form → UV quadrieren ( $I(x^2)$ ) · Sättigung → UV logarithmieren ( $\log(x)$ ) · exponentielles Wachstum → AV logarithmieren ( $\log(y)$ ) · Schwellenwert → UV kategorisieren · komplexe Formen → Splines (fortgeschritten) |
| Heteroskedastizität              | Heteroskedastizitätsrobuste Standardfehler (HC3)*                                                                                                                                                                               |
| Multikollinearität               | Eine der korrelierten UVen ausschließen oder zu Index zusammenfassen                                                                                                                                                            |
| Ausreißer                        | Fälle prüfen; Modell mit & ohne Ausreißer vergleichen; ggf. ausschließen; oder robuste Regression (fortgeschritten)                                                                                                             |
| Nicht normalverteilte Residuen   | Bei großem n unkritisch (zentraler Grenzwertsatz); bei kleinem n: Bootstrapping (fortgeschritten)                                                                                                                               |


\* Long JS & Ervin LH (2000). Using heteroscedasticity consistent standard errors in the linear regression model. *The American Statistician*, 54(3), 217–224. Zum Vertiefen: Kapitel 21 bis 24 in Wagemann, Goerres & Siewert (2020). *Handbuch Methoden der Politikwissenschaft*. Springer.

# Verletzung d. Linearität



- Rot = lineares Modell
- Liegt die Punktwolke systematisch daneben → Annahme verletzt
- Vier typische Muster + Lösungen auf den nächsten Folien

# Muster 1: U-Form




**Beispiel:** Lebenszufriedenheit ~  
Alter (Tief in der Lebensmitte)

**Lösung:** quadratischen Term  
ergänzen

**Rot** = lineares Modell verfehlt die  
Kurve

**Grün** = Modell mit  $I(x^2)$  fängt  
sie ein

# Muster 2: Sättigung




**Beispiel:** Lebenszufriedenheit ~  
Einkommen (jeder zusätzliche  
Euro bringt weniger)

**Lösung:** UV logarithmieren  
Nur bei positiven Werten  
möglich!




# Muster 3: Exponentielles Wachstum



**Beispiel:** AV wächst prozentual statt absolut (z.B. Kampagnenbudgets)

**Lösung:** AV logarithmieren  
Koeffizienten dann  
näherungsweise als %-Änderung  
interpretierbar

# Muster 4: Schwellenwert / Knick



**Beispiel:** Effekt setzt erst ab bestimmtem Wert ein (z.B. Sperrklausel)



**Lösung:** UV kategorisieren (Dummy)

# Linearität: typische Muster & Lösungen

| Muster                     | Beispiel                                           | Lösung                                |
|----------------------------|----------------------------------------------------|---------------------------------------|
| U-Form / umgekehrte U-Form | Lebenszufriedenheit ~ Alter                        | Quadratischer Term: $I(x^2)$          |
| Sättigung                  | Lebenszufriedenheit ~ Einkommen                    | UV logarithmieren: $\log(x)$          |
| Exponentielles Wachstum    | AV wächst prozentual statt absolut                 | AV logarithmieren: $\log(y)$          |
| Schwellenwert / Knick      | Effekt erst ab bestimmtem Wert (z.B. Sperrklausel) | UV kategorisieren                     |
| Komplexe Wellenform        | mehrfache Richtungswechsel                         | Splines (→ fortgeschrittene Methoden) |

Faustregel: ein Bogen → quadratischer Term · einseitiges Abflachen → `log()` (nur bei positiven Werten) · mehr als zwei Richtungswechsel → Splines

# Annahme d. Homoskedastizität



# Robuste Standardfehler (HC3)

- Problem Heteroskedastizität: Die Streuung der Residuen ist nicht überall gleich → die normalen Standardfehler sind **zu klein oder zu groß**
- Die **Koeffizienten bleiben identisch** — nur SEs, t- und p-Werte ändern sich
- Lösung: Standardfehler werden so korrigiert, dass sie der tatsächlichen, ungleichen Streuung gerecht werden


```
```{r}
lmtest::coeftest(model_2, vcov = sandwich::vcovHC(model_2, type = "HC3"))
```
```

# Hands On - Diagnostics



# Minute Cards

Bitte füllt die Minute Cards für die heutige Sitzung aus. Das sollt enicht länger als 3 Minuten dauern. Vielen Dank für eure Mitarbeit!



# Vielen Dank und bis kommenden Dienstag!



Sitzung 10 von 13



**Übung 10 zu Regressionsdiagnostik bis spätestens  
Sonntagabend!**