

Quantitative Methoden mit R & R-Studio

Sommersemester 2026 | Sitzung 11

Maura Kratz

Willkommen zurück!

I) Vorbereitung	01: Einführung in R und R-Studio	02: Projekte und Datenimport	03: Daten aufbereiten	04: Daten zusammenführen
II) Deskriptiv	05: Kannwerte & deren Visualisierung	06: Häufigkeiten & deren Visualisierung	07: The Grammar of Graphics	08: Zusammenhänge (Kreuztabellen, Korrelationen ...)
III) Inferenz	09: Einfache und multiple lineare (OLS) Regression	10: Regression Diagnostics	11: Logistische Regression (GLM)	
12: Data Analysis Reports				
13: Recap, offene Fragen & Feedback				

miro

Ergänzung multiple OLS-Regression (Ü8)

- Was bedeutet Split (-11) im Allbus-Datensatz?
- ordinale UV in multipler linearer Regression
 - ordinale Variablen (z.B. Schulabschluss) können entweder als quasi-metrisch oder als kategorial, also factor, behandelt werden
 - bei kategorialen Variablen werden allerdings automatisch dummies für jede Kategorie gegenüber der Referenzkategorie gebildet → ggf. kleines n pro Kategorie → große SEs und CIs



Praxistipps

- dünn besetzte Kategorien zusammenfassen (z.B. „Fachhochschulreife“ + „Hochschulreife“ → „(Fach-)Hochschulreife“)
- Je mehr Stufen, desto unproblematischer die quasi-metrische Behandlung. Ab ~5–7 Stufen wird sie in den Sozialwissenschaften breit akzeptiert.

Recap: Voraussetzungen der linearen Regression

Nr	Voraussetzung	Worauf bezogen?	Folgen bei Verletzung
1	Skalenniveau (metrische AV)	Daten / Messung	Modell ist inhaltlich nicht interpretierbar
2	Exogenität	Modellspezifikation	Koeffizienten verzerrt (z.B. Omitted Variable Bias)
3	Unabhängige Beobachtungen	Studiendesign	Scheinsignifikanz
4	Linearität	Funktionale Form	Koeffizienten falsch
5	Homoskedastizität	Residuen	Scheinsignifikanz
6	Keine Multikollinearität*	UVs untereinander	Koeffizienten instabil, große Standardfehler
7	Keine Ausreißer	Einzelne Fälle	Schätzung instabil
(8)	Normalverteilung der Residuen (optional)	Residuen	Nur bei kleinem n: Inferenz ungenau

* nur bei multiplen linearen Regressionen (mind. zwei UVs). Voraussetzungen 1–3 sind der Analyse *vorgelagert* (Daten & Design), 4–8 werden *am geschätzten Modell* geprüft.

Recap: Prüfung d. Voraussetzungen

Voraussetzung	Prüfung
Skalenniveau (metrische AV)*	theoretisch: Codebuch, Theorie
Exogenität	theoretisch: relevante Kontrollvariablen im Modell?
Unabhängige Beobachtungen	theoretisch: Studiendesign
Linearer Zusammenhang	grafisch: Scatterplot + Loess; Residuen vs. Fitted statistisch: Rainbow-Test
Homoskedastizität der Residuen	grafisch: Residuen vs. Fitted-Plot statistisch: Breusch-Pagan-Test
Keine Multikollinearität**	statistisch: Variance Inflation Factor (VIF)
Keine Ausreißer	grafisch: Cook's Distance statistisch: Anteil > Schwellwert
Normalverteilte Residuen	grafisch: Histogramm, Q-Q-Plot statistisch: Shapiro-Wilk***

* Die UVen können metrisch oder kategorial sein; kategoriale mit mehr als zwei Ausprägungen werden als Dummies kodiert.

** nur bei multiplen linearen Regressionen

*** nur bis n = 5000; bei großem n grafische Prüfung bevorzugen

Recap: Was tun bei Verletzung der Annahmen?

Nr	Verletzung	Lösung
1	Skalenniveau (AV nicht metrisch)	Anderes Modell wählen, z.B. logistische Regression bei binärer AV (→ Sitzung 11!)
2	Exogenität verletzt	Relevante Kontrollvariablen aufnehmen; vollständig nur über Forschungsdesign lösbar (fortgeschritten)
3	Abhängige Beobachtungen	Cluster-robuste Standardfehler; Mehrebenen- oder Panelmodelle (FE/RE)
4	Kein linearer Zusammenhang	U-Form → UV quadrieren ($I(x^2)$) · Sättigung → UV logarithmieren ($\log(x)$) · exponentielles Wachstum → AV logarithmieren ($\log(y)$) · Schwellenwert → UV kategorisieren · komplexe Formen → Splines (fortgeschritten)
5	Heteroskedastizität	Heteroskedastizitätsrobuste Standardfehler (HC3)*
6	Multikollinearität	Eine der korrelierten UVen ausschließen oder zu Index zusammenfassen
7	Ausreißer	Fälle prüfen; Modell mit & ohne Ausreißer vergleichen; ggf. ausschließen; oder robuste Regression (fortgeschritten)
(8)	Nicht normalverteilte Residuen	Bei großem n unkritisch (zentraler Grenzwertsatz); bei kleinem n: Bootstrapping (fortgeschritten)

* Long JS & Ervin LH (2000). Using heteroscedasticity consistent standard errors in the linear regression model. *The American Statistician*, 54(3), 217–224. Zum Vertiefen: Kapitel 21 bis 24 in Wagemann, Goerres & Siewert (2020). *Handbuch Methoden der Politikwissenschaft*. Springer.


Orga

- ihr bekommt heute eure letzte Übung (10) auf. Wenn ihr unsicher seid, ob ihr noch Ersatzleistungen erbringen müsst, um die ART für diesen Kurs zu bekommen, schreibt mir 
- kommende Sitzung würde ich gern euren Data Analysis Plans widmen! Macht euch also Gedanken + gern ein paar Notizen. Schreibt mir, wenn ihr euren diskutieren wollt + gern schon mal Ideen/Themen/Forschungsfragen, sollte es schon welche geben 
- individuelle Deadlines für die Abgabe d. Prüfungsleistung müssen innerhalb der Vorlesungszeit mit mir abgestimmt werden! Auch hier gerne 
- Fragen zu Übung 09?

Logistische Regressionen

Das Problem der binären AV

- Viele politikwissenschaftliche AVs sind **binär**: gewählt/nicht gewählt, Mitglied/kein Mitglied, zugestimmt/abgelehnt ($AV \in \{0, 1\}$)
- Eine lineare Regression (OLS) ist hier ungeeignet:
 - sie sagt Werte **außerhalb von $[0, 1]$** vorher (unsinnige „Wahrscheinlichkeiten“)
 - der Zusammenhang ist **nicht linear**, sondern S-förmig
 - Residuen sind weder normalverteilt noch homoskedastisch



Die Lösung: ein GLM

- statt eines linearen Modells (LM) ein **GLM** (*generalized linear model*)
- der zentrale Unterschied steckt in der **Schätzmethode** – nicht mehr Ordinary least squares (OLS), sondern Maximum-Likelihood (ML):

	OLS (lineare Regression)	ML (logistische Regression)
Idee	Gerade so legen, dass die Summe der quadrierten Residuen minimal ist («kleinste Quadrate»)	Koeffizienten so wählen, dass die beobachteten 0/1-Daten am wahrscheinlichsten werden («größte Plausibilität»)
Rechenweg	exakte Formel → Ergebnis in einem Schritt	keine Formel → iterativ angenähert (mehrere Durchläufe)
AV	metrisch	binär (0/1)

 In R

```
glm(av ~ uv1 + uv2, data = ..., family = binomial(link = "logit"), weights = ...)
```

Was rechnet die logistische Regression?

- Wir wollen die **Wahrscheinlichkeit** p modellieren, dass $AV = 1$ (z.B. „gewählt“).
- Problem: p liegt zwischen 0 und 1 – eine Gerade läuft aber aus diesem Bereich heraus.
- Lösung: p in zwei Schritten umrechnen, bis eine Gerade passt.

Schritt 1: Wahrscheinlichkeit $p \rightarrow$ Odds (Chance):

$$\text{Odds} = \frac{p}{1 - p}$$

- Bedeutung: „Wie viel wahrscheinlicher ist Eintreten als Nicht-Eintreten?“ (Verhältnis von Eintreten zu Nicht-Eintreten)
- Beispiel: $p = 0,8 \Rightarrow \text{Odds} = \frac{0,8}{0,2} = 4$, also „4 zu 1“
- Wertebereich jetzt: 0 bis $+\infty$ (die obere Grenze ist weg)

Was rechnet die logistische Regression?

Schritt 2: Odds → Log-Odds (Logit/logarithmierte Odds)

$$\text{logit}(p) = \ln(\text{Odds})$$

- der Logarithmus lässt auch negative Werte zu
- Wertebereich jetzt: $-\infty$ bis $+\infty$ → eine Gerade passt!
- die Roh-Koeffizienten aus `glm()` sind also log-Odds → wenig anschaulich
- für die Interpretation rechnen wir sie in **Odds Ratios** (= Chancenverhältnis, e^β) um → nächste Slide

Drei Ebenen der Interpretation

Ebene	Wie berechnet?	Wie lesen?
log-Odds (Roh- β)	direkt aus <code>glm()</code>	nur Signifikanz und Richtung (Vorzeichen): + erhöht, – senkt die Chance auf AV = 1
Odds Ratio (OR)	<code>exp(β)</code>	Effektstärke: Faktor , um den sich die Odds ändern; Prozent = $(OR - 1) \cdot 100$
Vorhergesagte Wahrscheinlichkeit	UV-Werte in die logist. Funktion einsetzen	konkrete Wahrscheinlichkeit für bestimmte Fälle – am intuitivsten



Tip

Faustregel: **Signifikanz & Richtung** liest man aus den log-Odds, die **Effektstärke** kommuniziert man über Odds Ratios, **konkrete Aussagen** über vorhergesagte Wahrscheinlichkeiten.

Drei unterschiedlich gut lesbare Outputs



1. `glm()` schätzt in **log-Odds** (wenig anschaulich)
2. e^{β} liefert das **Odds Ratio**, indem es das Logarithmieren rückgängig macht
 - **OR = 0,6**: eine Erhöhung der UV um eine Einheit **verringert** die Odds um 40 % ($1 - 0,6 = 0,4$)
 - **OR = 1,2**: eine Erhöhung um eine Einheit **erhöht** die Odds um 20 % ($1,2 - 1 = 0,2$)
 - **OR = 3,8**: eine Erhöhung um eine Einheit **erhöht** die Odds um 280 % ($3,8 - 1 = 2,8$)
3. Einsetzen in die logist. Funktion liefert die vorhergesagte **Wahrscheinlichkeit** (am intuitivsten)
 - „Für eine 30-jährige Person liegt die vorhergesagte Wahrscheinlichkeit, wählen zu gehen, bei 72 %, für eine 60-jährige bei 85 % (übrige UVs konstant gehalten).“
 - Achtung: Derselbe OR bewirkt nicht überall denselben Sprung in p – nahe $p = 0,5$ ist der Effekt am größten, an den Rändern (nahe 0 oder 1) kleiner (→ S-Kurve).

Bsp.: Vom Koeffizienten zur Aussage

Beispiel: ein Prädiktor hat den Koeffizienten $\beta_1 = 0,41$.

- **1. log-Odds:** $\beta_1 = +0,41 > 0 \rightarrow$ die UV **erhöht** die Chance auf $AV = 1$. *(Nur Richtung ablesen – die Zahl selbst ist schwer greifbar.)*
- **2. Odds Ratio:** $e^{0,41} \approx 1,5 \rightarrow$ pro Einheit UV werden die Odds **mal 1,5**, also **+50 %**.
 - $OR > 1$ erhöht · $OR < 1$ senkt · $OR = 1$ kein Effekt
 - $\text{Prozent} = (OR - 1) \cdot 100$
- **3. Vorhergesagte Wahrscheinlichkeit:** UV-Werte in $p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$ einsetzen.
 - z.B. steigt p von 0,30 (bei $x = 0$) auf 0,39 (bei $x = 1$)
 - **Achtung:** der Effekt auf p ist nicht konstant – er hängt vom Ausgangsniveau ab (S-Kurve!)

Modellgüte: zwei Fehlerarten

Bei Schwelle 0,5 sagt das Modell „AV = 1“ voraus, wenn $p > 0,5$. Das kann auf zwei Arten schiefgehen:

Maß	Frage	Beispiel
Sensitivität	Von den tatsächlichen Ereignis-Fällen (AV = 1) – wie viele erkennt das Modell?	von echten AfD-Wähler:innen erkannt: nur ~10 %
Spezifität	Von den tatsächlichen Nicht-Ereignis-Fällen (AV = 0) – wie viele erkennt das Modell?	von echten Nicht-AfD-Wähler:innen erkannt: ~99 %

Der Trade-Off: Senkt man die Schwelle, steigt die Sensitivität – aber die Spezifität sinkt (und umgekehrt). Es gibt keine „richtige“ Schwelle, nur einen Kompromiss je nach Anwendungsfall: Wie teuer ist ein übersehener Fall vs. ein fälschlich markierter?



Tip

Bei seltenem Ereignis (kleine Basisrate) ist eine hohe Gesamttrefferquote oft trügerisch – das Modell trifft v.a. durch Erraten der Mehrheitsklasse.

Voraussetzungen im Vergleich

Lineare Regression	Logistische Regression
metrische AV	binäre AV (0/1)
Exogenität	Exogenität
Unabhängige Beobachtungen	Unabhängige Beobachtungen
—	Ausreichende Stichprobengröße*
Keine einflussr. Ausreißer	Keine einflussr. Ausreißer
Keine Multikollinearität*	Keine Multikollinearität**
Linearität	Linearität des Logits
Homoskedastizität	— (entfällt)
Normalvert. der Residuen	— (entfällt)

* OLS hat eine exakte Formel, ML schätzt iterativ und braucht eine große Stichprobe. Engpass ist die seltenere AV-Kategorie: Faustregel »10 events per variable« – pro Prädiktor mind. ~10 Fälle in der selteneren Kategorie. Beispiel: 4 Prädiktoren → mind. ~40 Fälle der selteneren Kategorie; bei seltenen Ereignissen entsprechend mehr.

** nur bei multiplen Regressionen (mind. zwei UVs).

Varianten des GLM

AV-Typ	Modell
binär (2 Kategorien)	Logit- oder Probit-Modell
ordinal (> 2, geordnet)	Ordered Logit / Ordered Probit
nominal (> 2, ungeordnet)	Multinomiales Logit / Probit
Zähldaten (0, 1, 2, ... Ereignisse)	Poisson / Negativ-Binomial

Alle sind GLMs mit unterschiedlicher Link-Funktion. Heute behandeln wir nur die **binär-logistische** Variante (Logit).

Weiterlesen


- Behnke, Joachim (2015). *Logistische Regressionsanalyse: Eine Einführung*. Wiesbaden: Springer Fachmedien. doi:10.1007/978-3-658-05082-5
- Schlittgen, Rainer (2013). *Regressionsanalysen mit R*. Lehr- und Handbücher der Statistik. De Gruyter, S. 213 ff. doi:10.1524/9783486739671

Hands On - Logistische Regressionen



Minute Cards

Bitte füllt die Minute Cards für die heutige Sitzung aus. Das sollt enicht länger als 3 Minuten dauern. Vielen Dank für eure Mitarbeit!



Vielen Dank und bis kommenden Dienstag!



Sitzung 11 von 13



**Übung 10 zu Logistischen Regressionen bis spätestens
Sonntagabend!**