

# Übung 02: Datenimport & Datensatzüberblick

Politik vermessen: Quantitative Methoden mit R | SoSe 2026

Vorname Nachname

20.04.2026

## Inhalt

|                                            |          |
|--------------------------------------------|----------|
| <b>Setup</b>                               | <b>1</b> |
| <b>Aufgabe 1: Daten importieren</b>        | <b>2</b> |
| <b>Aufgabe 2: Datensatz aufbereiten</b>    | <b>2</b> |
| <b>Aufgabe 3: Variablenlabels vergeben</b> | <b>2</b> |
| <b>Aufgabe 4: Datensatzüberblick</b>       | <b>3</b> |
| Data Frame Summary . . . . .               | 3        |

Denkt daran: um als PFD rendern zu können, müsst ihr einmalig in der Konsole `tinytex::install_tinytex()` ausführen, damit die nötige Software (LaTeX) für die PDF-Erstellung installiert wird. Alternativ `quarto install tinytex` im Terminal eingeben. Danach könnt ihr die Übung sowohl als HTML als auch als PDF rendern.

## Setup

```
library(tidyverse)
library(rio)
library(janitor)
library(labelled)
library(summarytools)
```

## Aufgabe 1: Daten importieren

Die Datei `kergr2.csv` enthält die amtlichen Wahlergebnisse der Bundestagswahl 2025. Wir importieren sie zunächst mit Standardeinstellungen — und stellen dabei fest, dass etwas nicht stimmt.

```
btw_2025_ergebnisse_raw <- rio::import("../data/kergr2.csv",
                                         sep = ";",
                                         dec = ",",
                                         skip = 9) |>
  janitor::clean_names()
```

## Aufgabe 2: Datensatz aufbereiten

Zunächst prüfen wir, ob in der Spalte `bemerkung` relevante Informationen stehen:

```
btw_2025_ergebnisse_raw |>
  dplyr::distinct(bemerkung)
```

```
  bemerkung
1        NA
```

Die Spalte enthält keine relevanten Einträge und kann entfernt werden:

```
btw_2025_ergebnisse <- btw_2025_ergebnisse_raw |>
  dplyr::select(-bemerkung)
```

## Aufgabe 3: Variablenlabels vergeben

Für eine bessere Lesbarkeit vergeben wir Variablenlabels. Labels beschreiben den Inhalt einer Variable und werden z.B. in Tabellen und Grafiken angezeigt.

```
labels_btw_2025_ergebnisse <- list(
  wahlart      = "Wahlart: Bundes-, Landes-, Kommunalwahl",
  wahltag      = "Datum des Wahltags",
  gebietsart   = "Gebietsart: Bundesland, Wahlkreis oder gesamtes Staatsgebiet",
  gebietsnummer = "Gebietsnummer",
  gebietsname  = "Gebietsname",
```

```

    ueg_gebietsart      = "Übergeordnete Gebietsart",
    ueg_gebietsnummer  = "Übergeordnete Gebietsnummer",
    gruppenart         = "Gruppenart: Partei, Einzelbewerber, System",
    gruppenname        = "Gruppenname, z.B. Parteiname",
    gruppenreihenfolge = "Reihenfolge der Gruppe",
    stimme             = "Stimmart: Erst- oder Zweitstimme",
    anzahl              = "Anzahl Stimmen",
    prozent             = "Stimmenanteil in Prozent",
    vorp_anzahl        = "Anzahl Stimmen bei vorhergehender Wahl",
    vorp_prozent        = "Stimmenanteil bei vorhergehender Wahl in Prozent",
    diff_prozent        = "Veränderung zur vorhergehenden Wahl in Prozent",
    diff_prozent_pkt    = "Veränderung zur vorhergehenden Wahl in Prozentpunkten",
    gewahlt             = "Gewählt: Parteiname"
  )

btw_2025_ergebnisse <- btw_2025_ergebnisse |>
  labelled::set_variable_labels(.labels = labels_btw_2025_ergebnisse,
                                .strict = FALSE)

```

## Aufgabe 4: Datensatzüberblick

Abschließend verschaffen wir uns einen Überblick über den aufbereiteten Datensatz. Denk daran, die graph column auszuschalten, da sie nichtkorrekt dargestellt wird.

```

summarytools::dfSummary(btw_2025_ergebnisse,
  plain.ascii = FALSE,
  style       = "grid",
  na.col      = FALSE,
  graph.col   = FALSE,
  method      = "render")

```

### Data Frame Summary

**btw\_2025\_ergebnisse**

**Dimensions:** 15617 x 18

**Duplicates:** 0

| No | Variable                      | Label                                                        | Stats / Values                                                                                                                                                                                                                                                | Freqs (% of Valid)                                                                                                               | Valid             |
|----|-------------------------------|--------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------|-------------------|
| 1  | wahlart<br>[character]        | Wahlart: Bundes-, Landes-, Kommunalwahl                      | 1. BT                                                                                                                                                                                                                                                         | 15617<br>(100.0%)                                                                                                                | 15617<br>(100.0%) |
| 2  | wahltag<br>[character]        | Datum des Wahltags                                           | 1. 23.02.2025                                                                                                                                                                                                                                                 | 15617<br>(100.0%)                                                                                                                | 15617<br>(100.0%) |
| 3  | gebietsart<br>[character]     | Gebietsart: Bundesland, Wahlkreis oder gesamtes Staatsgebiet | 1. Bund<br>2. Land<br>3. Wahlkreis                                                                                                                                                                                                                            | 67 ( 0.4%)<br>774 ( 5.0%)<br>14776<br>(94.6%)                                                                                    | 15617<br>(100.0%) |
| 4  | gebietsnummer<br>[integer]    | Gebietsnummer                                                | Mean (sd) : 143.5<br>(87.7)<br>min < med <<br>max:<br>1 < 140 < 299<br>IQR (CV) : 149<br>(0.6)                                                                                                                                                                | 299 distinct<br>values                                                                                                           | 15617<br>(100.0%) |
| 5  | gebietsname<br>[character]    | Gebietsname                                                  | 1. Bundesgebiet<br>2. Berlin-Friedrichshain-Kre<br>3.<br>Berlin-Tempelhof-Schönebe<br>4. Dortmund I<br>5. Duisburg II<br>6. Gütersloh I<br>7. Köln II<br>8. Märkischer Kreis II<br>9. Olpe – Märkischer Kreis I<br>10.<br>Recklinghausen II<br>[ 306 others ] | 67 ( 0.4%)<br>58 ( 0.4%)<br>58 ( 0.4%)<br>58 ( 0.4%)<br>58 ( 0.4%)<br>58 ( 0.4%)<br>58 ( 0.4%)<br>58 ( 0.4%)<br>15028<br>(96.2%) | 15617<br>(100.0%) |
| 6  | ueg_gebietsart<br>[character] | Übergeordnete Gebietsart                                     | 1. (Empty string)<br>2. BUND<br>3. LAND                                                                                                                                                                                                                       | 67 ( 0.4%)<br>774 ( 5.0%)<br>14776<br>(94.6%)                                                                                    | 15617<br>(100.0%) |

| No | Variable                             | Label                                         | Stats / Values                                                                                                                                                        | Freqs (% of Valid)                                                                                                                                  | Valid             |
|----|--------------------------------------|-----------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------|-------------------|
| 7  | ueg_gebiet-<br>snummer<br>[integer]  | Übergeordnete<br>Gebietsnummer                | Mean (sd) : 12<br>(20.2)<br>min < med <<br>max:<br>1 < 8 < 99<br>IQR (CV) : 4 (1.7)                                                                                   | 17 distinct<br>values                                                                                                                               | 15550<br>(99.6%)  |
| 8  | gruppenart<br>[character]            | Gruppenart: Partei,<br>Einzelbewerber, System | 1. Einzelbewer-<br>ber/Wählergrup<br>2. Partei<br>3. System-Gruppe                                                                                                    | 139 ( 0.9%)<br>12950<br>(82.9%)<br>2528 (16.2%)                                                                                                     | 15617<br>(100.0%) |
| 9  | gruppen-<br>name<br>[character]      | Gruppenname, z.B.<br>Parteiename              | 1. AfD<br>2. BSW<br>3. BÜNDNIS<br>DEUTSCHLAND<br>4. Die Linke<br>5. Die PARTEI<br>6. FDP<br>7. FREIE<br>WÄHLER<br>8. GRÜNE<br>9. Gültige<br>10. MLPD<br>[ 87 others ] | 632 ( 4.0%)<br>632 ( 4.0%)<br>632 ( 4.0%)<br>632 ( 4.0%)<br>632 ( 4.0%)<br>632 ( 4.0%)<br>632 ( 4.0%)<br>632 ( 4.0%)<br>632 ( 4.0%)<br>9297 (59.5%) | 15617<br>(100.0%) |
| 10 | gruppenrei-<br>henfolge<br>[integer] | Reihenfolge der Gruppe                        | Mean (sd) : 49.4<br>(195.4)<br>min < med <<br>max:<br>-4 < 10 < 1000<br>IQR (CV) : 12 (4)                                                                             | 35 distinct<br>values                                                                                                                               | 15617<br>(100.0%) |
| 11 | stimme<br>[integer]                  | Stimmart: Erst- oder<br>Zweitstimme           | Min : 1<br>Mean : 1.5<br>Max : 2                                                                                                                                      | 1 : 7500<br>(50.1%)<br>2 : 7485<br>(49.9%)                                                                                                          | 14985<br>(96.0%)  |

| No | Variable                  | Label                                                  | Stats / Values                                                                                                    | Freqs (% of Valid)       | Valid            |
|----|---------------------------|--------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|--------------------------|------------------|
| 12 | anzahl<br>[integer]       | Anzahl Stimmen                                         | Mean (sd) :<br>95245.1 (1163500)<br>min < med <<br>max:<br>8 < 7381 <<br>60510631<br>IQR (CV) :<br>35360.5 (12.2) | 7493 distinct<br>values  | 9747<br>(62.4%)  |
| 13 | prozent<br>[numeric]      | Stimmenanteil in<br>Prozent                            | Mean (sd) : 16.2<br>(27.8)<br>min < med <<br>max:<br>0 < 3.6 < 99.8<br>IQR (CV) : 17.3<br>(1.7)                   | 9418 distinct<br>values  | 9431<br>(60.4%)  |
| 14 | vorp_anzahl<br>[integer]  | Anzahl Stimmen bei<br>vorhergehender Wahl              | Mean (sd) :<br>76920.9 (1028519)<br>min < med <<br>max:<br>0 < 3312 <<br>61172771<br>IQR (CV) : 26356<br>(13.4)   | 7817 distinct<br>values  | 11459<br>(73.4%) |
| 15 | vorp_prozent<br>[numeric] | Stimmenanteil bei<br>vorhergehender Wahl in<br>Prozent | Mean (sd) : 13.5<br>(25.6)<br>min < med <<br>max:<br>0 < 1.6 < 99.7<br>IQR (CV) : 12.4<br>(1.9)                   | 11020 distinct<br>values | 11143<br>(71.4%) |
| 16 | diff_prozent<br>[numeric] | Veränderung zur<br>vorhergehenden Wahl in<br>Prozent   | Mean (sd) : 17<br>(93.3)<br>min < med <<br>max:<br>-99.4 < -1.6 <<br>3786.8<br>IQR (CV) : 59.7<br>(5.5)           | 8415 distinct<br>values  | 8523<br>(54.6%)  |

| No | Variable                    | Label                                                       | Stats / Values                                                                                | Freqs (% of Valid)                                                                                                        | Valid             |
|----|-----------------------------|-------------------------------------------------------------|-----------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------|-------------------|
| 17 | diff_prozent_p<br>[numeric] | Veränderung zur<br>vorhergehenden Wahl in<br>Prozentpunkten | Mean (sd) : 0 (4.3)<br>min < med <<br>max:<br>-23.1 < -0.2 < 26.4<br>IQR (CV) : 1.4<br>(-123) | 11027 distinct<br>values                                                                                                  | 11143<br>(71.4%)  |
| 18 | gewählt<br>[character]      | Gewählt: Parteiname                                         | 1. (Empty string)<br>2. –<br>3. AfD<br>4. CDU<br>5. CSU<br>6. Die Linke<br>7. GRÜNE<br>8. SPD | 841 ( 5.4%)<br>1098 ( 7.0%)<br>1944 (12.4%)<br>6398 (41.0%)<br>2224 (14.2%)<br>316 ( 2.0%)<br>612 ( 3.9%)<br>2184 (14.0%) | 15617<br>(100.0%) |

Der Datensatz enthält 15617 Zeilen und 18 Spalten. Jede Zeile entspricht einem Ergebnis einer Partei in einem Gebiet (Wahlkreis, Bundesland oder Bundesgebiet) für eine Stimmart (Erst- oder Zweitstimme).