

Übung 02: Datenimport & Datensatzüberblick

Politik vermessen: Quantitative Methoden mit R | SoSe 2026

Vorname Nachname

05.05.2026

Inhalt

Setup	1
Aufgabe 1: Daten importieren	2
Aufgabe 2: Datensatz aufbereiten	2
Aufgabe 3: Variablenlabels vergeben	2
Aufgabe 4: Datensatzüberblick	3
Data Frame Summary	3

Denkt daran: um als PFD rendern zu können, müsst ihr einmalig in der Konsole `tinytex::install_tinytex()` ausführen, damit die nötige Software (LaTeX) für die PDF-Erstellung installiert wird. Alternativ `quarto install tinytex` im Terminal eingeben. Danach könnt ihr die Übung sowohl als HTML als auch als PDF rendern.

Setup

```
library(rio)
library(dplyr)
library(tidyr)
library(janitor)
library(labelled)
library(summarytools)
```

Aufgabe 1: Daten importieren

Die Datei `kergr2.csv` enthält die amtlichen Wahlergebnisse der Bundestagswahl 2025. Wir importieren sie zunächst mit Standardeinstellungen — und stellen dabei fest, dass etwas nicht stimmt.

```
btw_2025_ergebnisse_raw <- rio::import("../data/kergr2.csv",  
                                         sep = ";",  
                                         dec = ",",  
                                         skip = 9) |>  
  janitor::clean_names()
```

Aufgabe 2: Datensatz aufbereiten

Zunächst prüfen wir, ob in der Spalte `bemerkung` relevante Informationen stehen:

```
btw_2025_ergebnisse_raw |>  
  dplyr::distinct(bemerkung)
```

```
  bemerkung  
1      NA
```

Die Spalte enthält keine relevanten Einträge und kann entfernt werden:

```
btw_2025_ergebnisse <- btw_2025_ergebnisse_raw |>  
  dplyr::select(-bemerkung)
```

Aufgabe 3: Variablenlabels vergeben

Für eine bessere Lesbarkeit vergeben wir Variablenlabels. Labels beschreiben den Inhalt einer Variable und werden z.B. in Tabellen und Grafiken angezeigt.

```
labels_btw_2025_ergebnisse <- list(  
  wahlart      = "Wahlart: Bundes-, Landes-, Kommunalwahl",  
  wahltag      = "Datum des Wahltags",  
  gebietsart   = "Gebietsart: Bundesland, Wahlkreis oder gesamtes Staatsgebiet",  
  gebietsnummer = "Gebietsnummer",  
  gebietsname  = "Gebietsname",
```

```

    ueg_gebietsart      = "Übergeordnete Gebietsart",
    ueg_gebietsnummer   = "Übergeordnete Gebietsnummer",
    gruppenart          = "Gruppenart: Partei, Einzelbewerber, System",
    gruppenname         = "Gruppenname, z.B. Parteiname",
    gruppenreihenfolge  = "Reihenfolge der Gruppe",
    stimme              = "Stimmart: Erst- oder Zweitstimme",
    anzahl              = "Anzahl Stimmen",
    prozent             = "Stimmenanteil in Prozent",
    vorp_anzahl         = "Anzahl Stimmen bei vorhergehender Wahl",
    vorp_prozent        = "Stimmenanteil bei vorhergehender Wahl in Prozent",
    diff_prozent        = "Veränderung zur vorhergehenden Wahl in Prozent",
    diff_prozent_pkt    = "Veränderung zur vorhergehenden Wahl in Prozentpunkten",
    gewählt             = "Gewählt: Parteiname"
  )

btw_2025_ergebnisse <- btw_2025_ergebnisse |>
  labelled::set_variable_labels(.labels = labels_btw_2025_ergebnisse,
                                .strict = FALSE)

```

Aufgabe 4: Datensatzüberblick

Abschließend verschaffen wir uns einen Überblick über den aufbereiteten Datensatz. Denk daran, die graph column auszuschalten, da sie nichtkorrekt dargestellt wird.

```

summarytools::dfSummary(btw_2025_ergebnisse,
  plain.ascii = FALSE,
  style       = "grid",
  na.col      = FALSE,
  graph.col   = FALSE,
  method      = "render")

```

Data Frame Summary

btw_2025_ergebnisse

Dimensions: 15617 x 18

Duplicates: 0

No	Variable	Label	Stats / Values	Freqs (% of Valid)	Valid
1	wahlart [character]	Wahlart: Bundes-, Landes-, Kommunalwahl	1. BT	15617 (100.0%)	15617 (100.0%)
2	wahltag [character]	Datum des Wahltags	1. 23.02.2025	15617 (100.0%)	15617 (100.0%)
3	gebietsart [character]	Gebietsart: Bundesland, Wahlkreis oder gesamtes Staatsgebiet	1. Bund 2. Land 3. Wahlkreis	67 (0.4%) 774 (5.0%) 14776 (94.6%)	15617 (100.0%)
4	gebietsnummer [integer]	Gebietsnummer	Mean (sd) : 143.5 (87.7) min < med < max: 1 < 140 < 299 IQR (CV) : 149 (0.6)	299 distinct values	15617 (100.0%)
5	gebietsname [character]	Gebietsname	1. Bundesgebiet 2. Berlin-Friedrichshain-Kre 3. Berlin-Tempelhof-Schönebe 4. Dortmund I 5. Duisburg II 6. Gütersloh I 7. Köln II 8. Märkischer Kreis II 9. Olpe – Märkischer Kreis I 10. Recklinghausen II [306 others]	67 (0.4%) 58 (0.4%) 58 (0.4%) 58 (0.4%) 58 (0.4%) 58 (0.4%) 58 (0.4%) 58 (0.4%) 15028 (96.2%)	15617 (100.0%)
6	ueg_gebietsart [character]	Übergeordnete Gebietsart	1. (Empty string) 2. BUND 3. LAND	67 (0.4%) 774 (5.0%) 14776 (94.6%)	15617 (100.0%)

No	Variable	Label	Stats / Values	Freqs (% of Valid)	Valid
7	ueg_gebiet- snummer [integer]	Übergeordnete Gebietsnummer	Mean (sd) : 12 (20.2) min < med < max: 1 < 8 < 99 IQR (CV) : 4 (1.7)	17 distinct values	15550 (99.6%)
8	gruppenart [character]	Gruppenart: Partei, Einzelbewerber, System	1. Einzelbewer- ber/Wählergrup 2. Partei 3. System-Gruppe	139 (0.9%) 12950 (82.9%) 2528 (16.2%)	15617 (100.0%)
9	gruppen- name [character]	Gruppenname, z.B. Parteiename	1. AfD 2. BSW 3. BÜNDNIS DEUTSCHLAND 4. Die Linke 5. Die PARTEI 6. FDP 7. FREIE WÄHLER 8. GRÜNE 9. Gültige 10. MLPD [87 others]	632 (4.0%) 632 (4.0%) 632 (4.0%) 632 (4.0%) 632 (4.0%) 632 (4.0%) 632 (4.0%) 632 (4.0%) 632 (4.0%) 9297 (59.5%)	15617 (100.0%)
10	gruppenrei- henfolge [integer]	Reihenfolge der Gruppe	Mean (sd) : 49.4 (195.4) min < med < max: -4 < 10 < 1000 IQR (CV) : 12 (4)	35 distinct values	15617 (100.0%)
11	stimme [integer]	Stimmart: Erst- oder Zweitstimme	Min : 1 Mean : 1.5 Max : 2	1 : 7500 (50.1%) 2 : 7485 (49.9%)	14985 (96.0%)

No	Variable	Label	Stats / Values	Freqs (% of Valid)	Valid
12	anzahl [integer]	Anzahl Stimmen	Mean (sd) : 95245.1 (1163500) min < med < max: 8 < 7381 < 60510631 IQR (CV) : 35360.5 (12.2)	7493 distinct values	9747 (62.4%)
13	prozent [numeric]	Stimmenanteil in Prozent	Mean (sd) : 16.2 (27.8) min < med < max: 0 < 3.6 < 99.8 IQR (CV) : 17.3 (1.7)	9418 distinct values	9431 (60.4%)
14	vorp_anzahl [integer]	Anzahl Stimmen bei vorhergehender Wahl	Mean (sd) : 76920.9 (1028519) min < med < max: 0 < 3312 < 61172771 IQR (CV) : 26356 (13.4)	7817 distinct values	11459 (73.4%)
15	vorp_prozent [numeric]	Stimmenanteil bei vorhergehender Wahl in Prozent	Mean (sd) : 13.5 (25.6) min < med < max: 0 < 1.6 < 99.7 IQR (CV) : 12.4 (1.9)	11020 distinct values	11143 (71.4%)
16	diff_prozent [numeric]	Veränderung zur vorhergehenden Wahl in Prozent	Mean (sd) : 17 (93.3) min < med < max: -99.4 < -1.6 < 3786.8 IQR (CV) : 59.7 (5.5)	8415 distinct values	8523 (54.6%)

No	Variable	Label	Stats / Values	Freqs (% of Valid)	Valid
17	diff_prozent_p [numeric]	Veränderung zur vorhergehenden Wahl in Prozentpunkten	Mean (sd) : 0 (4.3) min < med < max: -23.1 < -0.2 < 26.4 IQR (CV) : 1.4 (-123)	11027 distinct values	11143 (71.4%)
18	gewählt [character]	Gewählt: Parteiname	1. (Empty string) 2. – 3. AfD 4. CDU 5. CSU 6. Die Linke 7. GRÜNE 8. SPD	841 (5.4%) 1098 (7.0%) 1944 (12.4%) 6398 (41.0%) 2224 (14.2%) 316 (2.0%) 612 (3.9%) 2184 (14.0%)	15617 (100.0%)

Der Datensatz enthält 15617 Zeilen und 18 Spalten. Jede Zeile entspricht einem Ergebnis einer Partei in einem Gebiet (Wahlkreis, Bundesland oder Bundesgebiet) für eine Stimmart (Erst- oder Zweitstimme).