

Übung 04: Kennwerte und deren Visualisierung

— Lösung

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

19.05.2026

Setup

```
library(dplyr)
library(skimr)
library(here)
```

Aufgabe 1: Daten laden und vorbereiten

Lade den Datensatz `btw_2025_ergebnisse.RData` mit `here::here()`. Filtere anschließend die Wahlkreise und die Wahlbeteiligung heraus (Gruppe: Wählende). Speichere das Ergebnis in einem neuen Objekt namens `wb`. Wie viele Zeilen hat der gefilterte Datensatz?

```
load(here::here("output/btw_2025_ergebnisse.RData"))

wb <- btw_2025_ergebnisse %>%
  dplyr::filter(
    gebietsart == "Wahlkreis",
    gruppenname == "Wählende"
  )

nrow(wb)
```

```
[1] 299
```

```
# stattdessen kannst du auch den Datensatz öffnen und die Zeilen zählen.
```

Der gefilterte Datensatz enthält 299 Zeilen — eine pro Wahlkreis.

Aufgabe 2: Kennwerte berechnen

Berechne mit `dplyr::summarise()` folgende Kennwerte für die Wahlbeteiligung (Variable `prozent`): `n`, Minimum, Maximum, Spannweite, Mittelwert, Standardabweichung, Median, Mittlere Abweichung vom Median, Q25, Q75 und IQR. Nutze `'dplyr::as_tibble'` für eine übersichtliche Ausgabe.

```
wb %>%
  dplyr::summarise(
    n = dplyr::n(),
    min = min(prozent, na.rm = TRUE),
    max = max(prozent, na.rm = TRUE),
    range = max(prozent, na.rm = TRUE) - min(prozent, na.rm = TRUE),
    mittelwert = mean(prozent, na.rm = TRUE),
    sd = sd(prozent, na.rm = TRUE),
    median = median(prozent, na.rm = TRUE),
    mad = mad(prozent, na.rm = TRUE),
    q25 = quantile(prozent, probs = 0.25, na.rm = TRUE),
    q75 = quantile(prozent, probs = 0.75, na.rm = TRUE),
    iqr = IQR(prozent, na.rm = TRUE)
  ) %>%
  dplyr::as_tibble()
```

```
# A tibble: 1 x 11
      n    min    max range mittelwert    sd median    mad   q25   q75   iqr
<int> <dbl> <dbl> <dbl>      <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1   299  73.4  88.0  14.6      82.4  2.62  82.9  2.25  81.1  84.3  3.16
```


Was sagen dir die Kennwerte? Interpretiere Mittelwert vs. Median und die Streuung.

Die durchschnittliche Wahlbeteiligung liegt bei etwa 82%. Die Spannweite von ca. 15 Prozentpunkten zeigt, dass es erhebliche Unterschiede zwischen den Wahlkreisen gibt. Der Median ist ähnlich hoch wie der Mittelwert, was auf eine annähernd symmetrische Verteilung hindeutet. Da der Mittelwert allerdings leicht unter dem Median liegt, beeinflussen ihn anscheinend einige Ausreißer nach unten - anders, als es beim Median der Fall ist. Die Standardabweichung von ca. 2,5 bedeutet, dass Wahlkreise im Durchschnitt 2,5 Prozentpunkte vom Mittelwert abweichen. Die meisten Wahlkreise liegen also relativ nah am Mittelwert und der Mittelwert wird tatsächlich von Ausreißern nach unten gezogen.

Aufgabe 3: Visualisierung

Erstelle einen Boxplot der Wahlbeteiligung.

```
boxplot(wb$prozent)
```



Merke: dieser BaseR-Boxplot zeigt nur den Median, nicht den Mittelwert. Er gibt also nur sehr indirekt Hinweise auf die oben beschriebene Linksschiefe - die Tatsache, dass einige, wenige, sehr niedrige Extremwerte den Mittelwert nach unten ziehen, nicht aber den Median. Am ehesten ist diese hier an den eingezeichneten Ausreißern zu erkennen.

Aufgabe 4: Extremfälle

In welchen drei Wahlkreisen war die Wahlbeteiligung am niedrigsten, in welchen am höchsten?

```
wb %>%  
  dplyr::select(gebietsnummer, gebietsname, prozent) %>%  
  dplyr::arrange(prozent) %>%  
  head(3)
```

	gebietsnummer	gebietsname	prozent
1	115	Duisburg II	73.39475
2	55	Bremen II - Bremerhaven	73.85110
3	122	Gelsenkirchen	74.49673

```
wb %>%
  dplyr::select(gebietsnummer, gebietsname, prozent) %>%
  dplyr::arrange(prozent) %>%
  tail(3)
```

	gebietsnummer	gebietsname	prozent
297	220	München-Land	87.51043
298	128	Münster	87.51841
299	93	Köln II	87.98255

Die Wahlkreise mit der niedrigsten Wahlbeteiligung liegen tendenziell in ehemaligen Industriestädten. Sowohl die Wahlkreise mit der höchsten, als auch jene mit der niedrigsten Wahlbeteiligung liegen in städtischen Gebieten und in Westdeutschland.

Aufgabe 5: Bundesland-Mapping

Führe zunächst folgenden Code aus, um den Wahlkreisen ihre Bundeslandnamen zuzuordnen. Erkläre in eigenen Worten, was die beiden Codeblöcke hier machen.

```
bula_mapping <- btw_2025_ergebnisse %>%
  dplyr::filter(gebietsart == "Land") %>%
  dplyr::select(bula_nr = gebietsnummer, bula_name = gebietsname) %>%
  dplyr::distinct()

wb <- wb %>%
  dplyr::left_join(bula_mapping, by = c("ueg_gebietsnummer" = "bula_nr")) %>%
  dplyr::rename(ueg_gebietsname = bula_name) %>%
  dplyr::relocate(ueg_gebietsname, .after = ueg_gebietsnummer)
```

Zunächst wird eine Tabelle erstellt, in der jeder Bundeslandnummer der dazugehörige Bundeslandname zugeordnet wird. Die Angaben dazu werden aus den Variablen `gebietsnummer` und `gebietsname` des Datensatzes `btw_2025_ergebnisse` entnommen. `left_join` verbindet zwei Datensätze anhand einer gemeinsamen Variable. In diesem Fall wird, basierend auf der Übereinstimmung von `ueg_gebietsnummer` (in `wb`) und `bula_nr` (in `bula_mapping`), jeder übergeordneten Gebietnummer der dazugehörige Bundeslandsname zugewiesen.

Aufgabe 6: Kennwerte nach Bundesland

Gruppieren Sie den Datensatz nach Bundesland und berechnen Sie die Kennwerte der Wahlbeteiligung pro Bundesland. Erstellen Sie außerdem einen gruppierten Boxplot.


```
wb %>%
  dplyr::group_by(ueg_gebietsname) %>%
  dplyr::summarise(
    n = dplyr::n(),
    min = min(prozent, na.rm = TRUE),
    max = max(prozent, na.rm = TRUE),
    range = max(prozent, na.rm = TRUE) - min(prozent, na.rm = TRUE),
    mittelwert = mean(prozent, na.rm = TRUE),
    sd = sd(prozent, na.rm = TRUE),
    median = median(prozent, na.rm = TRUE),
    mad = mad(prozent, na.rm = TRUE),
    q25 = quantile(prozent, probs = 0.25, na.rm = TRUE),
    q75 = quantile(prozent, probs = 0.75, na.rm = TRUE),
    iqr = IQR(prozent, na.rm = TRUE)
  ) %>%
  dplyr::as_tibble()
```

A tibble: 16 x 12

	ueg_gebietsname	n	min	max	range	mittelwert	sd	median	mad	q25
	<chr>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	Baden-Württemberg	38	78.4	86.2	7.78	83.4	1.69	83.4	1.61	82.3
2	Bayern	47	78.3	87.5	9.20	84.2	2.00	84.3	2.08	83.0
3	Berlin	12	75.5	84.7	9.18	80.1	3.38	80.2	3.88	77.4
4	Brandenburg	10	78.5	85.7	7.20	81.2	2.53	79.8	1.64	79.5
5	Bremen	2	73.9	81.2	7.35	77.5	5.19	77.5	5.45	75.7
6	Hamburg	6	76.1	85.6	9.55	81.1	4.28	81.1	5.52	77.8
7	Hessen	22	79.2	85.8	6.63	83.1	1.90	83.4	1.86	81.8
8	Mecklenburg-Vorp~	6	77.9	81.0	3.06	79.5	1.35	79.5	1.76	78.4
9	Niedersachsen	30	81.1	86.4	5.28	83.4	1.35	83.5	1.60	82.3
10	Nordrhein-Westfa~	64	73.4	88.0	14.6	82.0	2.84	82.3	2.11	80.4
11	Rheinland-Pfalz	15	79.2	85.5	6.30	82.9	1.52	83.3	1.46	82.1
12	Saarland	4	79.7	85.2	5.46	82.5	2.27	82.5	2.37	81.4
13	Sachsen	16	78.8	84.2	5.44	81.0	1.66	81.2	1.54	79.6
14	Sachsen-Anhalt	8	76.9	78.5	1.60	77.7	0.583	77.4	0.507	77.3
15	Schleswig-Holste~	11	80.2	85.1	4.90	83.4	1.41	83.2	0.836	82.8
16	Thüringen	8	78.9	83.0	4.16	80.7	1.39	80.3	1.55	79.9

i 2 more variables: q75 <dbl>, iqr <dbl>

```
boxplot(prozent ~ ueg_gebietsname,
        data = wb)
```



Beantworte anschließend folgende Fragen:

a) Schau dir Sachsen-Anhalt genauer an. Was fällt dir auf, wenn du Mittelwert, Median und die Streuung betrachtest? Was sagt das über die Wahlkreise dort aus?

Sachsen-Anhalt hat mit Abstand die niedrigste durchschnittliche Wahlbeteiligung (MW 77.7%) und gleichzeitig die geringste Streuung (SD 0.58, IQR 0.95). Mittelwert und Median liegen sehr nah beieinander (77.7% vs. 77.4%). Das bedeutet: Die Wahlkreise in Sachsen-Anhalt sind sich sehr ähnlich — überall niedrige Beteiligung, kaum Unterschiede zwischen den Wahlkreisen.

b) Vergleiche Bayern und Nordrhein-Westfalen: Beide haben viele Wahlkreise — aber was unterscheidet sie in ihrem Schwerpunkt und ihrer Streuung? Was sagt das aus?

Bayern ($n = 47$) und NRW ($n = 64$) haben beide viele Wahlkreise, unterscheiden sich aber deutlich in der Streuung: Bayern hat $SD = 2.00$ und $IQR = 2.81$, NRW dagegen $SD = 2.84$ und $IQR = 3.11$ — und vor allem eine Spannweite von 14.6 PP gegenüber 9.2 PP in Bayern. NRW ist also intern viel heterogener: zwischen städtischen Wahlkreisen (z.B. Ruhrgebiet) und ländlichen Wahlkreisen gibt es erhebliche Unterschiede in der Wahlbeteiligung.