

Übung 04: Kennwerte und deren Visualisierung

— Lösung

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

15.05.2026

Setup

```
library(dplyr)
library(skimr)
library(here)
```

Aufgabe 1: Daten laden und vorbereiten

Lade den Datensatz `btw_2025_ergebnisse.RData` mit `here::here()`. Filtere anschließend die Wahlkreise und die Wahlbeteiligung heraus (Gruppe: Wählende). Speichere das Ergebnis in einem neuen Objekt namens `wb`. Wie viele Zeilen hat der gefilterte Datensatz?

```
load(here::here("output/btw_2025_ergebnisse.RData"))

wb <- btw_2025_ergebnisse %>%
  dplyr::filter(
    gebietsart == "Wahlkreis",
    gruppenname == "Wählende"
  )

nrow(wb)
```

```
[1] 299
```

```
# stattdessen kannst du auch den Datensatz öffnen und die Zeilen zählen.
```

Der gefilterte Datensatz enthält 299 Zeilen — eine pro Wahlkreis.

Aufgabe 2: Kennwerte berechnen

Berechne mit `dplyr::summarise()` folgende Kennwerte für die Wahlbeteiligung (Variable `prozent`): `n`, Minimum, Maximum, Spannweite, Mittelwert, Standardabweichung, Median, Mittlere Abweichung vom Median, Q25, Q75 und IQR. Nutze `'dplyr::as_tibble'` für eine übersichtliche Ausgabe.

```
wb %>%
  dplyr::summarise(
    n = dplyr::n(),
    min = min(prozent, na.rm = TRUE),
    max = max(prozent, na.rm = TRUE),
    range = max(prozent, na.rm = TRUE) - min(prozent, na.rm = TRUE),
    mittelwert = mean(prozent, na.rm = TRUE),
    sd = sd(prozent, na.rm = TRUE),
    median = median(prozent, na.rm = TRUE),
    mad = mad(prozent, na.rm = TRUE),
    q25 = quantile(prozent, probs = 0.25, na.rm = TRUE),
    q75 = quantile(prozent, probs = 0.75, na.rm = TRUE),
    iqr = IQR(prozent, na.rm = TRUE)
  ) %>%
  dplyr::as_tibble()
```


```
# A tibble: 1 x 11
      n   min   max range mittelwert    sd median   mad   q25   q75   iqr
<int> <dbl> <dbl> <dbl>      <dbl> <dbl>  <dbl> <dbl> <dbl> <dbl> <dbl>
1   299  73.4  88.0  14.6      82.4  2.62  82.9  2.25  81.1  84.3  3.16
```

Die durchschnittliche Wahlbeteiligung liegt bei etwa 82%, der Median ist ähnlich hoch. Mittelwert und Median liegen nah beieinander, was auf eine annähernd symmetrische Verteilung hindeutet. Die Spannweite von ca. 15 PP zeigt aber, dass es erhebliche Unterschiede zwischen den Wahlkreisen gibt. Die SD von ca. 2.5 PP bedeutet, dass die meisten Wahlkreise relativ nah am Mittelwert liegen — die Extremfälle sind tatsächlich Ausreißer.

Aufgabe 3: Visualisierung

Erstelle einen Boxplot der Wahlbeteiligung.

```
boxplot(wb$prozent)
```



Der Median liegt leicht unterhalb der Mitte der Box, was auf eine leichte Rechtsschiefe hindeutet — es gibt einige Wahlkreise mit sehr hoher Wahlbeteiligung. Die Whisker sind asymmetrisch: der untere ist länger, was auf einige Wahlkreise mit deutlich niedrigerer Beteiligung hinweist. Es gibt keine extremen Ausreißer.

Aufgabe 4: Extremfälle

In welchen drei Wahlkreisen war die Wahlbeteiligung am niedrigsten, in welchen am höchsten?

```
wb %>%  
  dplyr::select(gebietsnummer, gebietsname, prozent) %>%  
  dplyr::arrange(prozent) %>%  
  head(3)
```

	gebietsnummer	gebietsname	prozent
1	115	Duisburg II	73.39475
2	55	Bremen II - Bremerhaven	73.85110
3	122	Gelsenkirchen	74.49673

```
wb %>%
  dplyr::select(gebietsnummer, gebietsname, prozent) %>%
  dplyr::arrange(prozent) %>%
  tail(3)
```

	gebietsnummer	gebietsname	prozent
297	220	München-Land	87.51043
298	128	Münster	87.51841
299	93	Köln II	87.98255

Die Wahlkreise mit der niedrigsten Wahlbeteiligung liegen tendenziell in städtischen Gebieten und ostdeutschen Bundesländern. Die Wahlkreise mit der höchsten Beteiligung finden sich eher in ländlichen Regionen Süddeutschlands.

Aufgabe 5: Bundesland-Mapping

Führe zunächst folgenden Code aus, um den Wahlkreisen ihre Bundeslandnamen zuzuordnen. Erkläre in eigenen Worten, was die beiden Codeblöcke hier machen.

```
bula_mapping <- btw_2025_ergebnisse %>%
  dplyr::filter(gebietsart == "Land") %>%
  dplyr::select(bula_nr = gebietsnummer, bula_name = gebietsname) %>%
  dplyr::distinct()

wb <- wb %>%
  dplyr::left_join(bula_mapping, by = c("ueg_gebietsnummer" = "bula_nr")) %>%
  dplyr::rename(ueg_gebietsname = bula_name) %>%
  dplyr::relocate(ueg_gebietsname, .after = ueg_gebietsnummer)
```

Zunächst wird eine Tabelle erstellt, in der jeder Bundeslandnummer der dazugehörige Bundeslandname zugeordnet wird. Die Angaben dazu werden aus den Variablen `gebietsnummer` und `gebietsname` des Datensatzes `btw_2025_ergebnisse` entnommen. `left_join` verbindet zwei Datensätze anhand einer gemeinsamen Variable. Basierend auf der Übereinstimmung von `ueg_gebietsnummer` (in `wb`) und `bula_nr` (in `bula_mapping`) wird jeder übergeordneten Gebietnummer ein übergeordneter Gebietsname zugewiesen.

Aufgabe 6: Kennwerte nach Bundesland

Gruppieren den Datensatz nach Bundesland und berechne die Kennwerte der Wahlbeteiligung pro Bundesland. Erstelle außerdem einen gruppierten Boxplot.

```
wb %>%
  dplyr::group_by(ueg_gebietsname) %>%
  dplyr::summarise(
    n = dplyr::n(),
    min = min(prozent, na.rm = TRUE),
    max = max(prozent, na.rm = TRUE),
    range = max(prozent, na.rm = TRUE) - min(prozent, na.rm = TRUE),
    mittelwert = mean(prozent, na.rm = TRUE),
    sd = sd(prozent, na.rm = TRUE),
    median = median(prozent, na.rm = TRUE),
    mad = mad(prozent, na.rm = TRUE),
    q25 = quantile(prozent, probs = 0.25, na.rm = TRUE),
    q75 = quantile(prozent, probs = 0.75, na.rm = TRUE),
    iqr = IQR(prozent, na.rm = TRUE)
  ) %>%
  t()
```


	[,1]	[,2]	[,3]	[,4]
ueg_gebietsname	"Baden-Württemberg"	"Bayern"	"Berlin"	"Brandenburg"
n	"38"	"47"	"12"	"10"
min	"78.40132"	"78.31401"	"75.51378"	"78.48133"
max	"86.17861"	"87.51043"	"84.69247"	"85.68367"
range	" 7.777291"	" 9.196420"	" 9.178690"	" 7.202347"
mittelwert	"83.35728"	"84.24978"	"80.09492"	"81.22817"
sd	"1.6887876"	"2.0023860"	"3.3781778"	"2.5343590"
median	"83.37643"	"84.32544"	"80.23311"	"79.79641"
mad	"1.6132549"	"2.0846512"	"3.8801384"	"1.6418446"
q25	"82.32823"	"82.95055"	"77.42094"	"79.54406"
q75	"84.57418"	"85.76173"	"82.77057"	"83.31382"
iqr	"2.245945"	"2.811177"	"5.349636"	"3.769759"

	[,5]	[,6]	[,7]	[,8]
ueg_gebietsname	"Bremen"	"Hamburg"	"Hessen"	"Mecklenburg-Vorpommern"
n	" 2"	" 6"	"22"	" 6"
min	"73.85110"	"76.08221"	"79.15077"	"77.92138"
max	"81.19677"	"85.63301"	"85.77745"	"80.98470"
range	" 7.345669"	" 9.550798"	" 6.626673"	" 3.063319"
mittelwert	"77.52393"	"81.10009"	"83.11332"	"79.48946"

sd	"5.1941724"	"4.2773894"	"1.9008235"	"1.3493840"
median	"77.52393"	"81.06605"	"83.44916"	"79.51630"
mad	"5.4453444"	"5.5178265"	"1.8569580"	"1.7580804"
q25	"75.68751"	"77.75985"	"81.81320"	"78.39070"
q75	"79.36035"	"84.83810"	"84.63512"	"80.61602"
iqr	"3.672835"	"7.078251"	"2.821918"	"2.225320"
	[,9]	[,10]		[,11]
ueg_gebietsname	"Niedersachsen"	"Nordrhein-Westfalen"		"Rheinland-Pfalz"
n	"30"	"64"		"15"
min	"81.13782"	"73.39475"		"79.17504"
max	"86.41345"	"87.98255"		"85.47998"
range	" 5.275627"	"14.587797"		" 6.304937"
mittelwert	"83.36202"	"82.00365"		"82.91936"
sd	"1.3464289"	"2.8372295"		"1.5183940"
median	"83.49511"	"82.28608"		"83.28989"
mad	"1.5978966"	"2.1087946"		"1.4574596"
q25	"82.25898"	"80.41271"		"82.09417"
q75	"84.49018"	"83.52304"		"83.80420"
iqr	"2.231200"	"3.110330"		"1.710028"
	[,12]	[,13]	[,14]	[,15]
ueg_gebietsname	"Saarland"	"Sachsen"	"Sachsen-Anhalt"	"Schleswig-Holstein"
n	" 4"	"16"	" 8"	"11"
min	"79.72884"	"78.75991"	"76.93226"	"80.22609"
max	"85.18977"	"84.20193"	"78.53223"	"85.12453"
range	" 5.460926"	" 5.442022"	" 1.599970"	" 4.898433"
mittelwert	"82.49920"	"80.98523"	"77.68457"	"83.39943"
sd	"2.2741332"	"1.6577089"	"0.5826158"	"1.4142385"
median	"82.53909"	"81.18383"	"77.44921"	"83.20242"
mad	"2.3702356"	"1.5352857"	"0.5074666"	"0.8361834"
q25	"81.42648"	"79.56910"	"77.30218"	"82.80900"
q75	"83.61181"	"81.70425"	"78.25213"	"84.67555"
iqr	"2.185323"	"2.135154"	"0.949953"	"1.866555"
	[,16]			
ueg_gebietsname	"Thüringen"			
n	" 8"			
min	"78.85383"			
max	"83.00996"			
range	" 4.156131"			
mittelwert	"80.71555"			
sd	"1.3912078"			
median	"80.30683"			
mad	"1.5522563"			
q25	"79.93079"			

```
q75      "81.71752"
iqr      "1.786733"
```

```
boxplot(prozent ~ ueg_gebietsname,
        data = wb)
```



Beantworte anschließend folgende Fragen:

a) Schau dir Sachsen-Anhalt genauer an. Was fällt dir auf, wenn du Mittelwert, Median und die Streuung betrachtest? Was sagt das über die Wahlkreise dort aus?

Sachsen-Anhalt hat mit Abstand die niedrigste durchschnittliche Wahlbeteiligung (MW 77.7%) und gleichzeitig die geringste Streuung (SD 0.58, IQR 0.95). Mittelwert und Median liegen sehr nah beieinander (77.7% vs. 77.4%). Das bedeutet: Die Wahlkreise in Sachsen-Anhalt sind sich sehr ähnlich — überall niedrige Beteiligung, kaum Unterschiede zwischen den Wahlkreisen.

b) Vergleiche Bayern und Nordrhein-Westfalen: Beide haben viele Wahlkreise — aber was unterscheidet sie in ihrem Schwerpunkt und ihrer Streuung? Was sagt das aus?

Bayern ($n = 47$) und NRW ($n = 64$) haben beide viele Wahlkreise, unterscheiden sich aber deutlich in der Streuung: Bayern hat $SD = 2.00$ und $IQR = 2.81$, NRW dagegen $SD = 2.84$ und $IQR = 3.11$ — und vor allem eine Spannweite von 14.6 PP gegenüber 9.2 PP in Bayern. NRW ist also intern viel heterogener: zwischen städtischen Wahlkreisen (z.B. Ruhrgebiet) und ländlichen Wahlkreisen gibt es erhebliche Unterschiede in der Wahlbeteiligung.