

Übung 07: Zusammenhänge

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

Franka Weiß

13.06.2026

Setup

Lade die für deine Analyse nötigen Pakete.

```
library(dplyr)
library(janitor)
library(ggplot2)
library(labelled)
library(haven)
library(forcats)
```

Aufgabe 1: Daten laden

Lies den ALLBUS-Datensatz von 2023 ein. Speichere den Datensatz in einem Objekt namens `allbus_c_2023_raw`.

```
allbus_c_2023_raw <- haven::read_dta(here::here("./data/ZA8831_v1-3-0.dta"))
```

Unter Sitzungen => Sitzung 08 findest du außerdem eine mit summarytools erstellte Übersicht über den Datensatz. Lade sie gern herunter und lege sie in deinen Datenordner. Du wirst im Laufe dieser und zukünftiger Übungen die Gelegenheit bekommen, selbst auszuwählen, welche Zusammenhänge dich interessieren. Um diese Auswahl zu treffen, kannst du dich auf diese Datensatzübersicht stützen.

Aufgabe 2: Variablen vorbereiten

Suche dir zwei (oder mehr) Variablen aus, deren Zusammenhang dich interessiert. Nimm dazu gern die Datensatzübersicht zur Hand (siehe oben). Welches Bauchgefühl oder welche Vermutung hast du bezüglich des Zusammenhangs?

Ich gehe davon aus, dass Personen, die mindestens “mehrmals im Jahr” in die Kirche gehen (rp01, “Kirchgangshäufigkeit”) zumindest “etwas” ($\Rightarrow 3$) danach streben, Gemeinschaft zu erfahren (vg02, “Strebe danach, Gemeinschaft zu erfahren”). Es wäre also interessant zu testen, inwiefern die Stärke des Strebens nach Gemeinschaft mit der Häufigkeit der Kirchenbesuche zusammenhängt.

Mit dem `look for`-Befehl aus dem `labelled`-Package kannst du anschließend nach diesen Variablen suchen. Beantworte dir für jede der Variablen folgende Fragen: Welche Werte kann sie annehmen? Und welche davon sind in Wahrheit “Missings”? Konvertiere diese Werte zu NA. Transformiere dabei die Variable zu einem Faktor, wenn sie kategorial ist, oder zu einer numerischen Variable, wenn sie metrisch bzw. intervallskaliert ist. Vergiss bei ersterer Option nicht, die leeren Faktorlevel zu entfernen (siehe Skript zu Sitzung 08).

```
allbus_c_2023_raw %>%  
  labelled::look_for("kirchgangshaeufigkeit")
```

pos	variable	label	col_type	missing	values
326	rp01	KIRCHGANGSHAEUFIGKEIT	dbl+lbl	0	[-42] DATENFEHLER: MFN [-41] DATENFEHLER [-10] TNZ: FILTER [-9] KEINE ANGABE [1] UEBER 1X DIE WOCHE [2] 1X PRO WOCHE [3] 1-3X PRO MONAT [4] MEHRMALS IM JAHR [5] SELTENER [6] NIE

```
allbus_c_2023_raw %>%  
  labelled::look_for("strebe danach gemeinschaft zu erfahren")
```

pos	variable	label	col_type	missing
38	vg02	STREBE DANACH GEMEINSCHAFT ZU E~	dbl+lbl	0

```
values
[-11] TNZ: SPLIT
[-9] KEINE ANGABE
[1] GAR NICHT
[2] KAUM
[3] ETWAS
[4] ZIEMLICH
[5] SEHR
[6] EXTREM
```

```
allbus_c_2023 <- allbus_c_2023_raw %>%
  dplyr::mutate(
    rp01_f = haven::as_factor(dplyr::case_when(rp01 < 0 ~ NA, .default = rp01)) %>%
      forcats::fct_drop(),
    vg02_f = haven::as_factor(dplyr::case_when(vg02 < 0 ~ NA, .default = vg02)) %>%
      forcats::fct_drop(),
  )
  # was ist nochmal der Sinn hinter dem Entfernen leerer Faktorlevels, bzw.
  #was ist das überhaupt? Das habe ich noch nicht verstanden...

allbus_c_2023 %>%
  count(rp01_f)
```

```
# A tibble: 7 x 2
  rp01_f          n
  <fct>        <int>
1 UEBER 1X DIE WOCHE    57
2 1X PRO WOCHE       140
3 1-3X PRO MONAT      217
4 MEHRMALS IM JAHR    610
5 SELTENER          1440
6 NIE               2582
7 <NA>              200
```

```
allbus_c_2023 %>%
  count(vg02_f)
```

```
# A tibble: 7 x 2
```

	vg02_f	n
	<fct>	<int>
1	GAR NICHT	10
2	KAUM	55
3	ETWAS	291
4	ZIEMLICH	792
5	SEHR	1231
6	EXTREM	274
7	<NA>	2593

- Die Variable "Kirchgangshäufigkeit" (rp01) ist ordinalskaliert und kann Werte von -42 bis 6 annehmen, wobei alle Werte im unter 1 Missings sind. - Die Variable "Strebe danach, Gemeinschaft zu erfahren" (vg02) ist ebenfalls ordinalskaliert und reicht von -11 bis 6, die Werte im Minusbereich sind ebenfalls Missings.

Aufgabe 3: Zusammenhang erkunden

Überlege dir, wie du den Zusammenhang, der dich interessiert, am besten darstellen könntest. In einer Kreuztabelle? In einem (gestapelten) Balkendiagramm? In einer Korrelationsmatrix oder einem Korrelationskoeffizienten? Nutze alle Darstellungsmöglichkeiten, die sinnvoll sind und führe die entsprechenden Analysen durch. Interpretiere dein Output unten.

```
# Kreuztabelle
```

```
allbus_c_2023 %>%
  gtsummary::tbl_cross(
    row = rp01_f,
    col = vg02_f,
    percent = "row",
    missing = "no",
    margin = "row"
  )
```

```
#Cramers V
```

```
effectsize::cramers_v(
  stats::chisq.test(allbus_c_2023$rp01_f, allbus_c_2023$vg02_f),
  ci = 0.95,
  alternative = "two.sided"
)
```


	STREBE DANACH GEMEINSCHAFT ZU ERFAHREN				
	GAR NICHT	KAUM	ETWAS	ZIEMLICH	SEHR
KIRCHGANGSHAUEFIGKEIT					
UEBER 1X DIE WOCHE	0 (0%)	0 (0%)	1 (4.8%)	6 (29%)	13 (62%)
1X PRO WOCHE	0 (0%)	0 (0%)	4 (6.3%)	18 (29%)	32 (51%)
1-3X PRO MONAT	0 (0%)	1 (0.9%)	5 (4.3%)	27 (23%)	73 (62%)
MEHRMALS IM JAHR	0 (0%)	3 (1.0%)	31 (10%)	95 (32%)	140 (47%)
SELTENER	2 (0.3%)	12 (1.6%)	75 (10%)	227 (31%)	348 (47%)
NIE	8 (0.6%)	37 (2.8%)	167 (13%)	398 (30%)	581 (44%)
Total	10 (0.4%)	53 (2.1%)	283 (11%)	771 (30%)	1,187 (46%)

Cramer's V (adj.) | 95% CI

 0.03 | [0.00, 0.03]

```
# stacked bar plot

allbus_c_2023_raw %>%
  dplyr::mutate(
    rp01 = haven::as_factor(dplyr::case_when(rp01 < 0 ~ NA, .default = rp01)),
    vg02 = haven::as_factor(dplyr::case_when(vg02 < 0 ~ NA, .default = vg02))
  ) %>%
  dplyr::filter(!is.na(rp01), !is.na(vg02)) %>%
  ggplot2::ggplot(aes(x = rp01, fill = vg02)) +
  ggplot2::geom_bar(position = "fill") +
  ggplot2::scale_y_continuous(labels = scales::percent) +
  ggplot2::theme_bw() +
  ggplot2::theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    legend.title = element_blank(),
    axis.title.y = element_blank()
  )
```



```
# scatter plot

allbus_c_2023 %>%
  filter(!is.na(rp01_f), !is.na(vg02_f)) %>%
  ggplot(aes(x = rp01_f, y = vg02_f)) +
  geom_point(position = "jitter", alpha = 0.3, color = "darkturquoise") +
  theme_minimal() +
  ggplot2::theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    legend.title = element_blank()
  )
```



```
#colors()
```

Die Kreuztabelle sieht zwar gut aus, offenbart aber keinen Zusammenhang. Daher versuche ich im nächsten Schritt die Berechnung von Cramers V. Der Wert ist 0.03 (also extrem niedrig) es liegt also kein Zusammenhang vor. Beim Anschauen der Kreuztabelle hatte ich das Gefühl, dass "in der Mitte" die Prozentzahlen größer sind, daher nochmal die Visualisierung mit einem stacked bar plot. Da sieht man, dass die Zahl der befragten Menschen, die sehr nach Gemeinschaft streben, am größten ist in der Gruppe derer, die 1-3x pro Monat oder über 1x die Woche in die Kirche gehen. Es sieht so aus, als hätte niemand, der/der mehr als 1x pro Woche in die Kirche geht angegeben, kaum oder gar nicht nach Gemeinschaft zu streben. (Ein Blick in die Kreuztabelle bestätigt das.) Der Scatter-Plot, letztendlich zeigt deutlich (was ich dank Cramers V eigentlich ja schon weiß), dass KEIN linearer Zusammenhang zwischen der Kirchgangshäufigkeit und dem Streben nach Gemeinschaft besteht.

(Eigentlich habe ich mit der Kirche nichts am Hut, die Variable ist mir nur als erstes ins Auge gesprungen) – um aber zu testen, ob ich R richtig benutzt habe, vergleiche ich die Kirchgangshäufigkeit jetzt nochmal mit einer weiteren Variable, wo ich eine hohe Korrelation mit der Kirchgangshäufigkeit vermute: vi12, "Wichtig: Gottesglaube":

```
allbus_c_2023_raw %>%
  labelled::look_for("Wichtig: Gottesglaube")
```

```
pos variable label
```

```
col_type missing values
```

```
58 vi12      WICHTIG: GOTTESGLAUBE dbl+lbl  0      [-11] TNZ: SPLIT
                                                    [-9] KEINE ANGABE
                                                    [1] 1 - UNWICHTIG
                                                    [2] ..
                                                    [3] ..
                                                    [4] ..
                                                    [5] ..
                                                    [6] ..
                                                    [7] 7 - SEHR WICHTIG
```

```
allbus_c_2023 <- allbus_c_2023 %>%
  mutate(
    vi12_d = vi12 %>%
      na_if(-11) %>%
      na_if(-9) %>%
    as.double(vi12) #ist das falsch? eigentlich ist vi12 ja auch eine
    #ordinalskalierte Variable... aber wenn ich sie als Faktor klassifiziere,
    #gehen mir die Stufen zwischen 1 und 7 verloren...
  )

allbus_c_2023 %>%
  count(vi12_d)
```

```
# A tibble: 8 x 2
  vi12_d      n
  <dbl> <int>
1      1  1055
2      2   288
3      3   216
4      4   234
5      5   196
6      6   255
7      7   312
8     NA  2690
```

```
allbus_c_2023_raw %>%
  count(vi12)
```

```
# A tibble: 9 x 2
  vi12      n
  <dbl+lbl> <int>
```

1	-11	[TNZ: SPLIT]	2675
2	-9	[KEINE ANGABE]	15
3	1	[1 - UNWICHTIG]	1055
4	2	[..]	288
5	3	[..]	216
6	4	[..]	234
7	5	[..]	196
8	6	[..]	255
9	7	[7 - SEHR WICHTIG]	312


```
# Cramers V

effectsize::cramers_v(
  stats::chisq.test(allbus_c_2023$rp01_f, allbus_c_2023$vi12_d),
  ci = 0.95,
  alternative = "two.sided"
)
```

Cramer's V (adj.)		95% CI
0.35		[0.32, 0.36]

```
# Scatterplot (überhaupt in Ordnung bei nicht (ausschließlich) metrischen Variablen?)

allbus_c_2023 %>%
  filter(!is.na(rp01_f), !is.na(vi12_d)) %>%
  ggplot(aes(x = rp01_f, y = vi12_d)) +
  geom_point(position = "jitter", alpha = 0.3, color = "blue") +
  ggplot2::scale_y_continuous(breaks = seq(1, 7, by = 1)) +
  labs(x = "Kirchgangshäufigkeit",
       y = "Wichtig: Gottesglaube") +
  theme_minimal() +
  ggplot2::theme(
    axis.text.x = element_text(angle = 45, hjust = 1),
    legend.title = element_blank()
  )
```



Cramers V zeigt einen Zusammenhang von 0.32 an, also mäßig stark. Der Scatterplot zeigt vielleicht, warum der Zusammenhang nicht sehr stark ist: Von den Leuten, die öfter als mehrmals im Jahr in die Kirche gehen, ist kaum jemanden der Gottesglaube nicht wichtig. Allerdings gaben auch viele Menschen an, dass ihnen der Gottesglaube (sehr) wichtig sei und sie nur selten oder nie in die Kirche gehen. Das liegt sicher auch daran, dass Menschen auch gläubig sein können ohne eine (christliche) Kirche zu besuchen. (Wurde im Allbus auch das Besuchen anderer Gotteshäuser erhoben?)