

Übung 07: Zusammenhänge

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

Anne Gerbach

16.06.2026

Setup

Lade die für deine Analyse nötigen Pakete.

```
library(dplyr)
library(ggplot2)
library(here)
library(haven)
library(tidyr)
library(labelled)
library(forcats)
library(correlation)
library(report)
```

Aufgabe 1: Daten laden

Lies den ALLBUS-Datensatz von 2023 ein. Speichere den Datensatz in einem Objekt namens `allbus_c_2023_raw`.

```
setwd("~/Desktop/FU Berlin/Semester/6. Semester/RStudio mit Kratz/data")
```

```
allbus_c_2023_raw <- haven::read_dta("/Users/anne/Desktop/FU Berlin/Semester/6. Semester/RStudio mit Kratz/data/allbus_c_2023.dta")
```

Unter Sitzungen => Sitzung 08 findest du außerdem eine mit summarytools erstellte Übersicht über den Datensatz. Lade sie gern herunter und lege sie in deinen Datenordner. Du wirst im Laufe dieser und zukünftiger Übungen die Gelegenheit bekommen, selbst auszuwählen, welche Zusammenhänge dich interessieren. Um diese Auswahl zu treffen, kannst du dich auf diese Datensatzübersicht stützen.

Aufgabe 2: Variablen vorbereiten

Suche dir zwei (oder mehr) Variablen aus, deren Zusammenhang dich interessiert. Nimm dazu gern die Datensatzübersicht zur Hand (siehe oben). Welches Bauchgefühl oder welche Vermutung hast du bezüglich des Zusammenhangs?

Ich habe mir die Variablen li02 (WICHTIGKEIT: BERUF UND ARBEIT) und vi10 (WICHTIG: POLITISCHES ENGAGEMENT) ausgesucht. Meine Vermutung ist desto höher die Wichtigkeit von Beruf und Arbeit ist, desto niedriger wird die Wichtigkeit von Politischem Engagemnet eingestuft.

Mit dem look for-Befehl aus dem labelled-Package kannst du anschließend nach diesen Variablen suchen. Beantworte dir für jede der Variablen folgende Fragen: Welche Werte kann sie annehmen? Und welche davon sind in Wahrheit “Missings”? Konvertiere diese Werte zu NA. Transformiere dabei die Variable zu einem Faktor, wenn sie kategorial ist, oder zu einer numerischen Variable, wenn sie metrisch bzw. intervallskaliert ist. Vergiss bei ersterer Option nicht, die leeren Faktorlevel zu entfernen (siehe Skript zu Sitzung 08).

```
allbus_c_2023_raw %>%  
  labelled::look_for("wichtigkeit: beruf")
```

```
pos variable label                                col_type missing  
27 li02      WICHTIGKEIT: BERUF UND ARB~ dbl+lbl  0
```

```
values  
[-42] DATENFEHLER: MFN  
[-9] KEINE ANGABE  
[1] 1 - UNWICHTIG  
[2] ..  
[3] ..  
[4] ..  
[5] ..  
[6] ..  
[7] 7 - SEHR WICHTIG
```

```
allbus_c_2023_raw %>%
  labelled::look_for("wichtig: pol")
```

```
pos variable label col_type missing
56 vi10 WICHTIG: POLITISCHES ENGAGEM~ dbl+lbl 0
```

```
values
[-11] TNZ: SPLIT
[-9] KEINE ANGABE
[1] 1 - UNWICHTIG
[2] ..
[3] ..
[4] ..
[5] ..
[6] ..
[7] 7 - SEHR WICHTIG
```

```
allbus_c_2023_raw <- allbus_c_2023_raw %>%
  mutate(vi10 = na_if(vi10, -9),
         vi10 = na_if(vi10, -11),
         vi10 = na_if(vi10, -42))

allbus_c_2023_raw <- allbus_c_2023_raw %>%
  mutate(li02 = na_if(li02, -09),
         li02 = na_if(li02, -11),
         li02 = na_if(li02, -42))

allbus_c_2023_clean <- allbus_c_2023_raw %>%
  filter(!is.na(vi10)) %>%
  filter(!is.na(li02))

allbus_c_2023_clean %>%
  dplyr::mutate(
    vi10 = as.double(vi10),
```

```

    li02 = as.double(li02)
  ) %>%
  select(vi10, li02)

```

```

# A tibble: 2,453 x 2
   vi10  li02
   <dbl> <dbl>
1     5     6
2     3     7
3     3     6
4     6     7
5     3     7
6     7     7
7     1     7
8     2     7
9     4     6
10    2     4
# i 2,443 more rows

```

Die Variablen können beide von 1 bis 7 - 1 = Unwichtig zu 7 = Sehr Wichtig - annehmen. Dazu gehören auch die Missings von -42(DATENFEHLER: MFN), -11(TNZ: SPLIT) und -9(KEINE ANGABE). Die Variablen haben das Label double und können daher metrisch weiterverarbeitet werden.

Aufgabe 3: Zusammenhang erkunden

Überlege dir, wie du den Zusammenhang, der dich interessiert, am besten darstellen könntest. In einer Kreuztabelle? In einem (gestapelten) Balkendiagramm? In einer Korrelationsmatrix oder einem Korrelationskoeffizienten? Nutze alle Darstellungsmöglichkeiten, die sinnvoll sind und führe die entsprechenden Analysen durch. Interpretiere dein Output unten.

```

cor_01 <- allbus_c_2023_clean %>%
  dplyr::select(vi10, li02) %>%
  correlation::correlation()

summary(cor_01)

```

```

# Correlation Matrix (pearson-method)


```

Parameter	li02

vi10	0.11***

p-value adjustment method: Holm (1979)

```
allbus_c_2023_clean %>%
  ggplot(aes(x = li02, y = vi10)) +
  geom_point(position = "jitter", alpha = 0.3) +
  labs(x = "Wichtigkeit Beruf und Arbeit",
       y = "Politisches Engagement ist Wichtig") +
  theme_minimal()
```



```
allbus_c_2023_raw <- allbus_c_2023_raw %>%
  dplyr::mutate(
    across(
      c(vi10, li02),
      ~ dplyr::case_when(.x < 0 ~ NA_real_, .default = as.double(.x)),
      .names = "{.col}_d"
    )
  )
```

```
allbus_c_2023_raw %>%
  select(ends_with("_d")) %>%
  correlation::correlation()
```

```
# Correlation Matrix (pearson-method)
```

Parameter1	Parameter2	r	95% CI	t(2451)	p
vi10_d	li02_d	0.11	[0.07, 0.15]	5.48	< .001***

```
p-value adjustment method: Holm (1979)
```

```
Observations: 2453
```

Da beide Variablen metrisch sind, kann ich entweder den Pearson Korrelationskoeffizienten nutzen oder das ganze in einem Scatterplot darstellen. Es gibt einen schwachen, positiven Zusammenhang zwischen der Wichtigkeit von Arbeit und Beruf und dem Empfinden von Politischem Engagement als Wichtig ($r=0.11$). In anderen Worten: Wer bei der einen Variable hoch ist, tendiert leicht dazu auch bei der anderen höher zu sein. Der Zusammenhang mit $p<.001$ ist statistisch sehr signifikant, was aber auch an der hohen Stichprobenanzahl ($n=2451$) liegen kann. Zusammengefasst kann man also sagen dass der Zusammenhang zwischen den beiden Variablen nicht unbedingt praktisch bedeutsam ist. P.S. die Interpretation von dem Scatterplot finde ich sehr schwierig und unübersichtlich, daher habe ich mich bei der Interpretation auf die Pearson-method verlassen.