

Übung 09: Multiple Regression & Diagnostik

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

Gurprasad Lütke

26.06.2026

Setup

Lade die für deine Analyse nötigen Pakete.

```
library(haven)
library(labelled)
library(dplyr)
library(ggplot2)

library(stargazer)
library(texreg)
library(performance)
library(see)
library(qqplotr)
```

Aufgabe 1: Daten laden

Lies den ALLBUS-Datensatz von 2023 ein. Speichere den Datensatz in einem Objekt namens `allbus_c_2023_raw`.

```
allbus_c_2023_raw <- haven::read_dta(here::here("../data/ZA8831_v1-3-0.dta"))
```

Aufgabe 2: Forschungsfrage & Variablenauswahl

In dieser Übung baust du deine eigene multiple Regression. Nimm dazu gern wieder die Datensatzübersicht zur Hand (siehe Sitzung 08). Überlege dir zunächst eine **Forschungsfrage**, die sich mit einer linearen Regression beantworten lässt.

Wähle dafür eine **abhängige Variable (AV)**, die (quasi-)metrisch ist, sowie **mindestens drei unabhängige Variablen (UVs)**, davon mindestens eine kategoriale. Welche Vermutung hast du bezüglich der Zusammenhänge?

Denke dabei auch an die **Exogenität**: Welche Variablen könnten deine AV *und* eine deiner UVs gemeinsam beeinflussen — und hast du sie als Kontrollvariablen dabei?

Frage: Welche Faktoren beeinflussen das Vertrauen in das Europäische Parlament?

AV: pt20 = VERTRAUEN: EUROPÄISCHES PARLAMENT

UV1: pd12 = BEWERTUNG VON DEMOKRATIE ALS IDEE - vmtl. pos. Zsmhg.

UV2: pa02a = POLITISCHES INTERESSE, BEFR. (ORDINAL) - vmtl. pos. Zsmhg.

UV3: pa35 = POLITIKER VERTRETEN NUR DIE REICHEN - vmtl. neg. Zsmhg.

UV4: eastwest = Erhebungsgebiet (West-Ost) - vmtl. Vertrauen Westen > Osten.

Kontrollvariablen: id02 = SUBJEKTIVE SCHICHTEINSTUFUNG, BEFR., de15 = BEFR.: HOCHSCHULABSCHLUSS, age = ALTER: BEFRAGTE(R).

Aufgabe 3: Variablen vorbereiten

Suche deine gewählten Variablen mit dem `look_for`-Befehl aus dem `labelled`-Package. Beantworte dir für jede: Welche Werte kann sie annehmen? Welche davon sind in Wahrheit “Missings”? Konvertiere diese zu `NA`. Dichotomisiere oder pole ggf. um, wo nötig. Prüfe anschließend mit `count()`, ob die Aufbereitung geklappt hat.

```
allbus_c_2023_raw %>%  
  labelled::look_for("pt20")
```

1 bis 7 = gar kein Vertrauen bis großes Vertrauen, -11 und -9 = missings

```
allbus_c_2023_raw %>%  
  labelled::look_for("pd12")
```

1 bis 6 = sehr dafür bis sehr dagegen, -42, -11 und -9 = missings, die Polung ist andersrum, als ich intuitiv vermutet hätte.

```
allbus_c_2023_raw %>%
  labelled::look_for("pa02a")
```

1 bis 5 = sehr starkes bis überhaupt kein politisches Interesse, -42 und -9 = missings, die Polung ist andersrum, als ich intuitiv vermutet hätte.

```
allbus_c_2023_raw %>%
  labelled::look_for("pa35")
```

1 bis 5 = stimme voll zu bis lehne ganz ab, -42, -11 und -9 = missings, die Polung ist andersrum, als ich intuitiv vermutet hätte.

```
allbus_c_2023_raw %>%
  labelled::look_for("eastwest")
```

1 = Alte Bundesländer, 2 = Neue Bundesländer, keine missings.

```
allbus_c_2023_raw %>%
  labelled::look_for("id02")
```

- 1 = UNTERSCHICHT, 2 = ARBEITERSCHICHT, 3 = MITTELSCHICHT, 4 = OBERE MITTELSCHICHT, 5 = OBERSCHICHT, <0 = missings

```
allbus_c_2023_raw %>%
  labelled::look_for("BEFR.: HOCHSCHULABSCHLUSS")
```

1 = Hochschulabschluss liegt vor, <0 = missing.

```
allbus_c_2023_raw %>%
  labelled::look_for("ALTER: BEFRAGT")
```

- age = Alter der Befragten, -32 = missing.*

```
allbus_c_2023 <- allbus_c_2023_raw %>%
  dplyr::mutate(
    pt20 = dplyr::case_when(pt20 < 0 ~ NA, .default = pt20),
    pd12 = dplyr::case_when(pd12 < 0 ~ NA, .default = pd12),
    pd12 = max(pd12, na.rm = TRUE) - pd12 + 1,
    pa02a = dplyr::case_when(pa02a < 0 ~ NA, .default = pa02a),
    pa02a = max(pa02a, na.rm = TRUE) - pa02a + 1,
```

```

pa35 = dplyr::case_when(pa35 < 0 ~ NA, .default = pa35),
  pa35 = max(pa35, na.rm = TRUE) - pa35 + 1,
  eastwest = haven::as_factor(eastwest),
  id02 = dplyr::case_when(id02 < 0 ~ NA, .default = id02),
  de15 = haven::as_factor(dplyr::case_when(de15 < 0 ~ NA, .default = de15)),
  age = dplyr::case_when(age < 0 ~ NA, .default = age)
)

```

```

allbus_c_2023 %>%
  count(pt20) %>%
  print(n = Inf)

```

```

# A tibble: 8 x 2
  pt20      n
  <dbl> <int>
1  1 [GAR KEIN VERTRAUEN] 520
2  2 [...]              452
3  3 [...]              650
4  4 [...]              820
5  5 [...]              652
6  6 [...]              344
7  7 [GROSSES VERTRAUEN]  99
8 NA              1709

```

```

allbus_c_2023 %>%
  count(pd12) %>%
  print(n = Inf)

```

```

# A tibble: 7 x 2
  pd12      n
  <dbl> <int>
1     1      9
2     2     28
3     3     54
4     4    266
5     5    906
6     6   2317
7    NA   1666

```

```
allbus_c_2023 %>%
  count(pa02a) %>%
  print(n = Inf)
```

```
# A tibble: 6 x 2
  pa02a      n
  <dbl> <int>
1     1    190
2     2    663
3     3   2303
4     4   1542
5     5    527
6    NA     21
```

```
allbus_c_2023 %>%
  count(pa35) %>%
  print(n = Inf)
```

```
# A tibble: 6 x 2
  pa35      n
  <dbl> <int>
1     1    232
2     2    740
3     3   1269
4     4    817
5     5    535
6    NA   1653
```

```
allbus_c_2023 %>%
  count(eastwest) %>%
  print(n = Inf)
```

```
# A tibble: 2 x 2
  eastwest      n
  <fct>      <int>
1 ALTE BUNDESLAENDER 3567
2 NEUE BUNDESLAENDER 1679
```

```
allbus_c_2023 %>%
  count(id02) %>%
  print(n = Inf)
```

```
# A tibble: 6 x 2
  id02          n
  <dbl+lbl>    <int>
1 1 [UNTERSCHICHT] 223
2 2 [ARBEITERSCHICHT] 1251
3 3 [MITTELSCHICHT] 2868
4 4 [OBERE MITTELSCHICHT] 793
5 5 [OBERSCHICHT] 54
6 NA          57
```

```
allbus_c_2023 %>%
  count(de15) %>%
  print(n = Inf)
```

```
# A tibble: 3 x 2
  de15          n
  <fct>    <int>
1 NICHT GENANNT 3974
2 GENANNT      1194
3 <NA>         78
```

```
allbus_c_2023 %>%
  count(age) %>%
  print(n = Inf)
```

```
# A tibble: 80 x 2
  age          n
  <dbl+lbl> <int>
1 18         41
2 19         57
3 20         54
4 21         44
5 22         61
6 23         60
7 24         56
8 25         51
```

9	26	57
10	27	62
11	28	60
12	29	91
13	30	70
14	31	73
15	32	67
16	33	89
17	34	74
18	35	88
19	36	90
20	37	77
21	38	84
22	39	87
23	40	77
24	41	70
25	42	90
26	43	74
27	44	80
28	45	63
29	46	69
30	47	80
31	48	45
32	49	70
33	50	70
34	51	82
35	52	95
36	53	97
37	54	111
38	55	101
39	56	98
40	57	108
41	58	99
42	59	138
43	60	117
44	61	99
45	62	107
46	63	97
47	64	102
48	65	95
49	66	98
50	67	94
51	68	82

52	69	87
53	70	88
54	71	87
55	72	81
56	73	74
57	74	65
58	75	66
59	76	59
60	77	45
61	78	44
62	79	53
63	80	36
64	81	49
65	82	39
66	83	55
67	84	51
68	85	24
69	86	24
70	87	17
71	88	22
72	89	11
73	90	15
74	91	7
75	92	12
76	93	4
77	94	4
78	97	2
79	99	1
80	NA	23

Aufgabe 4: Vorab-Prüfungen

Prüfe **vor** dem Modell die Voraussetzungen, die sich ohne geschätztes Modell klären lassen:

- Skalenniveau: Passt es für eine lineare Regression? - *pt20: ordinal, kann quasi-metrisch genutzt werden.*
- *pd12: ordinal, kann quasi-metrisch genutzt werden.*
- *pa02a: ordinal, kann quasi-metrisch genutzt werden.*
- *pa35: ordinal, kann quasi-metrisch genutzt werden.*


- eastwest: nominale, dichotome Variable.

- de15: dichotome, nominale Variable.

- age: metrische Variable.

- Exogenität: Hast du alle relevanten UVen im Modell? *Vermutlich nicht... aber ich tue jetzt mal so.*
- Unabhängigkeit der Beobachtungen: Was sagt das Studiendesign des ALLBUS? *Der ALLBUS ist eine Zufallsstichprobe ohne Messwiederholung: Keine empirische Prüfung - ergibt sich aus dem Studiendesign:-> Annahme erfüllt*
- Linearität: Sichte die Form des Zusammenhangs zwischen AV und der zentralen metrischen UV mit einem Scatterplot + Loess-Kurve.

```
allbus_c_2023 %>%  
ggplot2::ggplot(aes(x = pt20, y = pd12)) +  
  geom_jitter() + # überlagernde Punkte anzeigen  
  stat_smooth(method = "loess") + # Form des Zusammenhangs anzeigen (gerade = linear)  
  xlab("Vertrauen in das Europäische Parlament") + ylab("Bewertung von Demokratie als Idee")
```



(c): Man kann Linearität annehmen. Der Zusammenhang scheint jedoch schwach zu sein.

Aufgabe 5: Regression rechnen & interpretieren

Rechne deine multiple lineare Regression (mit `weights = wgthpew`) und gib die Ergebnisse in einer Tabelle aus. Interpretiere anschließend die Modellgüte (R^2) sowie Richtung, Stärke und Signifikanz der Effekte (*ceteris paribus*).

```
model_1 <- lm(pt20 ~ pd12 + pa02a + pa35 + eastwest + id02 + de15 + age,
              data = allbus_c_2023,
              weights = wgthpew)
```

```
summary(model_1)
```

Call:

```
lm(formula = pt20 ~ pd12 + pa02a + pa35 + eastwest + id02 + de15 +
    age, data = allbus_c_2023, weights = wgthpew)
```

Weighted Residuals:

Min	1Q	Median	3Q	Max
-4.8923	-0.9978	-0.0067	0.9836	4.4812

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.555732	0.245568	18.552	< 2e-16 ***
pd12	0.205456	0.033958	6.050	1.60e-09 ***
pa02a	-0.098500	0.028611	-3.443	0.000583 ***
pa35	-0.517882	0.024224	-21.379	< 2e-16 ***
eastwestNEUE BUNDESLAENDER	-0.134555	0.067349	-1.998	0.045810 *
id02	0.145463	0.036650	3.969	7.37e-05 ***
de15GENANNT	0.272782	0.063482	4.297	1.78e-05 ***
age	-0.010756	0.001393	-7.723	1.49e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.447 on 3378 degrees of freedom

(1860 observations deleted due to missingness)

Multiple R-squared: 0.2025, Adjusted R-squared: 0.2008

F-statistic: 122.5 on 7 and 3378 DF, p-value: < 2.2e-16

```
texreg::screenreg(
  list(model_1),
```

```

custom.coef.names = c("Intercept: Vertrauen in das EP", "Bewertung von Demokratie als Idee", "Politisches Interesse", "Politiker vertreten nur die Reichen", "Erhebungsgebiet: Ost", "Subjektive Schichteinstufung", "Hochschulabschluss: genannt", "Alter: Befragte(r)")
digits = 3
)

```

=====

Model 1

----- Intercept: Vertrauen in das EP 4.556 **(0.246)**

Bewertung von Demokratie als Idee 0.205 (0.034)

Politisches Interesse -0.098 **(0.029)**

Politiker vertreten nur die Reichen -0.518 (0.024)

Erhebungsgebiet: Ost -0.135 *
(0.067)

Subjektive Schichteinstufung 0.145 **(0.037)**

Hochschulabschluss: genannt 0.273 (0.063)

Alter: Befragte(r) -0.011 **(0.001)**

----- **R^2 0.202**

Adj. R^2 0.201

Num. obs. 3386

=====

p < 0.001; ** p < 0.01; * p < 0.05

Modellgüte (R^2) sowie Richtung, Stärke und Signifikanz der Effekte

- $R^2 = 0,201$. Die UVs erklären rund 20% der Varianz der AV Vertrauen ins Europäische Parlament. Damit ist der Erklärungsbeitrag des Modells moderat.

Fast alle Variablen haben eine Signifikanz von $p < 0.001$, nur Eastwest ist weniger signifikant mit $p < 0,05$.

Interpretation der Variablen:

- pd12: Je positiver Befragte die Demokratie als Idee bewerten, desto höher ist ihr Vertrauen in das Europäische Parlament. Bei einer Erhöhung der Demokratiebewertung um eine Einheit steigt das Vertrauen im Durchschnitt um 0,205 Punkte. Das ist ein relativ schwacher Effekt.

- pa02a: Personen mit höherem politischem Interesse weisen in diesem Modell geringeres Vertrauen in das Europäische Parlament auf. Das ist ein etwas überraschender Effekt schwacher Stärke.

- pa35: Eine stärkere Zustimmung zur Aussage „Politiker vertreten nur die Reichen“ geht mit geringerem Vertrauen in das Europäische Parlament einher. Eine Einheit höhere Zustimmung entspricht 0,518 Punkten weniger Vertrauen. Das ist ein starker Effekt.

- eastwest: Befragte aus Ostdeutschland haben durchschnittlich 0,135 Punkte weniger Vertrauen in das Europäische Parlament als Befragte aus Westdeutschland (Referenzgruppe).

- Kontrollvariablen *id02*, *de15* und *age*: Die Kontrollvariablen stehen ebenfalls mit der AV in Zusammenhang. Personen haben je höherer Kategorie der subjektiver Schichteinstufung 0.145 Punkte mehr Vertrauen. Befragte mit Hochschulabschluss haben im Durchschnitt 0.273 Punkte mehr Vertrauen. Pro Lebensjahr sinkt das Vertrauen sehr gering um statistisch 0.011 Punkte.

Um vergleichende Aussagen zu machen, berechne auch standardisierte Koeffizienten.

```
model_1_z <- lm(scale(pt20) ~ scale(pd12) + scale(pa02a) + scale(pa35) + eastwest + scale(id02) + de15 + scale(age),
  data = allbus_c_2023,
  weights = wghtpew)
```

```
summary(model_1_z)
```

Call:

```
lm(formula = scale(pt20) ~ scale(pd12) + scale(pa02a) + scale(pa35) +
    eastwest + scale(id02) + de15 + scale(age), data = allbus_c_2023,
    weights = wghtpew)
```

Weighted Residuals:

Min	1Q	Median	3Q	Max
-2.99416	-0.61064	-0.00409	0.60197	2.74259

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.01369	0.01883	-0.727	0.467335
scale(pd12)	0.10007	0.01654	6.050	1.60e-09 ***
scale(pa02a)	-0.05664	0.01645	-3.443	0.000583 ***
scale(pa35)	-0.35457	0.01658	-21.379	< 2e-16 ***
eastwestNEUE BUNDESLAENDER	-0.08235	0.04122	-1.998	0.045810 *
scale(id02)	0.06803	0.01714	3.969	7.37e-05 ***
de15GENANNT	0.16695	0.03885	4.297	1.78e-05 ***
scale(age)	-0.12014	0.01556	-7.723	1.49e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.8854 on 3378 degrees of freedom

(1860 observations deleted due to missingness)

Multiple R-squared: 0.2025, Adjusted R-squared: 0.2008

F-statistic: 122.5 on 7 and 3378 DF, p-value: < 2.2e-16

```
texreg::screenreg(
  list(model_1_z),
  custom.coef.names = c("Intercept: Vertrauen in das EP", "Bewertung von Demokratie als Idee",
  digits = 5
)
```

=====

Model 1

----- Intercept: Vertrauen in das EP -0.01369

(0.01883)

Bewertung von Demokratie als Idee 0.10007 (**0.01654**)

Politisches Interesse -0.05664 (0.01645)

Politiker vertreten nur die Reichen -0.35457 (**0.01658**)

Erhebungsgebiet: Ost -0.08235

(0.04122)

Subjektive Schichtestufung 0.06803 (0.01714)

Hochschulabschluss: genannt 0.16695 (**0.03885**)

Alter: Befragte(r) -0.12014 (0.01556)

----- R^2 0.20249

Adj. R^2 0.20084

Num. obs. 3386

===== **

p < 0.001; ** p < 0.01; * p < 0.05

Interpretation: Die Variable pa35 = Politiker vertreten nur die Reichen hat den weitaus größten Effekt, darauf folgen Alter und Bewertung der Demokratie, Sichteinstufung und politisches Interesse. Die Kontrollvariablen sind haben dabei ähnliche hohe Effekte, wie teile der UVs. Die dichotomen Variablen habe ich hier nicht interpretiert.

Aufgabe 6: Diagnostik

Prüfe nun **nachträglich** am Modell alle relevanten Annahmen. Nutze für jede die grafische und — wo möglich — die statistische Variante und halte deinen Befund fest:


- Linearität

```
plot(performance::check_model(model_1,
  check = "linearity",
  panel = FALSE))
```

\$NCV


Linearity

Reference line should be flat and horizontal



```
car::crPlots(model_1, terms = ~ pd12 + pa02a + pa35 + id02 + age)
```

Component + Residual Plots



```
lmtest::raintest(model_1)
```

Rainbow test


data: model_1

Rain = 1.0222, df1 = 1693, df2 = 1685, p-value = 0.3256

Die Linearität lässt sich grafisch und statistisch ($p > 0.05$) bestätigen

- Homoskedastizität

```
plot(performance::check_heteroscedasticity(model_1))
```



```
lmtest::bptest(model_1)
```

studentized Breusch-Pagan test

data: model_1

BP = 25.259, df = 7, p-value = 0.0006825


Beim grafischen Test ist die Linie nicht ganz flach (Streuung an den Rändern etwas größer) -> milde Heteroskedastizität. Statistisch kann ebenfalls keine Homoskedastizität (denn $p < 0,05$ = Heteroskedastizität) angenommen werden. Deshalb muss ich heteroskedastizitätsrobuste Standardfehler verwenden.

- Multikollinearität

```
plot(performance::check_collinearity(model_1))
```

Collinearity


High collinearity (VIF) may inflate parameter uncertainty



Geringe, unproblematisch Multikollinearität

- Ausreißer


```
plot(performance::check_outliers(model_1))
```

Es gibt keine kritischen Ausreißer

*Bei mir funktioniert auch folgende Variante, aber lässt sich (sowohl in der Quarto-Oberfläche, als auch als Plot) nicht gut anschauen.

```
performance::check_model(model_1)
```



Welche Annahmen sind erfüllt, welche verletzt? Halte dein Fazit kurz fest.

Linearität = erfüllt. Homoskedastizität = nicht erfüllt Multikollinearität = unproblematisch
Ausreißer: unproblematisch

Aufgabe 7: Konsequenzen ziehen

Zieh aus deiner Diagnostik die passende Konsequenz:

- Bei **Heteroskedastizität** → heteroskedastizitätsrobuste Standardfehler (HC3) rechnen und mit den normalen SEs vergleichen.
- Bei **verletzter Linearität** → eine UV transformieren (quadrieren / logarithmieren / kategorisieren) und prüfen, ob es das Modell verbessert.
- Sind alle Annahmen erfüllt → kurz begründen, dass keine Nachbesserung nötig ist.

```
hc3 <- lmtest::coeftest(model_1, vcov = sandwich::vcovHC(model_1, type = "HC3"))
```

```
hc3
```

```
t test of coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.5557321	0.2684380	16.9713	< 2.2e-16	***
pd12	0.2054559	0.0369061	5.5670	2.794e-08	***
pa02a	-0.0984999	0.0312417	-3.1528	0.0016311	**
pa35	-0.5178821	0.0262151	-19.7551	< 2.2e-16	***
eastwestNEUE BUNDESLAENDER	-0.1345546	0.0560570	-2.4003	0.0164346	*
id02	0.1454630	0.0407870	3.5664	0.0003669	***
de15GENANNT	0.2727822	0.0664823	4.1031	4.173e-05	***
age	-0.0107557	0.0014753	-7.2904	3.830e-13	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Was haben deine “remedies” bewirkt? Zieh eine kurze Bilanz aus der Diagnostik.

```
texreg::screenreg(
  list(model_1, model_1),
  custom.model.names = c("M1", "M1 (HC3)"),
  override.se        = list(0, hc3[, "Std. Error"]),
  override.pvalues   = list(0, hc3[, "Pr(>|t|)"]),
  digits = 3
)
```

	M1	M1 (HC3)
(Intercept)	4.556 *** (0.246)	4.556 *** (0.268)
pd12	0.205 *** (0.034)	0.205 *** (0.037)
pa02a	-0.098 *** (0.029)	-0.098 ** (0.031)
pa35	-0.518 *** (0.024)	-0.518 *** (0.026)
eastwestNEUE BUNDESLAENDER	-0.135 * (0.067)	-0.135 * (0.056)
id02	0.145 *** (0.037)	0.145 *** (0.041)
de15GENANNT	0.273 *** (0.063)	0.273 *** (0.066)
age	-0.011 *** (0.001)	-0.011 *** (0.001)

R ²	0.202	0.202
Adj. R ²	0.201	0.201
Num. obs.	3386	3386

*** p < 0.001; ** p < 0.01; * p < 0.05

Die Schlussfolgerungen ändern sich nicht, die milde Heteroskedastizität war bei $n \sim 4500$ praktisch folgenlos.

Aufgabe 8: Fazit

Beantworte auf Basis deiner Ergebnisse und unter Berücksichtigung der Diagnostik deine Forschungsfrage aus Aufgabe 2 in wenigen Sätzen.

Verschiedene Faktoren stehen mit dem Vertrauen in das Europäische Parlament in Zusammenhang. Das Modell kann 20% der Unterschiede der AV erklären. Eine positive Demokratieinstellung und eine höhere Schicht gehen mit höherem Vertrauen einher, während das Gefühl, dass politische Vertreter nur die Interessen Reicher vertreten, mit geringerem Vertrauen korreliert.