

Übung 09: Multiple Regression & Diagnostik

Politik vermessen: Quantitative Methoden mit R | SoSe 2026 | Maura Kratz

26.06.2026

Setup

Lade die für deine Analyse nötigen Pakete.

```
library(haven)
library(labelled)
library(dplyr)
library(ggplot2)

library(stargazer)
library(texreg)
library(performance)
library(see)
library(qqplotr)

options(scipen = 999)
```

Aufgabe 1: Daten laden

Lies den ALLBUS-Datensatz von 2023 ein. Speichere den Datensatz in einem Objekt namens `allbus_c_2023_raw`.

```
allbus_c_2023_raw <- haven::read_dta(here::here("./data/ZA8831_v1-3-0.dta"))
```

Aufgabe 2: Forschungsfrage & Variablenauswahl

In dieser Übung baust du deine eigene multiple Regression. Nimm dazu gern wieder die Datensatzübersicht zur Hand (siehe Sitzung 08). Überlege dir zunächst eine **Forschungsfrage**, die sich mit einer linearen Regression beantworten lässt.

Wähle dafür eine **abhängige Variable (AV)**, die (quasi-)metrisch ist, sowie **mindestens drei unabhängige Variablen (UVs)**, davon mindestens eine kategoriale. Welche Vermutung hast du bezüglich der Zusammenhänge?

Denke dabei auch an die **Exogenität**: Welche Variablen könnten deine AV *und* eine deiner UVs gemeinsam beeinflussen — und hast du sie als Kontrollvariablen dabei?

*Meine Forschungsfrage lautet: Wie beeinflussen wahrgenommen Bedrohungen die Zustimmung zu restriktiven Einstellungen gegenüber der Zuwanderung von Nicht-EU-Arbeitskräften?

Laut der Integrated Threat Theory (ITT) von Stephan und Stephan ist anti-migrantische Haltung von der Wahrnehmung einer Bedrohung beeinflusst. Diese werden in vier Kategorien unterteilt: realistische und symbolische Bedrohungen, negative Stereotypen und intergruppen Angst.

Als abhängige Variable mi10 zur Zustimmung vom Zuzug von nicht EU Arbeitskräften. Diese Variable ist eigentlich ordinal skaliert von 1 (uneingeschränkt) bis 3 Ganz unterbinden und wird als quasi metrische, intervallskalierte Variable behandelt. Meine Unabhängige Variablen sind Realistische Bedrohung: mp06 Ausländer nehmen arbeitsplätze weg Symbolische Bedrohung: ma01b Ausländer müssen ihren Lebensstil anpassen Negative stereotypen: mp07 Ausländer begehen häufiger straftaten Intergruppenangst: ma04 Ausländer sollten unter sich heiraten Als kontrollvariable habe ich Alter als age, Bildung mit de15 und Links-Rechts selbsteinstufung pa01*

Aufgabe 3: Variablen vorbereiten

Suche deine gewählten Variablen mit dem `look_for`-Befehl aus dem `labelled`-Package. Beantworte dir für jede: Welche Werte kann sie annehmen? Welche davon sind in Wahrheit “Missings”? Konvertiere diese zu `NA`. Dichotomisiere oder pole ggf. um, wo nötig. Prüfe anschließend mit `count()`, ob die Aufbereitung geklappt hat.

```
allbus_c_2023_raw %>%  
  labelled::look_for("mi10|mp06|ma01b|mp07|ma04|de15|pa01")
```

pos	variable	label	col_type	missing
71	mi10	ZUZUG VON: NICHT-EU-ARBE~	dbl+1b1	0

103	ma01b	AUSLAENDER: LEBENSSTILAN~	dbl+1b1	0
-----	-------	---------------------------	---------	---

106	ma04	AUSLAENDER: SOLLTEN UNTE~	dbl+1b1	0
-----	------	---------------------------	---------	---

115	mp06	AUSLAENDER:NEHMEN ARBEIT~	dbl+1b1	0
-----	------	---------------------------	---------	---

116	mp07	AUSLAENDER:BEGEHEN HAEUF~	dbl+1b1	0
-----	------	---------------------------	---------	---

245 pa01 LINKS-RECHTS-SELBSTEINST~ dbl+1b1 0

283 de15 BEFR.: HOCHSCHULABSCHLUSS dbl+1b1 0

345 scde15 GEGENW.EHEP.: HOCHSCHULA~ dbl+1b1 0

379 pde15 LEBENSPARTNER: HOCHSCHUL~ dbl+1b1 0

values

[-42] DATENFEHLER: MFN

[-11] TNZ: SPLIT

[-9] KEINE ANGABE

[-8] WEISS NICHT

[1] UNEINGESCHRAENKT

[2] ZUZUG BEGRENZEN

[3] GANZ UNTERBINDEN

[-42] DATENFEHLER: MFN

[-11] TNZ: SPLIT

[-9] KEINE ANGABE

[1] STIMME GAR NICHT ZU

[2] ..

[3] ..
[4] ..
[5] ..
[6] ..
[7] STIMME VOLL ZU
[-11] TNZ: SPLIT
[-9] KEINE ANGABE
[1] STIMME GAR NICHT ZU
[2] ..
[3] ..
[4] ..
[5] ..
[6] ..
[7] STIMME VOLL+GANZ ZU
[-11] TNZ: SPLIT
[-9] KEINE ANGABE
[1] STIMME GAR NICHT ZU
[2] ..
[3] ..
[4] ..
[5] ..
[6] ..
[7] STIMME VOLL+GANZ ZU
[-42] DATENFEHLER: MFN
[-11] TNZ: SPLIT
[-9] KEINE ANGABE
[1] STIMME GAR NICHT ZU
[2] ..
[3] ..
[4] ..
[5] ..
[6] ..
[7] STIMME VOLL+GANZ ZU
[-42] DATENFEHLER: MFN
[-9] KEINE ANGABE
[1] LINKS
[2] ..
[3] ..
[4] ..
[5] ..
[6] ..
[7] ..
[8] ..

```

[9] ..
[10] RECHTS
[-41] DATENFEHLER
[-10] TNZ: FILTER
[-9] KEINE ANGABE
[0] NICHT GENANNT
[1] GENANNT
[-41] DATENFEHLER
[-10] TNZ: FILTER
[-9] KEINE ANGABE
[0] NICHT GENANNT
[1] GENANNT
[-41] DATENFEHLER
[-10] TNZ: FILTER
[-9] KEINE ANGABE
[0] NICHT GENANNT
[1] GENANNT

```

```

allbus_c_2023 <- allbus_c_2023_raw %>%
  dplyr::mutate(
    mi10 = dplyr::case_when(mi10 < 0 ~ NA_real_, .default = mi10),

    de15 = dplyr::case_when(
      de15 < 0 ~ NA_real_,
      de15 == 0 ~ 1,
      de15 == 1 ~ 0
    ),

    pa01 = dplyr::case_when(pa01 < 0 ~ NA_real_, .default = pa01),
    age = dplyr::case_when(age < 0 ~ NA_real_, .default = age),
    mp07 = dplyr::case_when(mp07 < 0 ~ NA_real_, .default = mp07),
    ma04 = dplyr::case_when(ma04 < 0 ~ NA_real_, .default = ma04),
    mp06 = dplyr::case_when(mp06 < 0 ~ NA_real_, .default = mp06),
    ma01b = dplyr::case_when(ma01b < 0 ~ NA_real_, .default = ma01b)
  ) %>%
  tidyr::drop_na(pa01, age, mi10, mp06, ma01b, mp07, ma04, de15)

```

```

allbus_c_2023 %>%
  count(pa01,age,mi10,mp06,ma01b,mp07,ma04,de15)

```

```

# A tibble: 3,199 x 9
  pa01      age  mi10      mp06  ma01b  mp07  ma04  de15      n

```

```

      <dbl+lbl> <dbl+lbl> <dbl+lbl>      <dbl+1> <dbl+1> <dbl+1> <dbl+1> <dbl> <int>
1 1 [LINKS] 20      2 [ZUZUG BEG~ 2 [...] 3 [...] 3 [...] 1 [STI~ 1 1
2 1 [LINKS] 22      1 [UNEINGESC~ 1 [STI~ 2 [...] 1 [STI~ 1 [STI~ 1 2
3 1 [LINKS] 22      3 [GANZ UNTE~ 3 [...] 6 [...] 4 [...] 1 [STI~ 1 1
4 1 [LINKS] 23      1 [UNEINGESC~ 1 [STI~ 1 [STI~ 1 [STI~ 1 [STI~ 1 1
5 1 [LINKS] 23      1 [UNEINGESC~ 2 [...] 6 [...] 5 [...] 4 [...] 0 1
6 1 [LINKS] 23      2 [ZUZUG BEG~ 1 [STI~ 4 [...] 1 [STI~ 1 [STI~ 1 1
7 1 [LINKS] 24      1 [UNEINGESC~ 1 [STI~ 1 [STI~ 1 [STI~ 1 [STI~ 1 1
8 1 [LINKS] 24      1 [UNEINGESC~ 1 [STI~ 2 [...] 1 [STI~ 1 [STI~ 1 1
9 1 [LINKS] 24      2 [ZUZUG BEG~ 1 [STI~ 5 [...] 4 [...] 1 [STI~ 1 1
10 1 [LINKS] 25     1 [UNEINGESC~ 5 [...] 5 [...] 1 [STI~ 1 [STI~ 1 1
# i 3,189 more rows

```

Alle meine unabhängige Variablen sind von 1 bis 7 skaliert von 1 "stimme gar nicht zu" als eher ablehnende Haltung zu anti-migrantische Aussagen bis 7 Stimme voll zu als Zustimmung zu antimigrantische Aussagen. Meine Abhängige Variable ist von 1 bis 3 skaliert, von 1 Migration nicht einschränken zu 3 ganz unterbinden. Meine Kontrollvariablen gehen für Links-rechts skalierung gehen von 1 Links bis 10 Rechts. Für Bildung ist es eine dichotome Variable 0 Kein Abschluss und 1 Abschluss. Die Variable werde ich dichotomisieren und andersrum drehen, da ich sagen würde dass höhere Bildung anti-migrantische Haltung sinkt.

Aufgabe 4: Vorab-Prüfungen


.Prüfe vor dem Modell die Voraussetzungen, die sich ohne geschätztes Modell klären lassen:

- Skalenniveau: Passt es für eine lineare Regression?
- Exogenität: Hast du alle relevanten UVen im Modell?
- Unabhängigkeit der Beobachtungen: Was sagt das Studiendesign des ALLBUS?
- Linearität: Sichte die Form des Zusammenhangs zwischen AV und der zentralen metrischen UV mit einem Scatterplot + Loess-Kurve


```

allbus_c_2023 %>%
ggplot2::ggplot(aes(x = mp06, y = mi10)) +
geom_jitter() +
stat_smooth(method = "loess") +
xlab("Ausländer nehmen Arbeitsplätze weg") + ylab("Zuzug von nicht EU- Arbeitskräften beschr


```




```
allbus_c_2023 %>%
  ggplot2::ggplot(aes(x = ma01b, y = mi10)) +
  geom_jitter() +
  stat_smooth(method = "loess") +
  xlab("Ausländer müssen ihren Lebensstil anpassen") + ylab("Zuzug von nicht EU-Arbeitskräften beschränken")
```




```
allbus_c_2023 %>%
  ggplot2::ggplot(aes(x = mp07, y = mi10)) +
  geom_jitter() +
  stat_smooth(method = "loess") +
  xlab("Ausländer begehen häufiger Straftaten") + ylab("Zuzug von nicht EU- Arbeitskräften beschränken")
```




```
allbus_c_2023 %>%
  ggplot2::ggplot(aes(x = ma04, y = mi10)) +
  geom_jitter() +
  stat_smooth(method = "loess") +
  xlab("Ausländer sollten unter sich heiraten") + ylab("Zuzug von nicht EU- Arbeitskräften beschränken")
```



```
allbus_c_2023 %>%
  ggplot2::ggplot(aes(x = pa01, y = mi10)) +
  geom_jitter() +
  stat_smooth(method = "loess") +
  xlab("Links-Rechts-Selbsteinstufung (1= Links, 10 = Rechts)") + ylab("Zuzug von nicht EU- Ar
```



```
allbus_c_2023 %>%
  ggplot2::ggplot(aes(x = age, y = mi10)) +
  geom_jitter() +
  stat_smooth(method = "loess") +
  xlab("Alter") + ylab("Zuzug von nicht EU- Arbeitskräften beschränken")
```



Meine abhängige Variable hat nur 3 Skalenniveaus was etwas begrenzt ist, aber da wir sie als quasi metrische behandeln und die intervallen ähnlich groß sind können wir eine lineare Regression machen. Für die Exogenität beeinflusst laut die ITT Theorie die wahrgenommene Bedrohung die Einstellung zum Thema Migration. Alle vier Hauptkategorien werden in den UVs repräsentiert. Außerdem habe ich kontrollvariablen zum Alter, politische Einstellungen und Bildungsgrad hinzugefügt um Endogenität zu kontrollieren. Der ALLBUS ist eine Zufallsstichprobe ohne Messwiederholung. Die Beobachtungen sind unabhängig voneinander. Auf den Scatterplots kann man sagen dass alle Variablen einen linearen Zusammenhang haben. Eventuell hat die Variable ma01b einen exponentiellen Zusammenhang. Dies können wir dann nachträglich statistisch prüfen und korrigieren.

Aufgabe 5: Regression rechnen & interpretieren

Rechne deine multiple lineare Regression (mit `weights = wghtpew`) und gib die Ergebnisse in einer Tabelle aus. Interpretiere anschließend die Modellgüte (R^2) sowie Richtung, Stärke und Signifikanz der Effekte (*ceteris paribus*).

```
model_1 <- lm(mi10 ~ mp06 + age + ma01b + mp07+ ma04+ pa01+ de15,
              data = allbus_c_2023,
              weights = wghtpew)
summary(model_1)
```

Call:

```
lm(formula = mi10 ~ mp06 + age + ma01b + mp07 + ma04 + pa01 +  
    de15, data = allbus_c_2023, weights = wghtpew)
```

Weighted Residuals:

	Min	1Q	Median	3Q	Max
	-1.67677	-0.25381	0.04805	0.26965	1.73078

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.0295133	0.0404761	25.435	< 0.0000000000000002 ***
mp06	0.0583957	0.0074215	7.868	0.00000000000000485 ***
age	0.0043194	0.0005189	8.325	< 0.0000000000000002 ***
ma01b	0.0387569	0.0063817	6.073	0.00000000140009060 ***
mp07	0.0316272	0.0055992	5.649	0.00000001757789293 ***
ma04	0.0224955	0.0071232	3.158	0.0016 **
pa01	0.0273445	0.0056449	4.844	0.00000133141838179 ***
de15	0.0726543	0.0222489	3.266	0.0011 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5186 on 3242 degrees of freedom

Multiple R-squared: 0.1705, Adjusted R-squared: 0.1687

F-statistic: 95.21 on 7 and 3242 DF, p-value: < 0.00000000000000022

```
texreg::screenreg(list (model_1), digits = 3)
```

```
=====
Model 1
-----
(Intercept)    1.030 ***
                (0.040)
mp06            0.058 ***
                (0.007)
age             0.004 ***
                (0.001)
ma01b           0.039 ***
                (0.006)
mp07            0.032 ***
                (0.006)
```

```

ma04          0.022 **
              (0.007)
pa01          0.027 ***
              (0.006)
de15          0.073 **
              (0.022)
-----
R^2           0.171
Adj. R^2      0.169
Num. obs.     3250
=====
*** p < 0.001; ** p < 0.01; * p < 0.05

```

Insgesamt erklärt der Modell 17% der Einflüsse von der Meinung zur Restriktion der Migration von nicht EU- Arbeitskräfte. Der stärkste Prädiktor ist mp06. Das bedeutet das wenn die Zustimmung zu der Aussage “Ausländer nehmen Arbeitsplätze weg” um 1 steigt, die Meinung zur Einschränkung von Migration um 0.058 steigt. Außerdem sind die UVs ma01b und mp07 statistische hochsignifikant.

Um vergleichende Aussagen zu machen, berechne auch standardisierte Koeffizienten.

```

model_1_z <- lm(scale(mi10) ~ scale(mp06) + scale(age) + scale(ma01b)+ scale(mp07)+ scale(ma
              data = allbus_c_2023,
              weights = wghtpew)

summary(model_1_z)

```

Call:

```

lm(formula = scale(mi10) ~ scale(mp06) + scale(age) + scale(ma01b) +
    scale(mp07) + scale(ma04) + scale(pa01) + de15, data = allbus_c_2023,
    weights = wghtpew)

```

Weighted Residuals:

```

      Min       1Q   Median       3Q      Max
-2.92279 -0.44241  0.08375  0.47003  3.01693

```

Coefficients:

```

              Estimate Std. Error t value      Pr(>|t|)
(Intercept) -0.09629    0.03393   -2.838    0.00457 **
scale(mp06)  0.14674    0.01865    7.868 0.000000000000000485 ***
scale(age)   0.13692    0.01645    8.325 < 0.00000000000000002 ***

```

```

scale(ma01b) 0.11440 0.01884 6.073 0.00000000140009060 ***
scale(mp07) 0.10839 0.01919 5.649 0.000000001757789293 ***
scale(ma04) 0.05880 0.01862 3.158 0.00160 **
scale(pa01) 0.08523 0.01760 4.844 0.00000133141838179 ***
de15 0.12664 0.03878 3.266 0.00110 **

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.904 on 3242 degrees of freedom

Multiple R-squared: 0.1705, Adjusted R-squared: 0.1687

F-statistic: 95.21 on 7 and 3242 DF, p-value: < 0.000000000000000022

```

texreg::screenreg(
  list(model_1, model_1_z))

```

```

=====
              Model 1      Model 2
-----
(Intercept)    1.03 ***    -0.10 **
               (0.04)      (0.03)
mp06            0.06 ***
               (0.01)
age             0.00 ***
               (0.00)
ma01b           0.04 ***
               (0.01)
mp07            0.03 ***
               (0.01)
ma04            0.02 **
               (0.01)
pa01            0.03 ***
               (0.01)
de15            0.07 **     0.13 **
               (0.02)      (0.04)
scale(mp06)                0.15 ***
                        (0.02)
scale(age)                0.14 ***
                        (0.02)
scale(ma01b)              0.11 ***
                        (0.02)
scale(mp07)              0.11 ***

```

```

                                (0.02)
scale(ma04)                     0.06 **
                                (0.02)
scale(pa01)                     0.09 ***
                                (0.02)
-----
R^2                             0.17      0.17
Adj. R^2                       0.17      0.17
Num. obs.                      3250      3250
=====
*** p < 0.001; ** p < 0.01; * p < 0.05

```

Der Effekt hat sich bei den Standardisierten Koeffizienten verstärkt. Jetzt steigt zum Beispiel mp06 um 0.15 pro Einheit.

Aufgabe 6: Diagnostik

Prüfe nun nachträglich am Modell alle relevanten Annahmen: - Linearität - Homoskedastizität - Multikollinearität - Ausreißer. Nutze für jede die grafische und — wo möglich — die statistische Variante und halte deinen Befund fest:

```


plot(performance::check_model(model_1,
                                check = "linearity",
                                panel = FALSE))

```

\$NCV


Linearity

Reference line should be flat and horizontal



```
car::crPlots(model_1, terms = ~ mp06 + ma01b+mp07+ma04+pa01+age)
```

Component + Residual Plots




```
lmtest::raintest(model_1)
```

Rainbow test

data: model_1

Rain = 0.97468, df1 = 1625, df2 = 1617, p-value = 0.6972

```
plot(performance::check_heteroscedasticity(model_1))
```



```
lmtest::bptest(model_1)
```

studentized Breusch-Pagan test


data: model_1

BP = 45.426, df = 7, p-value = 0.000000113

```
plot(performance::check_collinearity(model_1))
```

Collinearity

High collinearity (VIF) may inflate parameter uncertainty



```
allbus_c_2023 %>%
  dplyr::select(mi10, mp06, ma01b, mp07, ma04, pa01, age, de15) %>%
  dplyr::filter(!is.na(mi10), !is.na(mp06), !is.na(ma01b), !is.na(mp07), !is.na(ma04), !is.na(pa01))
correlation::correlation()
```

Correlation Matrix (pearson-method)


Parameter1	Parameter2	r	95% CI	t(3248)	p
mi10	mp06	0.29	[0.26, 0.32]	17.08	< .001***
mi10	ma01b	0.29	[0.26, 0.32]	17.23	< .001***
mi10	mp07	0.29	[0.26, 0.32]	17.42	< .001***
mi10	ma04	0.23	[0.19, 0.26]	13.26	< .001***
mi10	pa01	0.22	[0.19, 0.25]	12.89	< .001***
mi10	age	0.20	[0.17, 0.24]	11.84	< .001***
mi10	de15	0.15	[0.12, 0.18]	8.71	< .001***
mp06	ma01b	0.30	[0.27, 0.33]	17.93	< .001***
mp06	mp07	0.41	[0.38, 0.44]	25.89	< .001***
mp06	ma04	0.34	[0.31, 0.37]	20.69	< .001***
mp06	pa01	0.22	[0.19, 0.26]	13.09	< .001***
mp06	age	0.08	[0.04, 0.11]	4.36	< .001***
mp06	de15	0.15	[0.12, 0.19]	8.83	< .001***

ma01b		mp07		0.44		[0.41, 0.47]		27.78		< .001***
ma01b		ma04		0.26		[0.23, 0.30]		15.64		< .001***
ma01b		pa01		0.33		[0.29, 0.36]		19.63		< .001***
ma01b		age		0.23		[0.20, 0.26]		13.36		< .001***
ma01b		de15		0.21		[0.17, 0.24]		12.11		< .001***
mp07		ma04		0.29		[0.26, 0.32]		17.41		< .001***
mp07		pa01		0.32		[0.29, 0.35]		19.38		< .001***
mp07		age		0.11		[0.08, 0.15]		6.60		< .001***
mp07		de15		0.15		[0.12, 0.19]		8.93		< .001***
ma04		pa01		0.17		[0.13, 0.20]		9.68		< .001***
ma04		age		0.18		[0.15, 0.22]		10.70		< .001***
ma04		de15		0.15		[0.12, 0.18]		8.66		< .001***
pa01		age		0.07		[0.04, 0.11]		4.18		< .001***
pa01		de15		0.14		[0.10, 0.17]		7.83		< .001***
age		de15		0.10		[0.06, 0.13]		5.66		< .001***


p-value adjustment method: Holm (1979)

Observations: 3250

```
plot(performance::check_outliers(model_1))
```



```
plot(model_1, which = 4)
```



Welche Annahmen sind erfüllt, welche verletzt? Halte dein Fazit kurz fest.

Die p -Wert des Rainbow tests ist über 0.05, das heißt dass wir H_1 ablehnen können, und dass der Zusammenhang linear ist. Die Referenzlinie verläuft bei Null bei dem Residuen vs Fitted plot. Die Gerade verläuft auch bei 0 bei dem Component + Residual plot für alle einzelne Variablen. Für die Homoskedastizität verläuft die Linie bei dem Homogeneity of Variance plot nicht gerade. Außerdem ist der p -Wert beim Breusch-Pagan test unter 0.05, was heißt dass wir Heteroskedastizität annehmen müssen. Bei der Multikollinearität liegen alle Variablen unter 5. Bei der Korrelationsmatrix gibt es keine Korrelation zwischen den unabhängigen Variablen die über 0.8 liegt. Das heißt dass wir Multikollinearität ausschließen können. Wir sehen dass es keine großen Ausreißer gibt, die wir ausschließen müssten.

Aufgabe 7: Konsequenzen ziehen

Zieh aus deiner Diagnostik die passende Konsequenz:

- Bei **Heteroskedastizität** → heteroskedastizitätsrobuste Standardfehler (HC3) rechnen und mit den normalen SEs vergleichen.
- Bei **verletzter Linearität** → eine UV transformieren (quadrieren / logarithmieren / kategorisieren) und prüfen, ob es das Modell verbessert.

- Sind alle Annahmen erfüllt → kurz begründen, dass keine Nachbesserung nötig ist.

```
hc3 <- lmtest::coefTest(model_1, vcov = sandwich::vcovHC(model_1, type = "HC3"))
texreg::screenreg(
  list(model_1, model_1),
  custom.model.names = c("M1", "M1 (HC3)"),
  override.se       = list(0, hc3[, "Std. Error"]),
  override.pvalues  = list(0, hc3[, "Pr(>|t|)"]),
  digits = 3
)
```

```
=====
              M1              M1 (HC3)
-----
(Intercept)   1.030 ***      1.030 ***
              (0.040)       (0.043)
mp06          0.058 ***      0.058 ***
              (0.007)       (0.008)
age           0.004 ***      0.004 ***
              (0.001)       (0.001)
ma01b         0.039 ***      0.039 ***
              (0.006)       (0.007)
mp07          0.032 ***      0.032 ***
              (0.006)       (0.006)
ma04          0.022 **       0.022 **
              (0.007)       (0.008)
pa01          0.027 ***      0.027 ***
              (0.006)       (0.006)
de15          0.073 **       0.073 ***
              (0.022)       (0.022)
-----
R^2           0.171          0.171
Adj. R^2      0.169          0.169
Num. obs.     3250           3250
=====
*** p < 0.001; ** p < 0.01; * p < 0.05
```

Was haben deine “remedies” bewirkt? Zieh eine kurze Bilanz aus der Diagnostik.

die UV ma04 wird weniger signifikant, und die kontrollvariable de15 auch.

Aufgabe 8: Fazit

Beantworte auf Basis deiner Ergebnisse und unter Berücksichtigung der Diagnostik deine Forschungsfrage aus Aufgabe 2 in wenigen Sätzen.

*Insgesamt zeigen die Ergebnisse, dass alle vier Kategorien wahrgenommener Bedrohungen positiv mit der Zustimmung zusammenhängen, die Migration aus Nicht-EU-Ländern zu beschränken. Den stärksten Zusammenhang weist die realistische Bedrohung auf, gemessen durch die Aussage, dass Ausländer Arbeitsplätze wegnehmen. Es folgt die symbolische Bedrohung, die durch die Einstellung erfasst wird, dass Ausländer ihren Lebensstil anpassen sollten. Auch negative Stereotype, insbesondere die Annahme, dass Ausländer häufiger Straftaten begehen, stehen in einem positiven Zusammenhang mit der Zustimmung zu einer Einschränkung der Migration. Den schwächsten Zusammenhang zeigt die Variable zur Intergruppenangst.

Der vergleichsweise geringe Effekt der Intergruppenangst könnte darauf zurückzuführen sein, dass die verwendete Variable („Ausländer sollten unter sich heiraten“) dieses theoretische Konstrukt nur eingeschränkt abbildet. Intergruppenangst beschreibt vielmehr ein Gefühl von Unwohlsein oder Unsicherheit im direkten Kontakt mit Angehörigen einer Fremdgruppe. Die verwendete Variable erfasst diesen Aspekt daher möglicherweise nicht vollständig.

Insgesamt sprechen die Ergebnisse dafür, dass die Annahmen der Integrated Threat Theory durch die ALLBUS-Daten unterstützt werden. Alle vier Dimensionen wahrgenommener Bedrohung weisen signifikante positive Zusammenhänge mit der Zustimmung zu einer Beschränkung der Migration aus Nicht-EU-Ländern auf. Die Ergebnisse liefern somit empirische Evidenz für die Relevanz der Theorie, ohne jedoch einen kausalen Zusammenhang nachzuweisen. *